



TRAKYA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
BLM450 YAPAY SİNİR AĞLARINA GİRİŞ
PROJE RAPORU

PROJE ADI:

Tahta Görüntüsünden Okunabilir
Ders Notu Üretimi: Board2Note

PROJE EKİBİ:

1221602035 – Samet Ünver
1221602013– Hilal Kaynar
1221602038 – Batuhan Güneysu
1221602040 – Taha Demir
1231602808 – Halit Eren Deniz

PROJE DANIŞMANI:

Dr. Öğr. Üyesi Turgut DOĞAN

Edirne – 2026

İÇİNDEKİLER

1. GİRİŞ & PROJENİN TANITIMI	5
1.1 Projenin Amacı	5
1.2 Projenin Kapsamı	6
1.3 Benzer Projeler ve Literatürdeki Durumu	7
1.4 Projenin Yenilikçi Yönleri.....	8
2. GEREKSİNİM ANALİZİ	9
2.1 Platform ve İşletim Sistemi Gereksinimleri	9
2.2 Geliştirme Sürecindeki Kaynak Kısıtları ve Çözüm Önerileri	10
2.3 Projenin Çözüm Ürettiği Sorunlar	12
2.4 Mevcut Örneklerine Göre Üstünlükleri	12
2.5 Hedef Kitle	13
2.6 Kullanılan Teknolojiler.....	14
3. TASARIM	16
3.1 Sistem Mimarisi.....	16
3.1.1 Sunum Katmanı	17
3.1.2 İş Katmanı	17
3.1.3 Görüntü İşleme Katmanı	18
3.1.4 Yapay Zeka Katmanı	19
3.1.5 Veri Katmanı	20
3.1.6 Katmanlar Arası İletişim	20
3.2 Veri Tasarımı ve Not Yönetimi	21
3.3 Projenin Çalışma Şekli	24
3.3.1 Genel Çalışma Akışı.....	25
4. GELİŞTİRME	26

4.1	Geliştirme Sürecine Genel Bakış.....	26
4.2	Veri Setleri ve Veri Ön İşleme Süreci	26
4.2.1	Kendi Veri Setimizin Oluşturulması	27
4.2.2	TTM İçin Kullanılan Veri Setleri.....	30
4.2.3	TTM Veri Ön İşleme Süreci.....	31
4.2.4	YGM İçin Kullanılan Sentetik Veri Seti	31
4.2.5	YGM İçin Sentetik Veri Üretim Yaklaşımı	32
4.2.6	YGM Veri Yapısı ve Hedef Çıktılar	33
4.2.7	YGM Veri Ön İşleme Süreci.....	33
4.2.8	Yazı Bölgelerine Ağırlık Verilmesi ve Maske Kullanımı.....	33
4.2.9	Çalışma Zamanı Ön İşleme Süreci	34
4.3	Mobil Uygulama Geliştirme Süreci.....	34
4.3.1	Ekranlar	35
4.4	Görüntü İşleme Geliştirme Süreci	39
4.5	Model Geliştirme ve Karşılaştırma Süreci	40
4.6	TTM: Tahta Tespit Modeli İçin Denenen Model Yapıları	41
4.6.1	TTM-V1: İlk Eğitim Modeli	41
4.6.2	TTM-V2: Final Model	42
4.7	YGM: Yazı Güçlendirme Modeli İçin Denenen Model Yapıları.....	42
4.7.1	YGM-V1: Tek Çıkışlı NAFNet Tabanlı Başlangıç Modeli	42
4.7.2	YGM-V2: NAFNet-Base64 Multi-Head Model	43
4.7.3	YGM-V3: Denetimli + Denetimsiz GAN Destekli Multi-Head Model.....	44
4.8	Final Model Seçimi	45
4.9	OCR ve AI Açıklaması Üretme Modülü	46
4.10	Projenin Çalıştırılması İçin Gereksinimler ve Kurulum Aşamaları.....	47
4.10.1	Python Model Geliştirme ve Eğitim Ortamı Gereksinimleri	47

4.10.2	Android Mobil Uygulama Gereksinimleri	50
4.10.3	Harici Araç ve Servis Kurulumları.....	52
4.10.4	Android Mobil Uygulama Kurulum Aşamaları	53
5.	TEST ve DOĞRULAMA.....	54
5.1	Test ve Hata Ayıklama Mekanizmaları	54
5.1.1	TTM Testleri	54
5.1.2	YGM Çok Çıkışlı Test ve Doğrulama Süreci	55
5.1.3	YGM Test Sonuçlarının Değerlendirilmesi	56
5.1.4	Mask Head İçin Threshold Testi	57
5.1.5	Görsel Çıktı ve Manuel Kalite Kontrolleri.....	58
5.2	Manuel Testler Sonucu Alınan Bazı Hatalar	59
5.3	Genel Değerlendirme.....	61
6.	SONUÇ	63
6.1	Genel Sistem Değerlendirmesi	63
6.2	TTM ve YGM Test Çıktıları	65
6.2.1	TTM-V1: LR-ASPP + MobileNetV3-Large Tahta Tespit Modeli	65
6.2.2	TTM-V2: Temizlenmiş Veri ve Dağıtıma Uygun TTM Sürümü	65
6.2.3	YGM-V1: NAFNet-Small ile İlk Yazı Güçlendirme Yaklaşımı.....	66
6.2.4	YGM-V2: NAFNet-Base Multi-Head Model	67
6.2.5	YGM-V3: Denetimli + Denetimsiz GAN Destekli Final Modeli	69
6.2.6	Modellerin Genel Sonuç Yorumu ve Final Kullanım Değerlendirmesi.....	72
6.3	Mobil Uygulama ve Not Çıktısı Örnekleri	73
6.4	Genel Kazanımlar ve Geliştirme Alanları	74
6.5	Genel Sonuç.....	76
6.6	Projemizin Github ve Drive Linkleri.....	76
7.	KAYNAKLAR.....	77

1. GİRİŞ & PROJENİN TANITIMI

Günümüzde eğitim süreçlerinde dijital teknolojilerin kullanımı giderek artmaktadır. Özellikle öğrenciler, ders sırasında anlatılan bilgileri daha hızlı kaydetmek, düzenlemek ve daha sonra tekrar kullanmak için farklı dijital araçlardan yararlanmaktadır. Buna rağmen sınıf ve amfi ortamlarında ders anlatımı hâlâ büyük ölçüde tahta kullanımı üzerinden ilerlemektedir. Bu durum, öğrencilerin tahtadaki bilgileri anlık olarak deftere geçirmesini veya daha sonra incelemek üzere fotoğrafını çekmesini gerekli hale getirmektedir.

Ancak tahta fotoğraflarının her zaman kaliteli ve okunabilir olması mümkün değildir. Derslik ortamındaki ışık yetersizliği, gölge, parlama, düşük kamera kalitesi, açılı çekim ve uzak mesafe gibi etkenler tahta üzerindeki yazıların netliğini azaltabilmektedir. Bu nedenle çekilen görüntüler çoğu zaman doğrudan ders notu olarak kullanılmaya uygun olmamakta, öğrencilerin bu görüntüleri tekrar düzenlemesi veya manuel olarak yeniden yazması gerekmektedir. Bu süreç hem zaman kaybına neden olmakta hem de not alma verimliliğini düşürmektedir.

Bu proje kapsamında geliştirilen **Board2Note**, **tahta görüntülerini daha okunabilir, düzenli ve kullanılabilir notlara dönüştürmeyi amaçlayan** yapay zekâ destekli bir mobil uygulamadır. Uygulama, kullanıcı tarafından çekilen veya galeriden seçilen **tahta görüntüsünü işleyerek tahta alanının belirlenmesini, görüntünün düzeltilmesini ve sonrasında not haline getirilmesini sağlar**. Böylece öğrenciler, ders sırasında yalnızca tahta fotoğrafını alarak daha sonra bu görüntüden düzenli dijital notlar oluşturabilir.

Board2Note projesi; görüntü işleme, mobil uygulama geliştirme ve yapay zekâ destekli not üretimi bileşenlerini bir araya getiren bütünlük bir sistem olarak tasarlanmıştır. Projenin temel hedefi, öğrencilerin ders notu alma sürecini kolaylaştırmak, tahta görüntülerinden daha kaliteli çıktılar elde etmek ve eğitim sürecinde dijital araçların kullanımını daha verimli hale getirmektir. Bu yönüyle proje, hem öğrenci deneyimini iyileştirmeyi hem de geleneksel not alma yöntemlerini modern teknolojilerle desteklemeyi amaçlamaktadır.

1.1 Projenin Amacı

Bu projenin amacı, sınıf ve amfi ortamlarında çekilen tahta görüntülerini yapay zekâ destekli yöntemlerle işleyerek daha okunabilir, düzenli ve kullanılabilir dijital notlara dönüştürmektir. Board2Note, öğrencilerin ders sırasında not alma sürecini kolaylaştırmayı ve tahta fotoğraflarından verimli bir şekilde ders materyali oluşturmayı hedeflemektedir.

Projenin temel amaçları şunlardır:

- Tahta görüntülerindeki gölge, parlama, bulanıklık ve düşük kontrast gibi kalite sorunlarını azaltmak.
- Açılı çekilen tahta fotoğraflarında perspektif düzeltme işlemi yaparak görüntüyü daha düzgün hale getirmek.
- Kullanıcının tahta alanını seçebilmesini ve görüntü üzerinde gerekli düzenlemeleri yapabilmesini sağlamak.
- İşlenen tahta görüntülerinden daha okunabilir ve düzenli notlar oluşturmak.
- Yapay zekâ destekli yöntemlerle tahta üzerindeki yazıları dijital nota dönüştürmek.
- Öğrencilerin ders notlarını daha hızlı kaydetmesini, düzenlemesini ve paylaşmasını sağlamak.
- Mobil cihazlar üzerinden kolay kullanılabilen, modern ve kullanıcı dostu bir not oluşturma sistemi geliştirmek.
- Oluşturulan dijital notlarda OCR işlemi uygulaması ve sonrasında yapay zeka servisleri aracılığıyla ilgili notun anlatımı.

Bu amaçlar doğrultusunda Board2Note, geleneksel not alma yöntemlerini dijital teknolojilerle destekleyen pratik bir çözüm sunmaktadır. Proje, öğrencilerin zamandan tasarruf etmesine, ders içeriklerini daha düzenli saklamasına ve tahta görüntülerinden daha kaliteli dijital notlar elde etmesine katkı sağlamayı hedeflemektedir.

1.2 Projenin Kapsamı

Board2Note projesi, sınıf veya amfi ortamında çekilen tahta görüntülerinin mobil uygulama üzerinden işlenerek dijital nota dönüştürülmesini kapsamaktadır. Proje; kullanıcının tahta fotoğrafı çekmesi veya galeriden görsel seçmesiyle başlayan, tahta alanının belirlenmesi, perspektif düzeltme, görüntü iyileştirme, metin çıkarımı ve not oluşturma adımlarını içeren bütünleşik bir sistem olarak tasarlanmıştır.

Proje kapsamında yer alan temel bileşenler şunlardır:

- Kullanıcının kamera ile tahta fotoğrafı çekebilmesi veya galeriden görsel seçebilmesi.
- Seçilen görüntünün önizleme ekranında kontrol edilebilmesi.
- Tahta alanının gerekli durumlarda köşe noktalarının düzenlenebilmesi.
- Açılı çekilen tahta görüntülerinde perspektif düzeltme işleminin yapılması.

- Tahta görüntüsündeki gölge, parlama, bulanıklık ve düşük kontrast gibi problemlerin azaltılması.
- Görüntünün OCR işlemine daha uygun hale getirilmesi.
- Tahta üzerindeki yazıların dijital nota dönüştürülmesi.
- Elde edilen metnin not editörü ekranında düzenlenebilmesi.
- Oluşturulan notların uygulama içerisinde saklanabilmesi.
- Notların derslere göre sınıflandırılabilmesi ve daha sonra tekrar görüntülenebilmesi.
- Kullanıcı dostu, modern ve mobil cihazlara uygun bir arayüz tasarlanması.
- Oluşturulan dijital notların yapay zeka servisleri aracılığıyla anlatılması.

Bu proje, özellikle öğrencilerin ders sırasında çektiği tahta fotoğraflarını daha düzenli ve kullanılabilir notlara dönüştürmeye odaklanmaktadır. Proje kapsamında geliştirilen sistem, tamamen mobil kullanım senaryosuna uygun olarak ele alınmış ve öğrencilerin not alma sürecini hızlandırmayı hedeflemiştir.

1.3 Benzer Projeler ve Literatürdeki Durumu

Tahta görüntülerinin dijital ortama aktarılması ve düzenlenebilir notlara dönüştürülmesi, hem akademik çalışmalarda hem de ticari mobil uygulamalarda ele alınan bir problemdir. Literatürde bu alandaki çalışmalar genel olarak görüntü alma, tahta veya belge alanını tespit etme, perspektif düzeltme, görüntü iyileştirme adımlarına odaklanmaktadır. Özellikle açılı çekilen tahta görüntülerinde perspektif bozulması, gölge, düşük kontrast ve okunabilirlik sorunları önemli problemler arasında yer almaktadır.

Günümüzde **Microsoft Lens**, **Adobe Scan** ve **CamScanner** gibi mobil uygulamalar belge veya tahta görüntülerini tarama, kırpma, perspektif düzeltme ve PDF olarak dışa aktarma gibi özellikler sunmaktadır. Microsoft Lens; belgeler, beyaz tahtalar, el yazısı notlar ve metin içeren görsellerden bilgi yakalama, kenarlık ayarlama, metin çıkarma ve paylaşma özellikleriyle öne çıkmaktadır. Adobe Scan ise mobil cihazı belge tarayıcıya dönüştürerek yapay zekâ desteğiyle perspektif düzeltme, metni keskinleştirme, parlama ve gölge azaltma gibi işlemler sunmaktadır. CamScanner da OCR, PDF/JPG/Word/TXT formatlarında dışa aktarma ve belge yönetimi özellikleriyle benzer bir kullanım alanına sahiptir.

Board2Note projesi, mevcut belge tarama uygulamalarından **farklı olarak özellikle ders ortamında çekilen tahta görüntülerini dijital ders notuna dönüştürme problemine** odaklanmaktadır. Proje yalnızca görüntüyü kırpma veya PDF'ye dönüştürme amacı

taşımamakta; tahta alanı seçimi, perspektif düzeltme, görüntü iyileştirme ve not editörü ile düzenlenebilir not oluşturma adımlarını tek bir mobil uygulama akışında birleştirmektedir. Bu yönüyle Board2Note, genel amaçlı tarama uygulamalarından ziyade öğrencilerin ders notu alma sürecini kolaylaştırmaya yönelik özelleştirilmiş bir çözüm olarak konumlandırılmaktadır.

1.4 Projenin Yenilikçi Yönleri

Board2Note projesinin yenilikçi yönü, tahta görüntülerini yalnızca fotoğraf olarak kaydetmek yerine bu görüntüleri işleyerek düzenli, okunabilir ve dijital notlara dönüştürmeyi hedeflemesidir. Mevcut birçok uygulama belge tarama veya PDF oluşturma üzerine odaklanırken, Board2Note özellikle eğitim ortamlarında kullanılan tahta görüntülerini ders notuna dönüştürme problemine yönelik geliştirilmiştir. Bu sayede proje, öğrencilerin ders sırasında çektiği dağınık ve düşük kaliteli tahta fotoğraflarını daha kullanışlı öğrenme materyallerine dönüştürmeyi amaçlamaktadır.

Projenin başlıca yenilikçi yönleri şunlardır:

- **Tahta görüntülerine özel mobil iş akışı sunması:** Uygulama, genel belge tarama uygulamalarından farklı olarak doğrudan tahta fotoğraflarını işlemeye ve not haline getirmeye odaklanmaktadır.
- **Tahta alanı seçimi ve perspektif düzeltme adımlarını içermesi:** Açılı veya düzensiz çekilen tahta görüntülerinde kullanıcının tahta alanını belirlemesine ve görüntünün daha düzgün hale getirilmesine olanak sağlar.
- **Görüntü iyileştirme sürecini not üretimiyle birleştirmesi:** Gölge, parlama, bulanıklık ve düşük kontrast gibi problemler azaltılarak görüntü hem kullanıcı için daha okunabilir hale getirilmektedir.
- **Not editörü ile düzenlenebilir çıktı sunması:** Kullanıcı yalnızca taranmış bir görüntü elde etmekle kalmaz; oluşturulan notu düzenleyebilir, saklayabilir ve daha sonra tekrar kullanabilir.
- **Ders bazlı not yönetimi sunması:** Oluşturulan notların derslere göre sınıflandırılabilmesi, öğrencilerin notlarını daha düzenli şekilde arşivlemesine katkı sağlar.
- **Mobil kullanım odaklı tasarlanması:** Uygulama, öğrencilerin ders sırasında hızlı şekilde fotoğraf çekip daha sonra not oluşturabilmesi için pratik ve kullanıcı dostu bir mobil deneyim sunmaktadır.

2. GEREKSİNİM ANALİZİ

Board2Note, sınıf veya amfi ortamında çekilen tahta görüntülerini işleyerek dijital nota dönüştürmeyi amaçlayan mobil bir uygulama olduğu için hem görüntü işleme hem de kullanıcı deneyimi açısından belirli gereksinimlere sahiptir. Uygulamanın kamera erişimi, galeri kullanımı, görüntü önizleme, tahta alanı seçimi, model destekli metin çıkarımı, not düzenleme ve notların saklanması gibi özellikleri desteklemesi gerekmektedir. Bu nedenle gereksinim analizi, projenin doğru bir mimariyle geliştirilmesi ve kullanıcı ihtiyaçlarına uygun bir çözüm sunması açısından önemli bir aşamadır.

Bu bölümde Board2Note projesinin platform ve işletim sistemi gereksinimleri, geliştirme sürecinde karşılaşılan sınırlılıklar, projenin çözüm sunduğu temel sorunlar, mevcut benzer uygulamalara göre üstün yönleri, hedef kitlesi ve kullanılan teknolojiler detaylı olarak açıklanacaktır.

2.1 Platform ve İşletim Sistemi Gereksinimleri

Board2Note, kullanıcıların mobil cihazları üzerinden tahta görüntülerini dijital nota dönüştürebilmesi amacıyla geliştirilen **Android/IOS tabanlı bir mobil uygulamadır**. Bu nedenle uygulamanın **temel platform gereksinimi, kamera ve galeri erişimine sahip bir Android/IOS telefon veya tablet üzerinde çalışabilmesidir**. Kullanıcı, ders sırasında tahta fotoğrafı çekebilmekte veya daha önce çekilmiş bir görseli galeriden seçerek uygulama içerisindeki işlem akışını başlatabilmektedir.

Uygulamanın temel işlevleri arasında görsel seçimi, görsel önizleme, tahta alanı seçimi, perspektif düzeltme, görüntü işleme, model destekli metin çıkarımı, not düzenleme ve not kaydetme işlemleri yer almaktadır. Bu nedenle cihazın kamera, medya erişimi, dokunmatik ekran ve yerel depolama gibi temel mobil donanım ve işletim sistemi özelliklerini desteklemesi gerekmektedir.

Board2Note'un kullanıcı tarafındaki temel platform ve işletim sistemi gereksinimleri şunlardır:

- Android/IOS işletim sistemine sahip akıllı telefon veya tablet.
- Kamera erişim izni.
- Galeri / medya erişim izni.
- Tahta fotoğrafı çekebilmek için yeterli kamera çözünürlüğü.
- Görüntü işleme adımlarının yürütülebilmesi için yeterli işlemci ve bellek kapasitesi.

- Oluşturulan notların ve görsel çıktıların saklanabilmesi için yeterli depolama alanı.
- Notların kaydedilmesi ve okunması için gerekli dosya erişim izinleri.
- Uygulama arayüzünün rahat kullanılabilmesi için dokunmatik ekran desteği.
- Yapay zekâ destekli harici servislerin kullanıldığı durumlarda internet bağlantısı.

Board2Note'un Android/IOS platformunda geliştirilmesi, uygulamanın öğrenciler tarafından ders sırasında veya sonrasında pratik şekilde kullanılabilmesini sağlamaktadır. Kullanıcı herhangi bir ek donanıma ihtiyaç duymadan yalnızca mobil cihazı üzerinden tahta görüntüsünü alabilmekte, bu görüntü üzerinde gerekli düzenlemeleri yapabilmekte ve elde edilen içeriği dijital not haline getirebilmektedir. Bu yönüyle proje, masaüstü kullanımından ziyade hızlı, taşınabilir ve öğrenci odaklı bir mobil kullanım senaryosuna göre tasarlanmıştır.

2.2 Geliştirme Sürecindeki Kaynak Kısıtları ve Çözüm Önerileri

Board2Note projesi; mobil uygulama geliştirme, görüntü işleme, yapay zekâ destekli model eğitimi ve yerel not yönetimi gibi farklı bileşenlerden oluşmaktadır. Bu nedenle geliştirme sürecinde hem donanımsal hem de yazılımsal bazı kaynak kısıtları dikkate alınmıştır. Özellikle model eğitimi, veri seti hazırlama, mobil cihaz performansı ve OCR doğruluğu projenin temel sınırlılık alanlarını oluşturmuştur.

Geliştirme sürecinde karşılaşılan başlıca kaynak kısıtları şunlardır:

- Yapay zekâ modellerinin eğitimi için yüksek işlem gücüne sahip GPU destekli ortamlara ihtiyaç duyulması.
- Farklı ışık, açı, gölge, parlama ve tahta türlerini içeren yeterli sayıda veri toplamanın zor olması.
- Gerçek sınıf ve amfi ortamlarında çekilen görüntülerin kalite açısından değişkenlik göstermesi.
- Mobil cihazlarda görüntü işleme adımlarının performanslı çalıştırılması gerekliliği.
- Düşük kaliteli, bulanık veya düşük kontrastlı tahta görüntülerinde model başarısının azalması.
- Farklı Android/IOS cihazlarda kamera kalitesi, ekran boyutu, işlemci gücü ve bellek kapasitesinin değişken olması.
- Geliştirme süresinin sınırlı olması nedeniyle tüm özelliklerin aynı anda ileri düzeyde geliştirilememesi.

- Model çıktılarının mobil uygulamaya aktarılabilmesi için boyut, hız ve çalışma zamanı uyumluluğu gerektirmesi.

Bu kısıtları azaltmak için model geliştirme tarafında hazır veri setleriyle birlikte **proje kapsamında toplanan özel tahta görüntülerinden yararlanılmıştır**. TTM için tahta alanı tespitine yönelik veri setleri kullanılmış, **YGM için ise sentetik eşleşmeli veri seti** hazırlanmıştır. Sentetik veri üretiminde **boş tahta görüntüleri üzerine el yazısı içerikleri bindirilmiş**; gölge, parlama, bulanıklık, düşük kontrast, gürültü ve JPEG bozulmaları gibi etkiler eklenmiştir. Böylece modelin gerçek sınıf ortamlarında karşılaşılabileceği farklı görüntü problemlerine karşı daha dayanıklı hale gelmesi amaçlanmıştır.

Donanımsal kısıtlar nedeniyle model eğitimleri GPU destekli ortamlarda yürütülmüştür. Eğitim sürecinde farklı model sürümleri denenmiş, başarı ve uygulanabilirlik açısından en uygun modeller seçilmiştir.

Mobil uygulama tarafında performans kısıtlarını azaltmak için işlem akışı aşamalı olarak tasarlanmıştır.

Öncesinde tahta alanı belirlenmiş, perspektif düzeltme uygulanmış ve YGM ile yazıların daha belirgin hale getirilmesi hedeflenmiştir. Bu sayede gölge, parlama, bulanıklık ve düşük kontrast gibi faktörlerin model üzerindeki olumsuz etkisi azaltılmaya çalışılmıştır.

Farklı Android/IOS cihazlardaki ekran ve performans farklılıkları için arayüz tasarımında sade, esnek ve mobil kullanıma uygun bir yapı tercih edilmiştir. Jetpack Compose ve Material 3 bileşenleri kullanılarak ekranların farklı cihaz boyutlarında daha tutarlı çalışması hedeflenmiştir. Ayrıca kullanıcı deneyimini korumak için görsel önlizeme, snackbar bildirimleri ve onay diyalogları gibi arayüz bileşenleri eklenmiştir.

Harici servis ihtiyacının oluşturabileceği sınırlılıklar da dikkate alınmıştır. Not düzenleme işlemlerinde internet bağlantısı gerekebileceği için uygulama, temel not saklama ve not yönetimi işlevlerini cihaz üzerinde çalışacak şekilde tasarlanmıştır. Bu sayede gizlilik ön planda tutulmuştur. Notlar dosya tabanlı yerel depolama yapısıyla saklanmış; böylece kullanıcı daha önce oluşturduğu notlara tekrar erişebilmiştir.

Sonuç olarak Board2Note projesinde karşılaşılan kaynak kısıtları; veri artırma, sentetik veri üretimi, GPU destekli eğitim, model karşılaştırmaları, aşamalı mobil işlem akışı, görüntü iyileştirme adımları ve esnek arayüz tasarımı ile azaltılmaya çalışılmıştır. Bu yaklaşım

sayesinde proje, mevcut teknik sınırlılıklara rağmen uygulanabilir, test edilebilir ve geliştirilebilir bir yapıda tamamlanmıştır.

2.3 Projenin Çözüm Ürettiği Sorunlar

Board2Note projesi, öğrencilerin ders sırasında tahta üzerindeki bilgileri kaydetme, düzenleme ve daha sonra tekrar kullanma sürecinde karşılaştıkları temel sorunlara çözüm üretmeyi amaçlamaktadır.

Projenin çözüm üretmeyi hedeflediği başlıca sorunlar şunlardır:

- Ders sırasında tahtadaki bilgileri hızlı şekilde not alamama.
- Tahta fotoğraflarında gölge, parlama ve düşük ışık nedeniyle okunabilirliğin azalması.
- Açılı çekilen fotoğraflarda perspektif bozukluğu oluşması.
- Uzak mesafeden çekilen görüntülerde yazıların netliğini kaybetmesi.
- Tahta fotoğraflarının düzensiz ve arşivlenmesi zor halde kalması.
- Öğrencilerin çekilen fotoğrafları sonradan manuel olarak düzenlemek zorunda kalması.
- Tahta üzerindeki yazıların dijital nota dönüştürülememesi.
- Ders notlarının farklı klasörlerde veya galeride dağınık şekilde saklanması.
- Notların derslere göre düzenli biçimde sınıflandırılamaması.
- Mevcut belge tarama uygulamalarının tahta görüntülerine ve ders notu üretimine özel bir akış sunmaması.

2.4 Mevcut Örneklerine Göre Üstünlükleri

Board2Note'un mevcut örneklerine göre başlıca üstünlükleri şunlardır:

- **Tahta görüntülerine özel geliştirilmiş olması:** Proje, genel belge tarama yerine doğrudan ders ortamında çekilen tahta görüntülerine odaklanmaktadır.
- **Ders notu oluşturma odaklı akış sunması:** Kullanıcı yalnızca görüntü taramakla kalmaz; görüntüyü işleyerek düzenlenebilir bir ders notuna dönüştürebilir.
- **Tahta alanı seçimi ve perspektif düzeltme sağlaması:** Açılı çekilen tahta fotoğraflarında kullanıcı tahta alanını belirleyebilir ve görüntünün daha düzgün hale getirilmesini sağlayabilir.
- **Görüntü kalitesini artırmaya yönelik işlem adımları içermesi:** Gölge, parlama, bulanıklık ve düşük kontrast gibi sorunların azaltılması hedeflenerek görüntünün okunabilirliği artırılır.

- **Not editörü ile düzenlenebilir çıktı sağlaması:** Kullanıcı oluşturulan notu uygulama içinde düzenleyebilir, kaydedebilir ve daha sonra tekrar kullanabilir.
- **Ders bazlı not yönetimi sağlaması:** Notların derslere göre ayrılması, öğrencilerin notlarını daha düzenli biçimde saklamasına yardımcı olur.
- **Öğrenci kullanım senaryosuna uygun olması:** Uygulama; ders sırasında hızlı fotoğraf çekme, sonradan düzenleme ve notları arşivleme gibi öğrenci ihtiyaçlarına göre tasarlanmıştır.
- **Mobil ve pratik kullanım sunması:** Ek donanımına ihtiyaç duymadan yalnızca mobil cihaz üzerinden kullanılabilir.

Bu yönleriyle Board2Note, yalnızca bir belge tarama uygulaması değil, tahta fotoğraflarını işleyerek ders notuna dönüştüren daha özelleştirilmiş bir çözüm sunmaktadır. Projenin en önemli üstünlüğü, **görüntü alma aşamasından not düzenleme ve saklama aşamasına kadar olan süreci tek bir mobil uygulama içerisinde bütünleşik şekilde sağlamasıdır.**

2.5 Hedef Kitle

Board2Note projesinin temel hedef kitlesi, eğitim ortamlarında tahta üzerinden aktarılan bilgileri dijital olarak kaydetmek ve daha sonra düzenli şekilde kullanmak isteyen öğrencilerdir. Özellikle sınıf, amfi, laboratuvar veya etüt ortamlarında ders takip eden öğrenciler, tahta üzerindeki bilgileri hızlıca kaydetme ihtiyacı duymaktadır. Bu nedenle proje, ders sırasında not alma sürecini kolaylaştırmak ve tahta fotoğraflarını daha kullanışlı dijital notlara dönüştürmek isteyen kullanıcılar için tasarlanmıştır.

Projenin hedef kitlesi şu şekilde sıralanabilir:

- Üniversite öğrencileri
- Lise öğrencileri
- Dershane ve kurs öğrencileri
- Yoğun ders anlatımı yapılan sınıf veya amfi ortamlarında eğitim alan öğrenciler
- Tahta fotoğraflarını düzenli ders notlarına dönüştürmek isteyen kullanıcılar
- Ders notlarını dijital ortamda saklamak ve derslere göre sınıflandırmak isteyen öğrenciler
- Tahta görüntülerindeki yazıları metne dönüştürerek daha sonra düzenlemek isteyen kullanıcılar
- Öğretmenler, akademisyenler ve eğitim içeriklerini dijitalleştirmek isteyen öğretmenler

2.6 Kullanılan Teknolojiler

Model Eğitimi ve Yapay Zeka

- **Python:** Projenin yapay zekâ, görüntü işleme ve veri hazırlama süreçlerinde ana geliştirme dili olarak kullanılmıştır. Geniş kütüphane desteği sayesinde model eğitimi, veri işleme ve deneysel çalışmalar için uygun bir ortam sunmaktadır.
- **PyTorch:** Görüntü iyileştirme ve derin öğrenme tabanlı model geliştirme süreçlerinde kullanılmıştır. Tahta görüntülerinin gölge, parlama, bulanıklık ve düşük kontrast gibi problemlerden arındırılması için geliştirilecek modellerin eğitilmesinde temel derin öğrenme çatısı olarak tercih edilmiştir.
- **Torchvision:** Görüntü verileri üzerinde dönüşüm işlemleri, veri artırma adımları ve model geliştirme süreçlerinde yardımcı kütüphane olarak kullanılmıştır. Eğitim verilerinin modele uygun hale getirilmesinde önemli bir rol oynamıştır.
- **Albumentations:** Tahta görüntüleri üzerinde veri artırma işlemleri yapmak için kullanılmıştır. Farklı ışık koşulları, gölge, parlama, bulanıklık, perspektif bozulması ve kontrast değişimleri gibi durumların yapay olarak oluşturulmasıyla modelin daha dayanıklı hale getirilmesi amaçlanmıştır.

Görüntü İşleme ve Veri Ön İşleme

- **OpenCV:** Tahta görüntülerinin işlenmesi, perspektif düzeltme, kırpma, köşe noktalarının işlenmesi, kontrast ayarlama ve temel görüntü düzenleme işlemlerinde kullanılmıştır. Projenin klasik görüntü işleme adımlarında temel kütüphanelerden biridir.
- **NumPy:** Görüntü matrisleri, koordinat hesaplamaları, maske işlemleri ve sayısal veri işlemleri için kullanılmıştır. Özellikle tahta alanı seçimi ve görüntü üzerinde piksel tabanlı işlemlerde destekleyici rol oynamıştır.
- **Pillow:** Görüntü dosyalarının açılması, dönüştürülmesi, yeniden boyutlandırılması ve farklı formatlarda işlenmesi amacıyla kullanılmıştır. Veri hazırlama ve ön işleme sürecinde yardımcı bir kütüphane olarak yer almıştır.
- **Matplotlib:** Eğitim sonuçlarının, örnek görüntü çıktılarının, kayıp grafiklerinin ve karşılaştırmalı analizlerin görselleştirilmesi için kullanılmıştır.

Mobil Uygulama Geliştirme

- **Kotlin:** Board2Note mobil uygulamasının geliştirilmesinde ana programlama dili olarak kullanılmıştır. Android/IOS platformu için modern, güvenli ve performanslı bir geliştirme ortamı sunmaktadır.
- **Android Studio:** Mobil uygulamanın geliştirilmesi, arayüz tasarımı, hata ayıklama ve test süreçlerinde kullanılan temel geliştirme ortamıdır.
- **Jetpack Compose:** Uygulamanın modern, dinamik ve kullanıcı dostu arayüzlerinin geliştirilmesi için kullanılmıştır. Ana sayfa, görsel önizleme, tahta alanı seçimi, not editörü, notların ve ayarlar ekranları gibi arayüzlerin oluşturulmasında kullanılmıştır.
- **Material 3:** Uygulamanın modern, profesyonel ve tutarlı bir tasarım diline sahip olması için kullanılmıştır. Butonlar, kartlar, alt navigasyon çubuğu, snackbar, dialog ve diğer arayüz bileşenleri Material 3 prensiplerine uygun şekilde tasarlanmıştır.

Veri Saklama ve Not Yönetimi

- **Dosya Tabanlı Yerel Depolama ve JSON:** Görüntü çıktıları, oluşturulan not dosyaları veya dışa aktarılan belgelerin cihaz üzerinde saklanması amacıyla kullanılmıştır. Kullanıcıların oluşturduğu notları daha sonra tekrar erişilebilir hale getirmek için kullanılmıştır.


Sürüm Kontrolü ve Proje Yönetimi

- **Git / GitHub:** Proje kodlarının düzenli şekilde saklanması, sürüm kontrolünün yapılması ve ekip içi geliştirme sürecinin yönetilmesi için kullanılmıştır. Kod değişikliklerinin takip edilmesi ve gerektiğinde önceki sürümlere dönülebilmesi açısından önemli bir araçtır.
- **Google Drive:** Veri setlerinin, model dosyalarının, eğitim çıktılarının, rapor dosyalarının ve proje dokümanlarının saklanması için kullanılmıştır. Özellikle ekip içi dosya paylaşımı ve yedekleme amacıyla kullanılmıştır.

3. TASARIM

3.1 Sistem Mimarisi

Board2Note projesi, Android/IOS tabanlı mobil bir uygulama olarak **katmanlı mimari** yaklaşımı temel alınarak geliştirilmiştir. Katmanlı mimari yapısının tercih edilmesindeki temel amaç; kullanıcı arayüzü, iş akışı yönetimi, görüntü işleme, yapay zekâ işlemleri ve veri saklama sorumluluklarını birbirinden ayırarak sistemin daha anlaşılır, sürdürülebilir ve geliştirilebilir hale getirilmesidir. Bu yapı sayesinde uygulamanın herhangi bir bölümünde yapılacak değişikliklerin tüm sistemi etkilemesi engellenmiş ve proje daha modüler bir yapıya kavuşturulmuştur.



Şekil 3.1. Board2Note Sistem Mimarisi

Board2Note sistem mimarisi temel olarak beş ana katmandan oluşmaktadır:

- Sunum Katmanı
- İş Katmanı
- Görüntü İşleme Katmanı
- Yapay Zekâ Katmanı
- Veri Katmanı

Bu katmanlar, kullanıcının tahta fotoğrafı çekmesi veya galeriden görsel seçmesiyle başlayan sürecin, düzenlenebilir ve saklanabilir bir dijital nota dönüşmesine kadar birlikte çalışmaktadır.

3.1.1 Sunum Katmanı

Sunum katmanı, kullanıcının uygulama ile doğrudan etkileşime geçtiği arayüz katmanıdır. Board2Note projesinde bu katman **Kotlin diliyle ve Jetpack Compose** kullanılarak geliştirilmiştir. Jetpack Compose'un tercih edilmesinin temel nedeni, modern **Android/IOS** uygulamalarında dinamik, hızlı ve esnek arayüzler oluşturmayı kolaylaştırmasıdır. Uygulamanın tüm ekranları Compose bileşenleri kullanılarak oluşturulmuş ve **Material 3** prensiplerine uygun şekilde tasarlanmıştır.

Sunum katmanının temel görevi, kullanıcıya sade, anlaşılır ve yönlendirici bir arayüz sunmaktır. Kullanıcı, uygulama içerisindeki bütün işlemlerini bu katman üzerinden gerçekleştirmektedir.

Sunum katmanında yalnızca görsel bileşenler değil, kullanıcıdan alınan etkileşimlerin ilgili katmanlara aktarılması da sağlanmaktadır. Böylece sunum katmanı, kullanıcı ile sistemin geri kalan bölümleri arasında bir bağlantı noktası görevi görmektedir.

3.1.2 İş Katmanı

İş katmanı, uygulamanın temel işlem akışını yöneten ve farklı katmanlar arasındaki iletişimi sağlayan bölümdür. Bu katman, kullanıcının uygulama içerisinde gerçekleştirdiği işlemlerin hangi sırayla yapılacağını belirlemektedir. Board2Note uygulamasında tahta görüntüsünden dijital not oluşturma süreci birden fazla adımdan oluştuğu için iş katmanı sistemin merkezi yönetim bileşeni olarak görev yapmaktadır.

Bu katmanda uygulamanın ekran geçişleri, işlem sıralaması, kullanıcıdan gelen komutların değerlendirilmesi, hata durumlarının yönetilmesi ve ilgili verilerin diğer katmanlara aktarılması sağlanmaktadır. Kullanıcı bir fotoğraf çektiğinde veya galeriden görsel seçtiğinde, bu görselin önce önizleme ekranına gönderilmesi, ardından tahta alanı seçimi ekranına aktarılması ve sonraki aşamada görüntü işleme katmanına iletilmesi iş katmanının sorumluluğundadır.

İş katmanında temel olarak şu görevler yürütülmektedir:

- Kullanıcı işlemlerinin yönetilmesi
- Ekranlar arası geçişlerin kontrol edilmesi
- Görsel seçimi ve onay sürecinin yönetilmesi
- Tahta alanı seçimi sonucunda oluşan koordinatların işlenmesi
- Görüntü işleme katmanına gerekli verilerin aktarılması

- Model desteğiyle elde edilen notun not editörüne iletilmesi
- Not kaydetme, listeleme ve silme işlemlerinin veri katmanı ile ilişkilendirilmesi
- Kullanıcıya gösterilecek hata ve bilgilendirme mesajlarının yönetilmesi

Bu katmanın önemli görevlerinden biri de uygulamanın kullanıcı akışını tutarlı hale getirmektir. Kullanıcı işlem adımlarında ileri veya geri gittiğinde, sistemin hangi veriyi saklayacağı ve hangi ekranı göstereceği iş katmanı tarafından kontrol edilmektedir.

Board2Note projesinde iş katmanı, sunum katmanı ile görüntü işleme ve veri katmanı arasında köprü görevi üstlenmiştir. Bu sayede arayüz bileşenleri doğrudan veri saklama veya görüntü işleme işlemlerine bağımlı hale getirilmemiştir. Bu yaklaşım, yazılımın daha düzenli ve bakımı kolay bir yapıda geliştirilmesine katkı sağlamıştır.

3.1.3 Görüntü İşleme Katmanı

Görüntü işleme katmanı, Board2Note projesinin temel teknik bileşenlerinden biridir. Bu katmanın amacı, kullanıcı tarafından çekilen veya galeriden seçilen tahta görüntüsünü daha düzgün, okunabilir ve kullanıcı kullanımına uygun hale getirmektir. Eğitim ortamlarında çekilen tahta fotoğrafları çoğu zaman ideal koşullarda elde edilmemektedir. Fotoğraflarda açı bozukluğu, perspektif kayması, gölge, parlama, düşük kontrast, bulanıklık ve gereksiz arka plan bölgeleri bulunabilmektedir. Bu nedenle ham görüntünün doğrudan modele verilmesi çoğu zaman düşük doğruluk oranlarına neden olabilmektedir.

Bu katmanda **temel görüntü işleme işlemleri için OpenCV** kullanılmıştır. OpenCV, görüntü üzerinde **kırpma, perspektif düzeltme, koordinat işleme ve temel görüntü düzenleme** işlemlerinde kullanılmıştır. Görüntü verilerinin matris yapısında işlenmesi ve **koordinat hesaplamalarının yapılması için NumPy kütüphanesinden** yararlanılmıştır. Görüntülerin **farklı formatlarda açılması, dönüştürülmesi ve ön işleme sürecine hazırlanması için ise Pillow destekleyici kütüphane** olarak kullanılmıştır.

Görüntü işleme katmanında ilk olarak tahta alanının belirlenmesi hedeflenmiştir. Kullanıcı, **BoardCropScreen** ekranı üzerinden **tahtanın köşe noktalarını seçebilmekte veya mevcut köşe noktalarını düzenleyebilmektedir**. Bu işlem, fotoğrafın tamamı yerine yalnızca tahta bölgesinin işlenmesini sağlamaktadır. Sınıf ortamında çekilen görüntülerde tahtanın dışında duvar, masa, öğrenci veya farklı nesneler yer alabildiği için tahta alanının izole edilmesi önemli bir adımdır.

Tahta alanı belirlendikten sonra perspektif düzeltme işlemi uygulanmaktadır. Açılı çekilmiş tahta görüntülerinde yazılar eğik görünebilmekte ve tahta dikdörtgen formunu kaybedebilmektedir. Bu işlem, hem görsel okunabilirliği artırmaktadır.

Bu katmanda ayrıca görüntünün okunabilirliğini artırmaya yönelik işlemler de uygulanmaktadır. Kontrast iyileştirme, parlaklık düzenleme, gölge etkisinin azaltılması, parlamanın düşürülmesi ve yazıların daha belirgin hale getirilmesi bu kapsamda ele alınmıştır. Böylece tahta üzerindeki yazıların arka plandan daha net ayrılması amaçlanmıştır.

Görüntü işleme katmanı, sistemde yapay zeka katmanından önce gelen kritik bir hazırlık aşamasıdır. Bu katmanda yapılan düzeltmeler, sonraki aşamada çıktının kalitesini doğrudan etkilemektedir. Bu nedenle Board2Note projesinde görüntü işleme yalnızca görsel bir iyileştirme adımı olarak değil, aynı zamanda metin çıkarımı başarısını artıran temel bir ön işlem basamağı olarak değerlendirilmiştir.

3.1.4 Yapay Zeka Katmanı

Yapay zekâ katmanı, işlenmiş tahta görüntüsünden dijital notun elde edilmesini ve bu metnin daha düzenli bir ders notu formatına dönüştürülmesini sağlayan katmandır. Board2Note projesinin temel hedefi, tahta fotoğraflarını yalnızca görsel olarak saklamak değil, bu görüntülerden düzenlenebilir ve anlamlı notlar oluşturmaktır. Bu nedenle yapay zekâ destekli metin düzenleme süreçleri sistem mimarisinde önemli bir yere sahiptir.

Model işlemi, **tahta görüntüsü üzerinde yer alan yazıların tanınarak dijital nota dönüştürülmesini** sağlamaktadır. Görüntü işleme katmanında perspektifi düzeltilen ve okunabilirliği artırılan tahta görüntüsü model işlemine aktarılmaktadır. **Model sonucunda elde edilen çıktı, ham not formatındadır.** Bu ham not üzerinde kullanıcı düzenleme yapabilmekte ve notu not editörü ekranında kaydedebilmektedir.

Bu katmanda model çıktısının daha anlamlı ve düzenli hale getirilmesi için yapay zekâ destekli metin düzenleme yaklaşımı kullanılmıştır.

Eğitim verileri üzerinde dönüşüm ve veri artırma işlemlerinde **Torchvision ve Albumentations kütüphanelerinden** yararlanılmıştır. Albumentations özellikle gölge, parlama, bulanıklık, perspektif bozulması ve kontrast değişimi gibi durumların veri setinde çeşitlendirilmesi amacıyla kullanılmıştır.

Bu katmanın sistemdeki önemi, görüntüden anlamlı bilgi çıkarma görevini üstlenmesinden kaynaklanmaktadır. Görüntü işleme katmanı yalnızca görüntüyü daha kaliteli

hale getirirken, yapay zekâ katmanı bu görüntüdeki yazılı bilgileri dijital nota dönüştürmektedir. Böylece kullanıcı, tahta fotoğrafını yalnızca görsel olarak saklamak yerine düzenlenebilir bir not çıktısı elde etmektedir.

3.1.5 Veri Katmanı

Veri katmanı, Board2Note uygulamasında **oluşturulan notların saklanması, listelenmesi, derslere göre gruplandırılması, arşivlenmesi ve gerektiğinde silinmesi** işlemlerinden sorumludur. Kullanıcının oluşturduğu notların daha sonra tekrar erişilebilir olması için bu katman uygulamanın not yönetimi altyapısını oluşturmaktadır.

Board2Note projesinde **dosya tabanlı yerel depolama yapısı** tercih edilmiştir. Notlara ait temel bilgiler uygulamanın yerel dosya alanında JSON formatında saklanmakta, notlarla ilişkili görsel çıktılar ise her not için oluşturulan ayrı klasörlerde tutulmaktadır.


Not verileri **`SavedNote`** modeliyle temsil edilmekte; not oluşturma, listeleme, güncelleme, arşivleme ve silme işlemleri **`NoteRepository`** ve **`FileNoteRepository`** yapıları üzerinden yönetilmektedir. Böylece arayüz katmanı doğrudan dosya sistemiyle çalışmamakta, veri işlemleri kontrollü bir katman üzerinden yürütülmektedir.

Notların ekranında notlar, her notun sahip olduğu ders adı bilgisine göre gruplandırılmaktadır. Bu yapı sayesinde kullanıcı, **oluşturduğu notları ders klasörleri görünümü altında düzenli şekilde görüntüleyebilmektedir**. Silme işlemlerinde ise kullanıcıdan onay alınarak yanlışlıkla veri kaybı yaşanması engellenmektedir.

Sonuç olarak veri katmanı, Board2Note uygulamasında oluşturulan dijital notların kalıcı, düzenli ve erişilebilir şekilde yönetilmesini sağlamaktadır. Veri modelinin ve dosya yapısının ayrıntıları **“3.3 Veri Tasarımı ve Not Yönetimi”** bölümünde açıklanmıştır.

3.1.6 Katmanlar Arası İletişim

Board2Note sisteminde katmanlar birbirinden bağımsız sorumluluklara sahip olacak şekilde tasarlanmıştır. Ancak uygulamanın **bütüncül olarak çalışabilmesi için bu katmanların belirli bir sırayla ve kontrollü şekilde iletişim kurması** gerekmektedir. Katmanlar arası iletişim, kullanıcıdan alınan bir tahta görüntüsünün işlenerek düzenlenebilir dijital nota dönüştürülmesi sürecini yönetmektedir.




Şekil 3.2. Katmanlar Arası İletişim Diyagramı

Bu yapı sayesinde Board2Note uygulamasında veri akışı düzenli ve kontrollü biçimde ilerlemektedir. Her katmanın belirli bir görevi olduğu için sistemin bakım ve geliştirme süreci kolaylaşmaktadır.

3.2 Veri Tasarımı ve Not Yönetimi


Board2Note projesinde not yönetimi, klasik ilişkisel veritabanı yapısından farklı olarak dosya tabanlı yerel veri saklama yaklaşımıyla tasarlanmıştır. **Projede not verileri, domain model, repository yapısı ve JSON dosyası üzerinden yönetilmektedir.** Bu tercih, uygulamanın daha basit, yerel odaklı ve dosya tabanlı bir not saklama sistemiyle çalışmasını sağlamıştır.



Şekil 3.3. Board2Note Dosya Tabanlı Veri Tasarımı

Projede not verisinin temel modeli **SavedNote** sınıfı ile temsil edilmektedir. Bu sınıf, uygulamada kalıcı olarak saklanan bir notun sahip olduğu temel bilgileri içermektedir. **Her not için benzersiz bir id, not başlığı, not içeriği, ders adı, oluşturulma tarihi, güncellenme tarihi, model sonucu, işlenmiş görsellere ait dosya yolları ve arşiv durumu** tutulmaktadır. Bu yapı teknik olarak Room Entity sınıfı değildir; ancak veri tasarımı açısından uygulamadaki not varlığının karşılığı olarak değerlendirilmektedir.

Not oluşturma süreci, görüntü işleme ve model işlemleri tamamlandıktan sonra başlamaktadır. Kullanıcı tarafından seçilen veya çekilen tahta görüntüsü işlendikten sonra model ile metin çıkarımı yapılmakta, elde edilen metin biçimlendirilerek not formatına dönüştürülmektedir. Daha sonra **oluşturulan not, repository katmanı aracılığıyla kalıcı depolama alanına** aktarılmaktadır. Bu süreçte yalnızca metinsel içerik değil; kırpılmış tahta görüntüsü, model için kullanılan görüntü ve beyaz sayfa çıktısı gibi görsel dosyalar da ilgili not ile ilişkilendirilmektedir.



Şekil 3.4. Not Oluşturma ve Saklama Akışı

Projede veri işlemlerinin soyutlanması amacıyla **NoteRepository** arayüzü kullanılmıştır. Bu arayüz; notları listeleme, arşivlenmiş notları görüntüleme, tekil not getirme, pipeline


sonucundan yeni not oluřturma, not ieriđini gncelleme, notu arřivleme, arřivden ıkarma ve silme gibi temel iřlemleri tanımlamaktadır. Bylece **uygulamanın ViewModel katmanı** dođrudan dosya sistemiyle alıřmamakta, veri iřlemleri repository yapısı zerinden ynetilmektedir. Bu yaklařım, DAO benzeri sorumluluđun repository tarafından stlenilmesini sađlamıřtır.

NoteRepository arayznn somut uygulaması **FileNoteRepository** sınıfı ile gerekleřtirilmiřtir. Bu sınıf, Android uygulamasının yerel dosya dizini altında notes adlı bir klasr oluřturmakta ve notların indeks bilgisini notes.json dosyasında saklamaktadır. Her not iin benzersiz id deđerine sahip ayrı bir klasr oluřturulmaktadır. Bu klasr ierisinde ilgili nota ait **crop.png, ocr.png ve white_page.png** gibi grsel ıktılar tutulmaktadır. Bu yapı ierisinde notes.json dosyası, veritabanı tablosuna benzer řekilde notların metinsel ve yapısal bilgilerini saklamakta; not id’siyle oluřturulan klasrler ise ilgili nota ait grsel dosyaların depolandıđı alanlar olarak grev yapmaktadır.

Veri btnlđn korumak amacıyla FileNoteRepository ierisinde eř zamanlı iřlemlere karřı Mutex yapısı kullanılmıřtır. Listeleme, oluřturma, gncelleme, silme ve arřivleme iřlemleri kilit mekanizması ierisinde yrtlmektedir. Bylece aynı anda birden fazla veri iřlemi yapılması durumunda dosya btnlđnn bozulması engellenmektedir. Ayrıca dosya okuma ve yazma iřlemleri Dispatchers.IO zerinde alıřtırılarak ana iř paracıđının bloklanmaması sađlanmıřtır. Bu durum, uygulamanın kullanıcı arayznn veri iřlemleri sırasında donmasını nlemeye yardımcı olmaktadır.

Notların listelenmesi sırasında arřivlenmemiř notlar **updatedAtEpochMs** alanına gre yeniden eskiye dođru sıralanmaktadır. Bylece kullanıcı, en son gncellenen notlara daha hızlı eriřebilmektedir. Arřivlenen notlar ise ayrı bir liste olarak tutulmakta ve normal not listesinden ayrılmaktadır. Arřivleme iřleminde not fiziksel olarak silinmemekte, yalnızca isArchived alanı gncellenmektedir. Silme iřleminde ise not hem notes.json indeksinden ıkarılmakta hem de ilgili nota ait grsel dosyaların bulunduđu klasr tamamen silinmektedir.

Ders klasrleri projede ayrı bir tablo veya fiziksel klasr olarak saklanmamaktadır. Bunun yerine **her notun sahip olduđu courseName alanı zerinden ders iliřkisi** kurulmaktadır. Kullanıcı bir not oluřtururken veya dzenlerken ilgili ders adını belirlemekte, bu bilgi notun courseName alanına kaydedilmektedir. Eđer ders adı boř bırakılırsa arayzde bu not “Genel” kategorisi altında gsterilmektedir.



Şekil 3.5. Ders Klasörlerinin Mantıksal Gruplama Yapısı


ViewModel katmanı, veri katmanı ile kullanıcı arayüzü arasında aracı rol üstlenmektedir. Kullanıcının not açma, düzenleme, kaydetme, silme, toplu silme, arşivleme ve arşivden çıkarma işlemleri ViewModel üzerinden yürütülmektedir.

ViewModel durum yönetimi birlikte çalışmaktadır. Bu yapı sayesinde uygulama, kullanıcı tarafından oluşturulan notları yerel olarak saklayabilmekte, **ders adına göre gruplandırabilmekte, arşivleyebilmekte ve gerektiğinde silebilmektedir.**

3.3 Projenin Çalışma Şekli

Board2Note projesinin çalışma şekli, kullanıcının tahta görüntüsünü uygulamaya aktarmasıyla başlayan ve bu görüntünün düzenlenebilir dijital nota dönüştürülmesiyle tamamlanan çok adımlı bir süreçten oluşmaktadır. Bu süreçte kullanıcı arayüzü, görüntü işleme, not düzenleme ve veri saklama bileşenleri birbiriyle bağlantılı olarak çalışmaktadır. Uygulama, **karmaşık teknik işlemleri kullanıcıya sade ve yönlendirici bir akış içerisinde sunarak tahta fotoğrafından not oluşturma sürecini kolaylaştırmaktadır.**

3.3.1 Genel Çalışma Akışı



Board2Note uygulamasında akış, tahta görüntüsünden dijital not oluşturma sürecini adım adım yönlendirecek şekilde tasarlanmıştır. Kullanıcı, uygulamayı açtıktan sonra ana sayfa üzerinden yeni bir tahta notu oluşturma işlemini başlatmaktadır. Bu aşamada kullanıcı kamera ile yeni bir fotoğraf çekebilmekte veya cihaz galerisinden daha önce çekilmiş bir tahta görüntüsünü seçebilmektedir.

Görsel seçimi tamamlandıktan sonra kullanıcı, seçilen görüntüyü önizleme ekranında kontrol etmektedir. Bu ekranda kullanıcı görselin doğru olup olmadığını değerlendirebilmekte ve gerekli durumda tekrar görsel seçimi yapabilmektedir. Görsel onaylandıktan sonra kullanıcı tahta alanı seçimi ekranına yönlendirilmekte ve burada hali hazırda belirlenmiş tahta sınırlarını değiştirebilmektedir. Tahta alanının seçilmesiyle birlikte sistem, görüntüyü kırpmaya ve perspektif düzeltme işlemleri için hazırlamaktadır.

Daha sonra görüntü iyileştirme aşamasına geçilmekte ve tahta görüntüsü model işlemine daha uygun hale getirilmektedir. Bu aşamadan sonra tahta üzerindeki yazılar dijital nota dönüştürülmekte ve elde edilen içerik not editörü ekranına aktarılmaktadır.

Şekil 3.6. Board2Note Kullanıcı Akışı Diyagramı

Kullanıcı, not editörü üzerinde metni düzenleyebilmekte ve oluşturulan notu kaydedebilmektedir. **Kaydedilen notlar, Notlarım ekranı üzerinden derslere göre görüntülenebilmekte ve daha sonra tekrar erişilebilir hale gelmektedir.**

Bu kullanıcı akışı sayesinde Board2Note, karmaşık görüntü işleme ve model süreçlerini kullanıcı açısından sade ve anlaşılır bir mobil deneyime dönüştürmektedir. Uygulama, **kullanıcıyı her adımda yönlendirerek** tahta fotoğrafından düzenlenebilir dijital nota ulaşmasını sağlamaktadır.

4. GELİŞTİRME

Bu bölüm, Board2Note projesinin geliştirme sürecini; mobil uygulama, görüntü işleme, veri hazırlama, model geliştirme ve not üretme bileşenleri üzerinden açıklamaktadır.

Geliştirme süreci iki ana eksen üzerinde yürütülmüştür. Birinci eksen, kullanıcının tahta görüntüsünü alıp düzenlenebilir nota dönüştürebildiği Android/IOS mobil uygulama akışıdır. İkinci eksen ise bu akışı destekleyen yapay zekâ ve görüntü işleme hattıdır. Bu hatta **TTM, tahta alanını belirlemek; YGM ise kırılmış tahta görüntüsünden yazıların tespit edilmesi**, belirginleştirilmesi ve maskelenmesi için geliştirilmiştir.

4.1 Geliştirme Sürecine Genel Bakış

Board2Note geliştirme süreci, ham tahta fotoğrafından düzenlenebilir dijital nota kadar uzanan uçtan uca bir işlem hattı olarak ele alınmıştır. Kullanıcı tarafında kamera veya galeri üzerinden görsel alınmış, görsel önizleme ekranında doğrulanmış, tahta alanı seçimiyle işlenecek bölge belirlenmiş, ardından perspektif düzeltme ve görüntü iyileştirme adımları uygulanmıştır. Son aşamada model çıktısı not editörüne aktarılmış ve oluşturulan not yerel dosya sistemi üzerinde saklanmıştır.

Yapay zekâ tarafında geliştirme, iki ayrı model ailesi üzerine kurulmuştur. **TTM: Tahta Tespit Modeli**, görüntü içerisindeki tahta alanını **segmentasyon maskesiyle** belirlemek için geliştirilmiştir. **YGM: Yazı Güçlendirme Modeli** ise tahta görüntüsünü temizlemek, modele ve kullanıcı kullanımına uygun çıktı üretmek ve yazı bölgelerini maske olarak ayırmak için tasarlanmıştır.

Model geliştirme süreci tek bir denemeye tamamlanmamıştır. **TTM tarafında TTM-V1 ve TTM-V2 sürümleri; YGM tarafında ise YGM-V1, YGM-V2 ve YGM-V3 sürümleri** oluşturulmuştur. Her sürüm, önceki sürümde görülen eksikliklere göre yeniden tasarlanmış ve **eğitim stratejisi buna göre güncellenmiştir**. Böylece final yapı yalnızca en yüksek tekil metrik değerine göre değil, **mobil uygulama akışına uygunluk, çıktı çeşitliliği, kullanıcı kullanımına ve proje amacına uygunluk kriterleri birlikte değerlendirilerek** seçilmiştir.

4.2 Veri Setleri ve Veri Ön İşleme Süreci

Veri hazırlama süreci, TTM ve YGM modellerinin farklı görevleri nedeniyle ayrı hatlar halinde yürütülmüştür. **TTM için tahta alanını arka plandan ayıran segmentasyon verileri** kullanılmıştır. **YGM için ise bozulmuş tahta görüntüsünü temiz görüntü ve yazı maskesi hedefleriyle eşleyen çok çıkışlı sentetik veri yapısı** hazırlanmıştır.

Veri hazırlama sürecinde, TTM ve YGM modellerinin farklı görevleri nedeniyle ayrı veri hatları kullanılmıştır. Bu kapsamda TTM tarafında yalnızca hazır veri setlerinden yararlanılmamış, projenin hedef kullanım senaryosuna daha yakın sonuçlar elde edebilmek için okul ortamında özel bir tahta veri seti de oluşturulmuştur. Bu özel veri seti, modelin gerçek derslik koşullarında karşılaşılabileceği farklı açı, uzaklık, ışık ve tahta kullanım durumlarına karşı daha dayanıklı hale gelmesini desteklemiştir.

4.2.1 Kendi Veri Setimizin Oluşturulması

Kendi veri setimizin oluşturulmasındaki temel amaç, tahta tespit modelinin yalnızca ideal ve düz çekilmiş örnekleri değil, gerçek eğitim ortamlarında karşılaşılan değişken görüntü koşullarını da öğrenebilmesini sağlamaktır. Bu nedenle veri toplama **sürecinde küçük, orta ve büyük ölçekli derslikler; amfi ortamları ve yüksek lisans derslikleri** dikkate alınmıştır.

Toplanan görüntülerde tahtanın kadraj içindeki konumu ve çekim mesafesi bilinçli olarak çeşitlendirilmiştir. Sağdan, soldan, önden, yakın mesafeden ve uzak mesafeden çekilen örnekler veri setine dahil edilmiştir. Ayrıca yalnızca boş tahtalar değil, üzerinde ders anlatımı sırasında yazılmış içerik bulunan dolu tahtalar da toplanmıştır. Böylece modelin hem sade arka planlı tahta görüntülerini hem de yazı yoğunluğu fazla olan gerçek ders görüntülerini görerek öğrenmesi hedeflenmiştir.

Ham görüntülerde tahta uzak mesafede yer almakta, bazı görüntülerde perspektif bozulması oluşmakta, bazı örneklerde ise ışık, gölge, yansıma ve yazı yoğunluğu gibi etkenler tahta sınırlarının algılanmasını zorlaştırmaktadır. **Bu çeşitlilik, veri setinin model eğitimi açısından daha gerçekçi ve dayanıklı bir kaynak haline gelmesini sağlamıştır.**



Şekil 4.1. Derslik ortamından toplanan işlenmemiş tahta görüntüsü örnekleri

Veri Setimizin İşlenmemiş Görüntüleri



Yüksek Lisans Dersliği





Şekil 4.2. Yüksek lisans dersliği ortamından toplanan işlenmemiş tahta görüntüsü örnekleri

Veri Setimizin İşlenmemiş Görüntüleri



Amfi





Şekil 4.3. Amfi ortamından toplanan işlenmemiş tahta görüntüsü örnekleri

Veri Setimizin İşlenmemiş Görüntüleri



Amfi



Şekil 4.4. Amfi ortamında farklı mesafe, açı ve yazı yoğunluğu içeren işlenmemiş tahta görüntüsü örnekleri

Etiketleme ve Model Eğitime Hazırlama

Elde edilen görüntüler, veri seti ön işleme ve etiketleme işlemleri için RoboFlow Annotate ortamına aktarılmıştır. Etiketleme süreci, tahta alanının WhiteBoard sınıfı olarak işaretlenmesine dayalı semantik segmentasyon yaklaşımıyla yürütülmüştür. Bu yaklaşımda modelin görevi, görüntü içindeki yazı, masa, duvar veya sınıf nesnelerini değil, doğrudan tahta bölgesini ayırt etmektir.

Etiketlenen görüntüler, projenin birinci model ailesi olan TTM/MobileNet tabanlı tahta tespit modelinin eğitimine uygun hale getirilmiştir. Bu sayede görüntü içerisindeki tahta alanı piksel düzeyinde temsil edilebilmiş ve modelin çıktı olarak tahta maskesi üretmesi hedeflenmiştir. Veri setinin semantik segmentasyon yapısında hazırlanması, tahta kırpma ve perspektif düzeltme adımlarının daha güvenilir şekilde uygulanabilmesi açısından önemli bir temel oluşturmuştur.

B2N_1 Veri Seti Özeti

Etiketleme ve düzenleme işlemleri sonucunda proje veri seti, RoboFlow üzerinde B2N_1 adı ile konumlandırılmıştır. B2N_1, WhiteBoard sınıfına sahip, Semantic Segmentation türünde ve orta ölçekli bir tahta veri seti olarak hazırlanmıştır. Veri seti, Board2Note projesinin TTM tarafında kendi verimize yakın model geliştirme sürecini destekleyen ana kaynaklardan biri olarak değerlendirilmiştir.

Özellik	Açıklama
Veri seti adı	B2N_1
Platform	RoboFlow
Görev türü	Semantic Segmentation
Etiket sınıfı	WhiteBoard
Toplam görüntü sayısı	493 görüntü
Çözünürlük	640 x 640
Kapsam	Derslik, yüksek lisans dersliği ve amfi ortamlarından toplanan boş ve dolu tahta görüntüleri
Kullanım amacı	TTM/MobileNet tabanlı tahta tespit modelinin eğitimi için tahta alanı maskesi üretmek

Tablo 4.1. B2N_1 Veri Setinin Özellikler

B2N_1 veri setinin proje içerisinde kullanılması, TTM'nin yalnızca dış kaynaklı veya ideal koşullardaki veri setlerine bağlı kalmasını engellemiştir. Bu veri seti sayesinde model, Board2Note uygulamasının hedeflediği gerçek kullanım ortamlarına daha yakın örneklerle desteklenmiştir. Özellikle farklı sınıf büyüklükleri, uzaklıklar, açılar ve yazılı/boş tahta örnekleri; modelin değişken sahne koşullarına karşı daha kararlı çalışmasına katkı sağlamıştır.

4.2.2 TTM İçin Kullanılan Veri Setleri

TTM'nin görevi, **görüntü içerisindeki tahta alanını** tespit etmektir. Bu nedenle TTM için kullanılan veriler, tahta alanının maske olarak işaretlendiği segmentasyon yapısında hazırlanmıştır. **TTM-V1 aşamasında** Roboflow kaynaklı iki COCO veri seti kullanılmıştır: new_dataset_xjgtk_v12_coco ve b2n_1_nktgm_v1_coco. COCO anotasyonları işlendikten sonra eğitim için **6259 train, 645 validation ve 500 test örneği** elde edilmiştir.

TTM-V2 aşamasında veri hattı daha dağıtıma uygun ve proje verisine yakın olacak şekilde yeniden düzenlenmiştir. Bu sürümde b2n_1_v2_own, whiteboard1_isweb_v3_public ve whiteboard_52kh3_v1_forked kaynakları birleştirilmiştir. **Trakya Üniversitesi Mühendislik Fakültesi ortamlarında toplanan özel tahta görüntüleri de veri kaynağı olarak kullanılmıştır.**

Özel veri seti; derslik, amfi ve yüksek lisans sınıflarında çekilmiş tahta görüntülerinden oluşmaktadır. Bu sayede TTM'nin yalnızca ideal koşullardaki tahta görüntülerini değil, gerçek eğitim ortamlarında karşılaşılabilecek farklı ışık, açı, mesafe ve arka plan koşullarını da öğrenmesi hedeflenmiştir. Temizleme ve bölme işlemleri sonucunda **2226 train, 278 validation ve 279 test örneğiyle** eğitim yürütülmüştür.

Model	Veri Kaynağı / Yapı	Örnek Dağılımı	Geliştirme Amacı
TTM-V1	new_dataset_xjgtk_v12_coco + b2n_1_nktgm_v1_coco; COCO segmentasyon	6259 train / 645 val / 500 test	Tahta segmentasyonu için ilk güçlü referans modeli oluşturmak
TTM-V2	b2n_1_v2_own + public whiteboard kaynakları; temizlenmiş ve daha kontrollü veri	2226 train / 278 val / 279 test	Kendi verimize daha yakın, paketlenabilir sürüm geliştirmek

Tablo 4.2. TTM Modellerinin Veri Kaynakları Hakkında

4.2.3 TTM Veri Ön İşleme Süreci

TTM veri hattında COCO anotasyonları okunarak **yalnızca tahta alanını temsil eden sınıflar ön plan** olarak kabul edilmiştir. Bu aşamada `handwritten\_text`, `text`, `writing`, `person`, `marker` gibi sınıflar özellikle dışarıda bırakılmıştır. Bunun temel amacı, TTM'nin yazı, kişi veya kalem gibi nesneleri değil, **yalnızca tahta bölgesini öğrenmesini** sağlamaktır.

COCO formatındaki segmentasyon anotasyonları maske formatına dönüştürülmüştür. Segmentasyon bilgisinin bulunmadığı durumlarda ise bounding box bilgisi dikdörtgen maske olarak kullanılmıştır. Hazırlanan maskeler ikili yapıdadır. Bu **yapıda tahta alanı `1`, arka plan ise `0` piksel değeriyle** temsil edilmektedir.

TTM için görüntüler eğitim öncesinde `640 x 640` boyutuna getirilmiştir. Bu işlem sırasında **letterbox** yöntemi kullanılmıştır. Letterbox yönteminde görüntünün orijinal en-boy oranı korunmuş, boş kalan alanlar RGB değeri `114` olan gri dolgu ile tamamlanmıştır. Maskeler de aynı geometrik dönüşümle yeniden boyutlandırılmıştır. Maske tarafında sınıf değerlerinin bozulmaması için **en yakın komşu interpolasyonu** kullanılmıştır.

TTM eğitimi sırasında uygulanan başlıca veri artırma işlemleri şunlardır:

- Yatay çevirme,
- Küçük ölçekleme ve kırpma,
- Parlaklık ve kontrast değişimi,
- Hafif bulanıklık,
- Gauss gürültüsü.

Görüntüler model girişine verilmeden önce ImageNet ortalama ve standart sapma değerleriyle normalize edilmiştir. Bu ön işleme hattı sayesinde TTM, MobileNetV3-Large + LR-ASPP segmentasyon yapısına uygun giriş formatıyla eğitilmiştir.

Veri setinde train, validation ve test ayrımı korunmuştur. Eksik olduğu durumlarda ise deterministik biçimde yaklaşık olarak `**%80 train**`, `**%10 validation**` ve `**%10 test**` ayrımı oluşturulmuştur. Böylece TTM'nin eğitim, doğrulama ve test aşamalarında düzenli bir veri bölünmesiyle değerlendirilmesi sağlanmıştır.

4.2.4 YGM İçin Kullanılan Sentetik Veri Seti

YGM tarafında veri seti yapısı model sürümlerine göre değişmiştir. **YGM-V1** aşamasında **tek çıkışlı restorasyon problemi ele alınmış** ve paired input/target yapısındaki

SD7K tabanlı veri kullanılmıştır. Bu veri hattında **5506 train**, **647 validation** ve **325 test** çiftiyle **NAFNet-Small** modeli eğitilmiştir.

YGM-V2 ve YGM-V3 aşamalarında ise çok başlı model yapısına uygun olarak `generated_multihead_dataset_v2.zip` adlı sentetik eşleşmeli veri seti kullanılmıştır. Bu veri setinde her örnek için `input`, `target_restored`, `target_ocr` ve `text_mask` klasörleri paralel tutulmuştur. **Train bölümünde 3920**, **validation bölümünde 144** ve **test bölümünde 156 örnek** bulunmaktadır.

YGM Sürümü	Veri Yapısı	Çıktı Hedefi	Rolü
YGM-V1	Paired input/target restorasyon verisi	Tek restored görüntü	Restorasyon tabanlı ilk yazı güçlendirme denemesi
YGM-V2	<code>generated_multihead_dataset_v2.zip</code>	Restored + model output + text mask	Ürün akışı için çok başlı model altyapısını kurma
YGM-V3	YGM-V2 ile aynı çok başlı veri yapısı	Restored + model output + text mask	Denetimli temel üzerine GAN destekli fine-tune

Tablo 4.3. YGM Modellerinin Veri Kaynakları Hakkında

4.2.5 YGM İçin Sentetik Veri Üretim Yaklaşımı

YGM-V2 ve YGM-V3 için kullanılan **sentetik veri üretiminde temel amaç**, **gerçek sınıf ortamlarında görülen bozulmaları kontrollü biçimde eğitim verisine yansıtmaktır**. Bu amaçla **boş tahta görüntüleri üzerine el yazısı içerikleri bindirilmiş**, **ardından farklı ışık ve kalite problemleri eklenerek bozulmuş giriş görüntüleri oluşturulmuştur**.

- Eklenen başlıca bozulmalar: gölge, parlama, blur, düşük kontrast, ışık dengesizliği, gürültü, renk kayması ve JPEG sıkıştırma bozulmalarıdır.
- Her bozulmuş input görüntüsü için temiz hedef, modele uygun hedef ve text mask hedefi birlikte hazırlanmıştır.
- Bu yapı, modelin yalnızca arka planı temizlemesini değil, yazı piksellerini korumasını ve yazı bölgelerini ayırmasını da desteklemiştir.

4.2.6 YGM Veri Yapısı ve Hedef Çıktılar

Çok başlı YGM veri seti **dört paralel klasörden** oluşmaktadır. **input klasörü** bozulmuş tahta görüntüsünü, **target_restored klasörü** insan gözüyle daha okunabilir temiz görüntüyü, **target_ocr klasörü** OCR motoru için daha kontrastlı ve okunabilir hedefi, **text_mask klasörü** ise yazı bölgelerini gösteren gri seviye maskeyi temsil etmektedir.

Bu yapı sayesinde **YGM, aynı giriş görüntüsünden üç farklı çıktı üretmeyi öğrenmiştir:**

- `restored`
- `ocr`
- `mask\_logits`

`restored` çıktısı `target\_restored` ile, `ocr` çıktısı `target\_ocr` ile, `mask\_logits` çıktısı ise `text\_mask` ile denetlenmiştir. Böylece YGM'nin hem görüntü restorasyonu hem modele hazırlık hem de yazı maskesi üretimi görevlerini birlikte öğrenmesi sağlanmıştır.

4.2.7 YGM Veri Ön İşleme Süreci

YGM eğitiminde görüntüler 512 x 512 boyutlu yamalar halinde işlenmiştir. Eğitim aşamasında rastgele kırpma ve yatay çevirme uygulanmış; validation ve test tarafında hizalamayı koruyacak daha **kontrollü kırpma yaklaşımı** kullanılmıştır. RGB görüntülerde **bicubic interpolasyon**, maske hedeflerinde ise **nearest-neighbor interpolasyon** tercih edilmiştir.

input, target_restored, target_ocr ve text_mask bileşenleri aynı geometrik dönüşümlerden geçirilmiştir. Bu nokta çok başlı eğitim için kritiktir; çünkü modelin aynı piksel konumunda hem temiz görüntüyü hem model hedefini hem de yazı maskesini öğrenmesi gerekmektedir. **RGB görüntüler 0-1 aralığına normalize edilmiş, text mask tek kanallı 0-1 değer aralığında** hazırlanmıştır.

4.2.8 Yazı Bölgelerine Ağırlık Verilmesi ve Maske Kullanımı

YGM eğitiminde model hedefi oluşturulurken yazı bölgelerine daha fazla önem verilmiştir. Text mask kullanılarak yazı piksellerindeki hatalar daha önemli hale getirilmiştir. Bu yaklaşım, modelin arka planı temizlerken yazı çizgilerini silmesini veya zayıflatmasını engellemek amacıyla kullanılmıştır.

Maske çıktısı için **BCE ve Dice loss** birlikte kullanılmıştır. BCE loss piksel düzeyinde sınıflandırma başarısını desteklerken, Dice loss maske alanının bütünsel olarak doğru

çıkarılmasına katkı sağlamaktadır. Bu yapı sayesinde YGM'nin yalnızca görüntüyü temizlemesi değil, **yazı bölgelerini konumsal olarak öğrenmesi** de sağlanmıştır.

4.2.9 Çalışma Zamanı Ön İşleme Süreci

Eğitim sürecinde kullanılan ön işleme adımlarının benzerleri çalışma zamanında da uygulanmıştır. TTM'ye verilen görüntüler `640 x 640` **letterbox** formatına dönüştürülmüştür. TTM'den **elde edilen çıktı maskesi sigmoid sonrası eşiklenmiş; ardından morfolojik açma/kapama, boşluk doldurma ve en büyük bağlı bileşen seçimi gibi işlemlerle temizlenmiştir.**

Daha sonra tahta dörtgeni çıkarılmış, perspektif düzeltme uygulanmış ve **YGM'ye aktarılacak tahta kırpmı** elde edilmiştir. YGM ise `512 x 512` tile yapısı ve `64` piksel örtüşme ile çalışmıştır. Bu sayede büyük görüntüler parçalara ayrılarak işlenmiş ve parça sınırlarında oluşabilecek keskin geçişlerin azaltılması hedeflenmiştir.

YGM çalışma zamanında `restored`, `ocr\_enhanced` ve `text\_mask` çıktıları üretmektedir. Text mask çıktısı sigmoid sonrası olasılık haritası olarak değerlendirilmiştir. Bu çıktı, model sonucuyla birlikte beyaz zemin üzerinde yazı katmanı oluşturmak için kullanılabilecek bir ara çıktı sağlamaktadır.


4.3 Mobil Uygulama Geliştirme Süreci

Board2Note projesinin mobil uygulama geliştirme süreci, Android platformu temel alınarak yürütülmüştür. Uygulama, **kullanıcıların tahta görüntülerini hızlı bir şekilde sisteme aktarabilmesi, görüntü üzerinde gerekli düzenlemeleri yapabilmesi, model sonucunda elde edilen metni düzenleyebilmesi ve oluşturulan notları daha sonra tekrar görüntüleyebilmesi** amacıyla geliştirilmiştir. Bu doğrultuda mobil uygulama, yalnızca bir arayüz katmanı olarak değil; kullanıcı etkileşimini yöneten, görüntü işleme sürecini başlatan ve not yönetimini sağlayan temel bileşenlerden biri olarak ele alınmıştır.


Uygulamanın geliştirilmesinde **Kotlin** programlama dili kullanılmıştır. Geliştirme ortamı olarak **Android Studio** tercih edilmiştir. Kullanıcı arayüzlerinin oluşturulmasında modern Android geliştirme yaklaşımına uygun olarak **Jetpack Compose** kullanılmıştır. Jetpack Compose sayesinde ekran bileşenleri daha esnek, okunabilir ve yeniden kullanılabilir şekilde tasarlanmıştır. Arayüz tasarımı ise **Material 3** prensipleri esas alınmış; butonlar, kart yapıları, alt navigasyon çubuğu, snackbar bildirimleri ve diğer kullanıcı arayüzü bileşenleri bu tasarım yaklaşımına uygun biçimde geliştirilmiştir.

4.3.1 Ekranlar

4.3.1.1 Ana Sayfa



Şekil 4.5. Ana Sayfanın Telefon Ekranındaki Görünümü




Şekil 4.6. Ana Sayfanın Tablet Ekrandaki Klasör İşlemlerin Görünümü




Şekil 4.7. Ana Sayfanın Tablet Ekranındaki Görünümü

Bu görseller, Board2Note uygulamasının ana sayfa yapısını göstermektedir. Ana sayfada kullanıcı, ders klasörlerini ve oluşturduğu not kartlarını görüntüleyebilmekte; arama, menü ve yeni not ekleme seçeneklerine hızlıca erişebilmektedir. Uygulama arayüzü hem telefon hem de tablet ekranlarında kullanılabilecek şekilde tasarlanmış, geniş ekranlarda not kartları ve ders klasörleri daha yatay ve ferah bir düzende sunulmuştur. Ayrıca not kartı üzerinde açılan işlem menüsü sayesinde kullanıcı notu açma, favoriyi ekleme, arşivleme, çoklu seçim yapma ve silme gibi temel yönetim işlemlerini doğrudan ana sayfa üzerinden gerçekleştirebilmektedir. Bu yapı, Board2Note'un yalnızca not oluşturma değil, oluşturulan notları düzenli şekilde saklama ve yönetme işlevini de desteklediğini göstermektedir.

4.3.1.2 Notlarım Ekranı



Şekil 4.8. Notlarım Ekranının Telefon Ekranındaki Görünümü



Şekil 4.9. Notlarım Ekranının Tablet Ekranındaki Görünümü

Bu görseller, Board2Note uygulamasında oluşturulan notların ve ders klasörlerinin listelendiği Notlarım ekranını göstermektedir. Kullanıcı bu ekranda toplam not sayısını, arşiv bilgisini, son oluşturulan notları ve derslere göre gruplanmış klasörleri görüntüleyebilmektedir.


Arama alanı sayesinde kullanıcı, not veya ders adına göre hızlı erişim sağlayabilmektedir. Telefon ve tablet görünümünde aynı işlevler korunmuş; tablet ekranında geniş alan daha verimli kullanılarak not kartları ve ders klasörleri yatay düzende daha fazla içerik gösterecek şekilde sunulmuştur. Bu ekran, uygulamanın not oluşturma sürecinden sonra kullanıcıya düzenli bir not yönetim alanı sağlar.

4.3.1.3 Tahtadan Not Ekleme Süreci Ekranları




Bu görseller, Board2Note uygulamasında canvas not editörü üzerinden tahta görüntüsü ekleme sürecini göstermektedir. Kullanıcı, not editörü ekranındaki “+” butonuna bastığında “Tahtadan ekle” ve “Görsel ekle” seçeneklerinin bulunduğu bir menü açılmaktadır. “Tahtadan ekle” seçeneği seçildiğinde kullanıcı, tahta veya slayt ekranı görüntüsünü ders notuna dönüştürmek için özel olarak tasarlanan ekrana yönlendirilmektedir. Bu ekranda kullanıcıya sürecin temel adımları kısa şekilde açıklanmakta; galeriden görsel seçme veya kamerayla fotoğraf çekme seçenekleri sunulmaktadır. Böylece tahta görüntüsünü not içerisine ekleme işlemi, kullanıcı açısından sade ve yönlendirici bir akışla başlatılmaktadır.

Şekil 4.10. Not Editörü Ekranından Tahtadan Not Ekleme Ekranına Geçiş



Şekil 4.11. Tahtadan Not Ekleme Ekranının Tablet Ekranındaki Görünümü

4.3.1.4 Canvas Not Editörü Ekranı




Şekil 4.12. Canvas Not Editörü Ekranının Tablet Ekranındaki Görünümü

Bu görsel, Board2Note uygulamasında oluşturulan notun canvas tabanlı not editörü üzerinde düzenlenebildiğini göstermektedir. Kullanıcı, tahta görüntüsünden elde edilen içeriği sayfa üzerinde görüntüleyebilmekte ve

gerektiğinde kalem aracıyla ek açıklamalar, çizimler veya işaretlemeler yapabilmektedir.

Ekranın sol tarafında yer alan araç çubuğu; çizim, renk seçimi, düzenleme, taşıma, geri alma ve silme gibi temel not düzenleme işlemlerini desteklemektedir. Bu yapı sayesinde uygulama yalnızca metin çıkarımı yapan bir sistem olmaktan çıkmakta, özellikle formül, şema ve el çizimi içeren ders içerikleri için kullanıcıya esnek bir görsel not düzenleme alanı sunmaktadır.



Şekil 4.13. Canvas Ekranındaki Yapay Zekâ Destekli Anlatım Paneli

Bu ekran, Board2Note uygulamasında canvas not editörü üzerinde yer alan yapay zekâ destekli anlatım panelini göstermektedir. Kullanıcı, tahta görüntüsünden elde edilen ders içeriğini

canvas üzerinde görüntülerken aynı zamanda sağ tarafta açılan panel üzerinden konuya ait açıklamaları inceleyebilmektedir. Bu yapı, kullanıcının yalnızca görsel notu saklamasını değil, not içeriğini daha anlaşılır hale getiren ek açıklamalara da ulaşmasını sağlamaktadır.

Yapay zekâ destekli anlatım paneli, özellikle formül, şema, işlem adımı veya karmaşık konu anlatımı içeren ders notlarında destekleyici bir bileşen olarak tasarlanmıştır. Panelde, görsel üzerindeki içerikle ilişkili açıklamalar adım adım sunulmakta ve kullanıcıya konunun nasıl çözümlendiği veya nasıl yorumlanması gerektiği gösterilmektedir. Böylece uygulama, yalnızca tahta görüntüsünü dijital ortama aktaran bir araç olmaktan çıkarak öğrenme sürecini destekleyen etkileşimli bir not ortamı sunmaktadır.

Canvas alanı ile yapay zekâ panelinin aynı ekranda bulunması, kullanıcı deneyimi açısından önemli bir avantaj sağlamaktadır. Kullanıcı bir yandan tahta görüntüsünü inceleyebilirken, diğer yandan yapay zekâ tarafından üretilen açıklamaları takip edebilmekte ve gerekli durumlarda not üzerinde düzenleme yapabilmektedir. Bu yapı, Board2Note'un görsel not, metin açıklaması ve kullanıcı düzenlemesini tek bir çalışma ekranında birleştirdiğini göstermektedir.

4.4 Görüntü İşleme Geliştirme Süreci

Görüntü işleme süreci, ham tahta fotoğrafını model aşamalarına uygun hale getirmek için geliştirilmiştir. Bu süreç yalnızca görsel kaliteyi artırmayı değil, model başarısını doğrudan etkileyen geometrik ve görsel bozulmaları azaltmayı hedeflemektedir.

Tahta Alanının Belirlenmesi

Tahta alanı belirleme aşamasında TTM maskesi, görüntüdeki tahta alanını arka plandan ayırarak sonraki kırpma ve perspektif düzeltme adımlarına temel oluşturmaktadır.

TTM çıktısı doğrudan kullanılmamış; eşikleme ve morfolojik temizlik adımlarından geçirilmiştir. Küçük gürültülü bölgeler elenmiş, en büyük bağlı bileşen korunmuş ve tahta bölgesinin daha kararlı biçimde çıkarılması sağlanmıştır. Bu tasarım, model tahminlerindeki küçük hataların tüm pipeline'ı bozmasını engellemek amacıyla uygulanmıştır.

Kırpma ve Perspektif Düzeltme

Tahta alanı belirlendikten sonra kırpma ve perspektif düzeltme işlemleri uygulanmıştır. Kırpma işlemi, görüntüdeki gereksiz duvar, masa, öğrenci veya arka plan bölgelerini sistem

dışı bırakmaktadır. Perspektif düzeltme ise açılı çekilen tahta görüntülerini daha düzgün bir dikdörtgen forma getirmektedir.

Bu aşamada **OpenCV tabanlı koordinat işleme ve perspektif dönüşüm** yöntemlerinden yararlanılmıştır. Kullanıcı tarafından seçilen veya TTM çıktısından elde edilen köşe noktaları kullanılarak tahta yüzeyi düzeltilmiştir.

Görüntünün Model İçin Hazırlanması

Perspektifi düzeltilen tahta görüntüsü, YGM aşamasında **yazı korunumu ve okunabilirliği** açısından iyileştirilmiştir. Bu aşamada hedef, görüntüyü yalnızca görsel olarak temizlemek değil; yazı çizgilerini koruyarak daha uygun bir ara çıktı üretmektir.

YGM'nin çok başlı yapısı bu noktada temel avantaj sağlamıştır. Restored output kullanıcıya daha temiz bir tahta görüntüsü sunarken, ocr_enhanced output model işlemine daha uygun bir görüntü üretmektedir. text_mask çıktısı ise yazı bölgelerini ayrı bir bilgi katmanı olarak ayırmakta ve ileride beyaz sayfa üzerine yazı aktarımı gibi görsel not senaryolarına temel oluşturmaktadır.

4.5 Model Geliştirme ve Karşılaştırma Süreci

Model geliştirme sürecinde amaç, ham tahta fotoğrafını doğrudan modele vermek yerine önce tahta alanını tespit eden, ardından bu alanı modele uygun hale getiren çok aşamalı bir yapı kurmaktır. Bu nedenle TTM ve YGM modelleri farklı görevler için ayrı ayrı geliştirilmiş, her model ailesinde birden fazla sürüm denenmiştir.

Model geliştirme süreci **iki temel problem** etrafında şekillenmiştir. **Birinci problem**, kullanıcının yüklediği görüntü içerisinde **tahta alanının doğru şekilde belirlenmesidir**. Sınıf ortamında çekilen fotoğraflarda görüntü çoğu zaman yalnızca tahtadan oluşmadığı için, duvar, sıra, öğrenci, perde veya farklı çevresel nesneler görüntüde yer alabilmektedir. Bu nedenle ilk aşamada tahta bölgesinin ayrıştırılması ve sonraki işlemlerin yalnızca ilgili alan üzerinde yürütülmesi hedeflenmiştir. Bu görev için **MobileNetV3-Large + LR-ASPP** segmentasyon tabanlı bir yaklaşım değerlendirilmiştir. Bu modelin; tahta alanı maskesi, kırılmış tahta görüntüsü ve perspektif düzeltmeye uygun koordinat bilgileri üretmesi hedeflenmiştir.

İkinci problem ise tespit edilen **tahta görüntüsünün okunabilir hale getirilmesidir**. Tahta alanı belirlendikten sonra görüntüde hâlâ gölge, parlama, bulanıklık, düşük kontrast, ışık dengesizliği veya silik yazı problemleri bulunabilmektedir. Bu nedenle yalnızca tahta alanını tespit etmek yeterli görülmemiş, yazıların korunması ve belirginleştirilmesi için ayrı bir görüntü

iyileştirme modeli geliştirilmiştir. Bu kapsamda YGM tarafında **NAFNet-Base tabanlı Multi-Head Enhancement** yapısı kullanılmıştır. Bu model, kırılmış tahta görüntüsünü iyileştirmek, OCR'ye uygun çıktı üretmek ve yazı bölgelerine ait maske oluşturmak amacıyla geliştirilmiştir.

4.6 TTM: Tahta Tespit Modeli İçin Denenen Model Yapıları

4.6.1 TTM-V1: İlk Eğitim Modeli

TTM-V1 modeli, **tahta segmentasyonu için geliştirilen** ilk güçlü model denemesidir. Eğitimde Roboflow üzerinden alınan COCO/COCO segmentation formatlı veri setleri kullanılmıştır. Eğitim kayıtlarında train/validation/test ayrımı sırasıyla 6259, 645 ve 500 örnek olarak oluşturulmuş; tüm veri RAM cache'e alınarak veri okuma darboğazı azaltılmıştır. Görüntüler 640×640 boyutuna getirilmiş, eğitim batch size 48 olarak belirlenmiş ve 40 epoch boyunca model eğitilmiştir.

Model, TorchVision LR-ASPP MobileNetV3-Large mimarisi üzerine kurulmuştur. **Segmentasyon kaybında Cross Entropy, Dice Loss ve Focal Loss bileşenleri** birlikte kullanılmıştır. Bu yapı, piksel bazlı sınıflandırma başarısı ile maske örtüşmesini birlikte optimize etmeyi hedeflemiştir. Eğitim sürecinde belirli epoch aralıklarında validation yapılmış ve en iyi checkpoint IoU değerine göre seçilmiştir.

Özellik	TTM-V1 Eğitim Bilgisi
Mimari	MobileNetV3-Large + LR-ASPP
Görev	Whiteboard alanı semantik segmentasyonu
Girdi boyutu	640×640
Train / Val / Test	6259 / 645 / 500
Batch / Epoch	48 / 40
Cache stratejisi	Train, validation ve test RAM cache
Loss yapısı	Cross Entropy + Dice Loss + Focal Loss
Parametre sayısı	Yaklaşık 3.22M
Test IoU / Dice	0.9759 / 0.9878
Test Precision / Recall	0.9870 / 0.9887
Pixel Accuracy	0.9798

Tablo 4.4. TTM-V1 Eğitim Bilgileri

TTM-V1 sonucunda test setinde 0.9759 IoU ve 0.9878 Dice değerlerine ulaşılmıştır. Bu değerler, modelin tahta bölgesini yüksek doğrulukla ayırabildiğini göstermektedir. Özellikle precision ve recall değerlerinin dengeli şekilde yüksek olması, modelin hem tahta alanını kaçırmadığını hem de arka planı büyük oranda doğru bastırabildiğini göstermektedir.

4.6.2 TTM-V2: Final Model

TTM-V2 modeli, birinci modelin daha temiz, paketlenabilir ve final sisteme daha uygun hale getirilmiş sürümüdür. Bu modelde yine **MobileNetV3-Large + LR-ASPP** mimarisi kullanılmış, eğitim 640×640 giriş boyutuyla yürütülmüş ve staged fine-tune stratejisi uygulanmıştır. Eğitim akışı head warmup, full fine-tune, ek fine-tune ve final polish aşamalarından oluşmuştur.

TTM-V2 eğitiminde **modelin başarı değerleri aşama aşama yükselmiştir**. Stage2 devam eğitiminde IoU 0.9617 seviyesine çıkmış, final polish aşamasının sonunda validation IoU 0.9633, Dice 0.9798, precision 0.9780 ve recall 0.9847 değerleri elde edilmiştir. Final modelin boyutu yaklaşık 12.47 MB olarak kaydedilmiştir. Bu değer, modelin mobil uygulama içinde taşınabilir olduğunu göstermektedir.

Metrik	TTM-V2 Final Değer
Loss	0.0702
IoU	0.9633
Dice/F1	0.9798
Precision	0.9780
Recall	0.9847
Score	0.0936
Model boyutu	12.47 MB

Tablo 4.5. TTM-V2 Metrikler

4.7 YGM: Yazı Güçlendirme Modeli İçin Denenen Model Yapıları

4.7.1 YGM-V1: Tek Çıkışlı NAFNet Tabanlı Başlangıç Modeli

YGM-V1, ikinci model ailesinin ilk temel denemesidir. Bu sürümde model, **bozulmuş tahta görüntüsünden daha temiz bir hedef görüntü** üretmeyi amaçlayan tek çıkışlı image-to-image restoration modeli olarak kurgulanmıştır. Eğitim sürecinde **L1, SSIM loss, edge loss, PSNR ve SSIM metrikleri** izlenmiştir.

Test seti sonucunda YGM-V1 modeli 0.0272 L1, 33.46 dB PSNR ve 0.9877 SSIM değerlerine ulaşmıştır. Bu değerler, hedef veri yapısında piksel benzerliği açısından güçlü bir restorasyon başarısı elde edildiğini göstermektedir.

Metrik	YGM-V1 Test Sonucu
L1	0.0272
SSIM Loss	0.0123
Edge Loss	0.0238
PSNR	33.46 dB
SSIM	0.9877
Score	0.0419

Tablo 4.6. YGM-V1 Metrikler

4.7.2 YGM-V2: NAFNet-Base64 Multi-Head Model

YGM-V2 modeli, Board2Note için geliştirilen **ilk çok başlı yazı geliştirme** modelidir. Bu modelde **NAFNet-Base64** mimarisi kullanılmış ve model üç farklı çıktı üretmek üzere genişletilmiştir. Birinci çıktı restored görüntüyü, ikinci çıktı modele uygun koyu yazı/beyaz arka plan görüntüsünü, üçüncü çıktı ise yazı bölgelerini gösteren mask_logits çıktısını üretmektedir.

YGM-V2 eğitiminde paired veri seti kullanılmıştır. Her giriş görüntüsü için target_restored, target_ocr ve text_mask hedefleri hazırlanmıştır. **Eğitim iki aşamalı** gerçekleştirilmiştir: stage1 modelin genel dönüşümü öğrenmesini sağlamış, stage2 ise daha düşük learning rate ile model ve mask çıktılarının daha kararlı hale getirilmesini amaçlamıştır. Model bfloat16 mixed precision ile eğitilmiş ve final model kaydedilmiştir.

Çıkış Başlığı	Görev	Kullanım Amacı
restored	Tahta görüntüsünü genel olarak restore etmek	Görsel temizlik ve arşivleme
ocr	Yazıyı koyulaştırıp arka planı sadeleştirmek	Dijital not üretimi
mask_logits	Yazı piksellerini segmentasyon maskesi olarak üretmek	Yazı katmanı çıkarımı ve text-on-white üretimi

Tablo 4.7. YGM-V2 Modeli Çıkışları Hakkında

Metrik	YGM-V2 Test Sonucu
rest_l1	0.0659
ocr_l1	0.0684
psnr_rest	18.09 dB
psnr_ocr	17.92 dB
mask_iou	0.5828
score	0.2177

Tablo 4.8. YGM-V2 Modeli Metrikleri

Modelin özellikle çıktı ve yazı maskesi üretme konusunda kullanılabilir bir temel oluşturduğu görülmektedir. Restored çıktısı genel görüntü temizliği sunsa da bazı örneklerde renk kayması ve doğal olmayan tonlar görülebilmektedir. Buna karşılık model çıktısı yazıları daha belirgin hale getirmekte, mask çıktısı ise gölge ve düşük kontrasta rağmen yazı bölgelerini yakalayabilmektedir.

4.7.3 YGM-V3: Denetimli + Denetimsiz GAN Destekli Multi-Head Model

YGM-V3 modeli, YGM-V2'deki çok başlı yapının geliştirilmiş sürümüdür. Bu modelde **NAFNet multi-head** mimarisi korunmuş; **eğitim süreci denetimli stage1, denetimli stage2 ve denetimsiz adversarial GAN fine-tune aşamalarından** oluşacak şekilde genişletilmiştir. **GAN aşamasının amacı**, pixel loss ile tam yakalanamayan görsel dağılım ve modele uygun yazı görünümünü daha iyi hale getirmektir.

YGM-V3 eğitiminde modelin çıktıları yalnızca L1/PSNR gibi metriklerle değil; OCR SSIM, OCR MS-SSIM, mask Dice/F1, mask boundary-F1, text contrast ve ürün çıktısı olan white canvas PSNR/SSIM değerleriyle değerlendirilmiştir. Final modelin en iyi stage olarak stage3_gan seçilmiş ve final score 0.2982 olarak raporlanmıştır.

Eğitim Aşaması	Amaç	Temel Etki
Stage 1	Denetimli temel dönüşüm öğrenimi	OCR ve mask başlıklarının temel seviyede öğrenilmesi
Stage 2	OCR + mask rafine denetimli eğitim	OCR çıktısının ve mask kararlılığının artırılması
Stage 3 - GAN	Denetimsiz adversarial fine-tune	OCR PSNR/SSIM ve ürün white canvas başarısının yükseltilmesi

Tablo 4.9. YGM-V3 Eğitim Aşamaları

Metrik	YGM-V3 Final Test Sonucu
rest_psnr / rest_mae	20.97 dB / 0.0569
ocr_psnr / ocr_mae	24.81 dB / 0.0471
ocr_ssim / ocr_ms-ssim	0.5082 / 0.7888
ocr_edge_f1	0.9597
ocr_text_contrast	0.3887
mask_iou / mask_dice	0.5778 / 0.7159
mask_precision / mask_recall	0.6077 / 0.8808
mask_boundary_f1	0.9712
white_canvas_psnr / white_canvas_ssim	30.84 dB / 0.9767

Tablo 4.10. YGM-V3 Metrik Sonuçları

4.8 Final Model Seçimi

Geliştirme sürecinde modeller **iki ana ailede** değerlendirilmiştir. **TTM ailesi** görüntüden tahta alanının ayrılmasına odaklanırken, **YGM ailesi** elde edilen tahta görüntüsünü okunabilir ve modele uygun hale getirmeyi hedeflemiştir. Aşağıdaki tablo, model denemelerinin genel karşılaştırmasını özetlemektedir.

Model	Mimari / Eğitim	Veri / Boyut	Temel Sonuç	Değerlendirme
TTM-V1	MobileNetV3-Large + LR-ASPP, FastRAM, 40 epoch	6259 train / 645 val / 500 test, 640×640	Test IoU 0.9759, Dice 0.9878	Tahta tespiti için çok güçlü ilk model.
TTM-V2	MobileNetV3-Large + LR-ASPP, staged fine-tune + polish	640×640, batch 64, final package 12.47 MB	IoU 0.9633, Dice 0.9798	Ürünleştirme için daha temiz final model.
YGM-V1	Tek çıkışlı NAFNet restoration	512 tabanlı paired restoration	PSNR 33.46, SSIM 0.9877	Görüntü benzerliği güçlü; OCR/mask ihtiyacı için yetersiz kaldı.
YGM-V2	NAFNet-Base64 multi-head	target_restored + target_ocr + text_mask	OCR L1 0.0684, mask IoU 0.5828	Üç başlıklı ilk güçlü yazı geliştirme modeli.
YGM-V3	NAFNet multi-head + supervised + GAN	Stage1 + Stage2 + Stage3-GAN	OCR PSNR 24.81, white canvas SSIM 0.9767	Final ürün çıktısı için en güçlü YGM modeli.

Tablo 4.11 Tüm Modellerin Değerlendirilmesi

Sonuçlar birlikte değerlendirildiğinde **TTM-V2, tahta alanı segmentasyonu için final sisteme** uygun hafif ve başarılı model olarak öne çıkmaktadır. **YGM tarafında ise YGM-V3,** uygun görüntü ve white canvas ürün çıktısı açısından en güçlü modeldir. Bu nedenle nihai **Board2Note pipeline’ında TTM-V2 ile tahta alanı elde edilmekte, ardından YGM-V3 ile** yazı belirginleştirme işlemleri gerçekleştirilmektedir.

4.9 OCR ve AI Açıklaması Üretme Modülü

OCR ve AI açıklaması modülü, YGM tarafından iyileştirilen görüntüden düzenlenebilir metin elde etmek için geliştirilmiştir. OCR işlemi doğrudan ham görüntü üzerinde değil, tahta alanı belirlenmiş, perspektifi düzeltilmiş ve OCR’ye uygun hale getirilmiş görüntü üzerinde yürütülmüştür. Bu tercih, gölge, parlama, düşük kontrast ve eğik çekim gibi etkenlerin OCR üzerindeki olumsuz etkisini azaltmayı hedeflemiştir.

OCR sonucunda elde edilen metin doğrudan nihai çıktı olarak kabul edilmemiştir. Çünkü tahta görüntülerinde satır sıralaması, harf benzerlikleri, eksik karakterler ve biçimsel bozulmalar görülebilmektedir. Bu nedenle OCR çıktısı not üretme akışına aktarılmış, gerekli durumlarda LLM/Gemini API ile daha düzenli bir ders notu formatına dönüştürülmesi hedeflenmiştir. Özetleme, adım adım anlatım ve anahtar kelimeler ile anlatım bu modülün temel görevleri arasındadır.

Kullanıcı kontrolünü korumak amacıyla oluşturulan içerik Not Editörü ekranına aktarılmıştır. Kullanıcı, otomatik üretilen metni inceleyebilmekte, hatalı OCR kısımlarını düzeltebilmekte, ders adını belirleyebilmekte ve notu kaydedebilmektedir. Böylece sistem tamamen kapalı bir otomatik çıktı üretmek yerine, kullanıcı denetimine açık bir not oluşturma hattı sunmaktadır.

4.10 Projenin Çalıştırılması İçin Gereksinimler ve Kurulum Aşamaları

Board2Note projesinin çalıştırılması için gerekli ortam, projenin hangi bileşeninin çalıştırılacağına göre değişmektedir. Projede **iki temel çalışma ortamı** bulunmaktadır. Bunlardan ilki, yapay zekâ modellerinin eğitimi, test edilmesi ve görüntü işleme deneylerinin yürütüldüğü **Python tabanlı model geliştirme** ortamıdır. İkincisi ise kullanıcıların tahta fotoğrafı çektiği, görüntüleri işlediği ve sonucunda not oluşturduğu ve notlarını yönettiği **Android mobil uygulama** ortamıdır.

Model geliştirme tarafında TTM ve YGM modellerinin eğitimi, veri ön işleme süreçleri, sentetik veri seti kullanımı ve model çıktılarının değerlendirilmesi Python ortamında gerçekleştirilmiştir. Mobil uygulama tarafında ise Board2Note, Android/IOS platformunda Kotlin diliyle geliştirilmiş ve kullanıcıya kamera, galeri, tahta alanı seçimi, not editörü ve not yönetimi özelliklerini sunacak şekilde yapılandırılmıştır.

4.10.1 Python Model Geliştirme ve Eğitim Ortamı Gereksinimleri

Python tabanlı geliştirme ortamı, Board2Note projesindeki yapay zekâ modellerinin eğitilmesi, test edilmesi, veri setlerinin hazırlanması ve görüntü işleme deneylerinin yürütülmesi için kullanılmıştır. Bu ortamda özellikle TTM: Tahta Tespit Modeli ve YGM: Yazı Güçlendirme Modeli üzerinde çalışılmıştır. TTM tarafında tahta alanı tespiti yapılırken, YGM tarafında tahta görüntüsünün iyileştirilmesi, modele uygun hale getirilmesi ve yazı maskesi üretimi hedeflenmiştir.

Python ortamı, özellikle yüksek işlem gücü gerektiren model eğitimlerinde tercih edilmiştir. Model eğitimlerinde GPU destekli çalışma ortamları kullanılmış; veri seti hazırlama, augmentation, model eğitimi, loss hesaplamaları ve görsel çıktıların incelenmesi bu ortamda gerçekleştirilmiştir.

Gerekli Temel Bileşenler

- **Python:** Projenin model geliştirme, veri işleme ve deneysel çalışmalarında ana programlama dili olarak kullanılmıştır.
- **PyTorch:** TTM ve YGM modellerinin geliştirilmesi, eğitilmesi ve test edilmesi için kullanılmıştır.
- **Torchvision:** Görüntü dönüşümleri, veri hazırlama işlemleri ve model bileşenleri için kullanılmıştır.
- **Albumentations:** Veri artırma işlemlerinde kullanılmıştır. Gölge, parlama, bulanıklık, kontrast değişimi ve benzeri görüntü bozulmalarının uygulanmasına destek sağlamıştır.
- **OpenCV:** Tahta alanı kırpma, perspektif düzeltme, morfolojik işlemler ve temel görüntü işleme adımlarında kullanılmıştır.
- **NumPy:** Görüntü matrisleri, koordinat hesaplamaları ve maske işlemlerinde kullanılmıştır.
- **Pillow:** Görüntü okuma, dönüştürme, yeniden boyutlandırma ve format işlemlerinde kullanılmıştır.
- **Matplotlib:** Eğitim sonuçlarının, örnek çıktıların ve grafiklerin görselleştirilmesi için kullanılmıştır.
- **TQDM:** Eğitim ve veri işleme süreçlerinde ilerleme takibi için kullanılmıştır.
- **PyYAML:** Veri seti yapılandırma dosyalarının ve yol bilgilerinin okunması için kullanılmıştır.
- **pycocotools:** COCO formatındaki segmentasyon anotasyonlarının okunması ve maske işlemlerinde kullanılmıştır.
- **Google Colab:** GPU destekli eğitim deneylerinin yürütülmesinde kullanılmıştır.
- **Google Drive:** Veri setleri, model dosyaları, checkpoint çıktıları ve eğitim sonuçlarının saklanması için kullanılmıştır.

Sistem Gereksinimleri

- **Python Sürümü:** Python 3.9 veya üzeri bir sürüm önerilmektedir.
- **İşletim Sistemi:** Windows, macOS veya Linux ortamlarında çalıştırılabilir.
- **GPU Desteği:** YGM gibi derin öğrenme tabanlı görüntü iyileştirme modellerinin eğitimi için GPU destekli ortam önerilmektedir.
- **Bellek ve Depolama:** Sentetik veri setleri, model ağırlıkları ve eğitim çıktıları yüksek depolama alanı gerektirebildiği için yeterli disk alanı bulunmalıdır.
- **İnternet Bağlantısı:** Veri setlerinin indirilmesi, Google Drive bağlantıları ve harici servislerin kullanımı için gereklidir.

Kullanılan Kütüphaneler

- **Python:** Model geliştirme, veri işleme ve deneysel çalışmaların ana dili olarak kullanılmıştır.
- **PyTorch:** TTM ve YGM modellerinin eğitilmesi, test edilmesi ve çıkarım işlemlerinde kullanılmıştır.
- **Torchvision:** Görüntü dönüşümleri, veri hazırlama ve model bileşenleri için kullanılmıştır.
- **Albumentations:** Veri artırma ve sentetik bozulma işlemlerinde kullanılmıştır.
- **OpenCV:** Kırpma, perspektif düzeltme, maske işleme ve görüntü düzenleme adımlarında kullanılmıştır.
- **NumPy:** Görüntü matrisleri, koordinatlar ve sayısal işlemler için kullanılmıştır.
- **Pillow:** Görüntü açma, dönüştürme ve yeniden boyutlandırma işlemlerinde kullanılmıştır.
- **Matplotlib:** Eğitim sonuçları ve model çıktılarının görselleştirilmesi için kullanılmıştır.
- **TQDM:** Eğitim ve veri hazırlama süreçlerinde ilerleme takibi için kullanılmıştır.
- **PyYAML:** Veri seti yapılandırma dosyalarının okunması için kullanılmıştır.
- **Pycocotools:** COCO formatındaki anotasyonların işlenmesi ve maske üretimi için kullanılmıştır.
- **Google Colab:** GPU destekli model eğitimlerinin yürütülmesi için kullanılmıştır.
- **Google Drive:** Veri seti, model dosyası ve eğitim çıktılarının saklanması için kullanılmıştır.

Python Ortamı Kurulum Aşamaları

- Python 3.9 veya daha güncel bir sürüm kurulmalıdır.
- Proje dosyaları yerel bilgisayara veya Google Colab ortamına aktarılmalıdır.
- Gerekli Python kütüphaneleri kurulmalıdır.
- Kullanılacak veri setleri ilgili klasör yapısına yerleştirilmelidir.
- TTM için segmentasyon veri setleri hazırlanmalıdır.
- YGM için generated_multihead_dataset_v2.zip sentetik veri seti kullanılmalıdır.
- Eğitim notebookları üzerinden model eğitimleri başlatılmalıdır.
- Eğitim sonucunda oluşan checkpoint ve model dosyaları kaydedilmelidir.
- Eğitilen modeller test görüntüleri üzerinde değerlendirilmelidir.
- Uygun görülen model çıktıları mobil uygulama entegrasyonu veya raporlama için kullanılmalıdır.

4.10.2 Android Mobil Uygulama Gereksinimleri

Board2Note mobil uygulaması, Android/IOS platformu üzerinde çalışacak şekilde geliştirilmiştir. Uygulama; kullanıcıların kamera ile tahta fotoğrafı çekmesini, galeriden görsel seçmesini, tahta alanını belirlemesini, görüntüyü işleme almasını, OCR sonucunda oluşan metni düzenlemesini ve oluşturulan notları cihaz üzerinde saklamasını sağlamaktadır.

Mobil uygulama tarafında temel amaç, kullanıcıya sade ve anlaşılır bir arayüz üzerinden karmaşık görüntü işleme ve not oluşturma işlemlerini sunmaktır. Bu nedenle uygulama geliştirilirken modern Android geliştirme araçları tercih edilmiştir.

4.10.2.1 Sürüm ve SDK Bilgileri

Programlama Dili: Kotlin

Geliştirme Ortamı: Android Studio

Arayüz Yapısı: Jetpack Compose

Tasarım Dili: Material 3

Hedef Platform: Android/IOS telefon ve tabletler

Temel Donanım Gereksinimleri: Kamera, dokunmatik ekran, yeterli depolama alanı

İzin Gereksinimleri: Kamera erişimi, galeri/medya erişimi, dosya erişimi ve internet erişimi

4.10.2.2 Temel Bağımlılıklar

Kotlin: Android mobil uygulamasının ana geliştirme dili olarak kullanılmıştır.

Android Studio: Uygulamanın geliştirilmesi, test edilmesi ve hata ayıklama süreçlerinde kullanılmıştır.

Jetpack Compose: Modern ve dinamik kullanıcı arayüzlerinin geliştirilmesi için kullanılmıştır.

Material 3: Buton, kart, snackbar, dialog, alt navigasyon ve diğer arayüz bileşenlerinde modern tasarım dili sağlamak için kullanılmıştır.

Android Camera / Kamera Erişimi: Kullanıcının tahta fotoğrafı çekebilmesini sağlamak için kullanılmıştır.

Galeri / Medya Seçimi: Kullanıcının cihazındaki mevcut tahta görüntülerini seçebilmesi için kullanılmıştır.

OpenCV: Tahta alanı seçimi, kırpma, perspektif düzeltme ve görüntü işleme adımlarında kullanılmıştır.

Dosya Tabanlı Yerel Depolama: Notların ve ilgili görsel çıktıların cihaz üzerinde saklanması için kullanılmıştır.

JSON Dosya Yapısı: Notlara ait metinsel ve yapısal bilgilerin notes.json dosyasında tutulması için kullanılmıştır.

4.10.2.3 Yardımcı ve Donanımsal Gereksinimler

Sistem ve İzin Yönetimi

Kamera İzni: Kullanıcının tahta fotoğrafı çekebilmesi için gereklidir.

Galeri / Medya İzni: Kullanıcının cihaz galerisinden görsel seçebilmesi için gereklidir.

Dosya Erişimi: Oluşturulan notların, görsel çıktıların ve JSON kayıtlarının cihaz üzerinde saklanması için gereklidir.

Görüntü ve Format İşleme Araçları

OpenCV: Tahta alanı seçimi, perspektif düzeltme ve görüntü düzenleme işlemlerinde kullanılmıştır.

Bitmap / Görsel İşleme Bileşenleri: Android/IOS tarafında görüntülerin ekranda gösterilmesi, döndürülmesi ve işlenmesi için kullanılmıştır.

JSON İşleme: Not verilerinin dosya tabanlı yapıda okunması ve yazılması için kullanılmıştır.

4.10.3 Harici Araç ve Servis Kurulumları

Board2Note projesinde bazı işlemler için harici servisler ve destekleyici araçlar kullanılmıştır. Bu araçlar model geliştirme, veri seti yönetimi, not düzenleme ve dosya paylaşımı süreçlerini desteklemek amacıyla değerlendirilmiştir.

Roboflow Veri Setlerinin Kullanılması

TTM eğitimi için kullanılan segmentasyon veri setleri Roboflow üzerinden hazırlanmış veya temin edilmiştir. Roboflow üzerinde yer alan veri setleri COCO formatında dışa aktarılmış ve model eğitiminde kullanılmak üzere proje ortamına alınmıştır.

Kurulum ve kullanım süreci genel olarak şu şekildedir:

1. Roboflow üzerinden ilgili veri seti seçilmiştir.
2. Veri seti COCO formatında dışa aktarılmıştır.
3. Görüntüler ve anotasyon dosyaları proje eğitim ortamına aktarılmıştır.
4. COCO anotasyonları okunarak tahta alanı maskeleri oluşturulmuştur.
5. Eğitim öncesi letterbox, normalizasyon ve augmentation işlemleri uygulanmıştır.

Google Drive Kullanımı

Model dosyaları, veri setleri ve eğitim çıktıları yüksek boyutlu olabildiği için Google Drive üzerinde saklanmıştır. Özellikle model checkpoint dosyaları, sentetik veri setleri ve eğitim çıktılarının saklanması Google Drive kullanılmıştır. Bu yapı, hem Google Colab ile uyumlu çalışmayı hem de dosyaların ekip içinde paylaşılmasını kolaylaştırmıştır.

OCR Servisi ve OCR Kütüphanesi Kurulumu

OCR modülü, iyileştirilmiş tahta görüntüsündeki yazıları metne dönüştürmek için kullanılmıştır. OCR işlemi için backend sunucu tarafında çalışacak QWEN2.5 VL 3B modeli kullanılmıştır. OCR modülü, YGM tarafından üretilen OCR'ye uygun görüntü üzerinde çalışarak ham metin çıktısı üretmektedir.

Genel kullanım adımları:

1. YGM tarafından iyileştirilmiş tahta görüntüsü alınır.
2. LM Studio içindeki QWEN2.5 VL 3B modeliyle OCR gerçekleştirilir.
3. OCR sonucunda ham metin çıktısı elde edilir.
4. Ham metin ilgili görüntü üzerinde kaydedilir.

Gemini API / LLM Servisi Kurulumu

OCR sonucunda elde edilen ham metin, her zaman doğrudan düzenli bir ders notu formatında olmayabilir. Bu nedenle metni daha okunabilir ve düzenli hale getirmek için LLM tabanlı servislerden yararlanılmıştır. Gemini API, OCR çıktısını daha kullanışlı ve anlaşılabilir ders notu formatına dönüştürme amacıyla kullanılmıştır.

Genel kullanım adımları:

1. Gemini API anahtarı alınır.
2. API anahtarı proje yapılandırmasına eklenir.
3. OCR sonucunda elde edilen ham metin LLM servisine gönderilir.
4. Servis çıktısı ders anlatımı olarak alınır.

4.10.4 Android Mobil Uygulama Kurulum Aşamaları

Board2Note mobil uygulamasının çalıştırılabilmesi için Android Studio ortamında proje açılmalı ve gerekli Gradle yapılandırmaları tamamlanmalıdır.

Kurulum aşamaları şu şekildedir:

1. Android Studio kurulmalıdır.
2. Proje dosyaları Android Studio ile açılmalıdır.
3. Gradle senkronizasyonu tamamlanmalıdır.
4. Gerekli Android SDK bileşenleri yüklenmelidir.
5. Kamera, galeri ve internet izinleri Android manifest dosyasında tanımlanmalıdır.
6. İlgili OCR, LLM API anahtarları ve LM Studio yapılandırılmalıdır.
7. Uygulama fiziksel Android cihazda veya emülatörde çalıştırılmalıdır.
8. Kamera ve galeri erişim izinleri kullanıcı tarafından onaylanmalıdır.
9. Ana sayfa üzerinden “Yeni Tahta Notu Oluştur” işlemi başlatılarak uygulama akışı test edilmelidir.

5. TEST ve DOĞRULAMA

5.1 Test ve Hata Ayıklama Mekanizmaları

Board2Note projesinde test ve doğrulama süreci yalnızca model metriklerinin ölçülmesiyle sınırlı tutulmamıştır. Proje **iki ayrı derin öğrenme modelinden** ve bu modellerin birbirine bağlı çalıştığı bir görüntü işleme hattından oluştuğu için test süreci; veri seti hazırlama, eğitim izleme, checkpoint doğrulama, manuel çıktı inceleme, model karşılaştırma ve mobil entegrasyon hazırlığı gibi birçok aşamayı kapsamaktadır.

Birinci model, sınıf veya amfi görüntüsünden **tahta alanını piksel seviyesinde tespit etmektedir**. Bu modelin başarısı IoU, Dice/F1, precision ve recall değerleriyle izlenmiştir. **İkinci model** ise **tespit edilen tahta görüntüsünü iyileştirmekte; restore edilmiş görüntü, amacımıza uygun görüntü ve yazı maskesi olmak üzere üç ayrı çıktı üretmektedir**. Bu nedenle **ikinci model için L1/MAE, PSNR, SSIM, mask IoU, Dice/F1, precision, recall, yazı-arka plan kontrastı ve çıktı görselleri birlikte değerlendirilmiştir**.

Test sürecinde her epoch sonunda doğrulama yapılmış, en iyi checkpoint dosyaları saklanmış ve model çıktıları düzenli olarak görselleştirilmiştir. Böylece modelin yalnızca sayısal olarak ilerleyip ilerlemediği değil, gerçek görüntüler üzerinde anlamlı çıktılar üretip üretmediği de kontrol edilmiştir. Özellikle tahta görüntülerinde gölge, parlama, düşük kontrast, soluk yazı ve kamera açısı gibi değişkenler bulunduğu için manuel görsel doğrulama bu proje açısından kritik bir test adımı olarak ele alınmıştır.

5.1.1 TTM Testleri

TTM için temel test amacı, giriş görüntüsünde yer alan **tahta alanının doğru maskelenip maskelenmediğini** belirlemektir. Bu nedenle modelin çıktısı, gerçek tahta maskesiyle karşılaştırılmış ve segmentasyon metrikleri kullanılmıştır. **IoU** metriği tahmin edilen maske ile gerçek maske arasındaki örtüşmeyi, **Dice/F1** metriği genel segmentasyon uyumunu, **precision** arka planın yanlışlıkla tahta seçilip seçilmediğini ve **recall** gerçek tahta alanının kaçırılıp kaçırılmadığını göstermektedir.

Eğitim sürecinde önce backbone dondurularak segmentasyon başlığı ısıtılmış, daha sonra tüm model açılarak full fine-tune yapılmıştır. Eğitim çıktılarında IoU ve Dice değerlerinin düzenli biçimde arttığı görülmüştür. Özellikle devam eğitimleri sonunda modelin tahta alanını çok daha kararlı ayırdığı, precision ve recall dengesinin yükseldiği ve maske sınırlarının daha düzgün hale geldiği gözlemlenmiştir.

TTM tarafında yapılan testler, sistemin YGM'ye göndereceği görüntünün doğruluğunu doğrudan etkilediği için ayrıca önemlidir. Tahta alanının eksik kırılması yazıların kaybolmasına, fazla geniş kırılması ise ikinci modelin duvar, masa veya arka plan bölgeleriyle gereksiz yere uğraşmasına neden olabilmektedir. Bu nedenle TTM doğrulamasında yalnızca metrik değerleri değil, çıktı maskesinin gerçek kullanım senaryosunda doğru crop üretip üretmediği de incelenmiştir.

Model	Test Edilen Çıktı	Temel Metrikler	Değerlendirme
TTM / MobileNetV3-Large + LR-ASPP	Tahta alanı maskesi	IoU, Dice/F1, Precision, Recall	Tahta bölgesini piksel seviyesinde ayırma başarısı izlendi.
YGM / NAFNet Multi-Head	Restored, OCR ve Ürün seviyesinde White Canvas Çıktısı	L1, PSNR, SSIM, IoU, Dice, Contrast	Görüntü iyileştirme, proje amacına uygunlaştırma ve yazı maskesi birlikte değerlendirildi.

Tablo 5.1. TTM ve YGM Modellerinin Çıktı, Metrik ve Değerlendirmesi Hakkında

5.1.2 YGM Çok Çıkışlı Test ve Doğrulama Süreci

YGM, çok başlı bir yapı olarak tasarlandığı için tek bir başarı metriğiyle değerlendirilmemiştir. Modelin birinci çıkışı olan restored output, tahta görüntüsünün genel olarak temizlenmiş halini üretmektedir. İkinci çıkış olan OCR output, yazının daha koyu ve arka planın daha sade olduğu kullanıma uygun görüntüyü üretmektedir. Üçüncü çıkış olan mask_logits ise yazı bölgelerini piksel seviyesinde gösteren yazı maskesidir.

Test sürecinde modelin her çıktısı kendi hedef görüntüsüyle karşılaştırılmıştır. **Restored çıkışı target_restored ile, OCR çıkışı target_ocr ile, mask çıkışı ise text_mask ile** değerlendirilmiştir. Böylece modelin bir çıktısındaki başarı veya hata diğer çıktılardan ayrı biçimde analiz edilebilmiştir. Bu yaklaşım, özellikle OCR çıktısı başarılıyken restored çıktısında renk kayması veya doğal görüntü kalitesi problemleri görüldüğünde hangi başlığın geliştirilmesi gerektiğini belirlemeyi kolaylaştırmıştır.

YGM testlerinde kullanılan paired veri seti train, validation ve test ayrımlarına sahiptir. Eğitim loglarında 3920 train, 144 validation ve 156 test örneği kullanılmıştır. Bu ayırım sayesinde modelin yalnızca eğitim görüntülerine uyum sağlayıp sağlamadığı değil, daha önce görmediği örneklerde de benzer performans üretip üretmediği kontrol edilmiştir.

Çıktı Başlığı	Görevi	Testte Kullanılan Ölçütler	Yorumlama
restored	Tahta görüntüsünü genel olarak temizlemek	rest_l1, rest_psnr, rest_ssim, edge_mae	Düşük L1 ve yüksek PSNR/SSIM daha iyi restore kalitesini gösterir.
ocr	OCR'ye uygun beyaz arka plan/koyu yazı üretmek	ocr_l1, ocr_psnr, ocr_ssim, contrast	Yazı belirginliği ve arka plan sadeliği bu başlıkta değerlendirilir.
mask_logits	Yazı bölgelerini piksel seviyesinde ayırmak	mask_iou, Dice/F1, Precision, Recall, AP, ROC-AUC	Yazı yakalama ve arka planı bastırma başarısı ölçülür.

Tablo 5.2. YGM Çıktı Başlıkları Bilgileri

5.1.3 YGM Test Sonuçlarının Değerlendirilmesi

YGM'nin test seti üzerinde yapılan kapsamlı değerlendirmesinde OCR'ye uygun çıktı başlığının kullanılabilir seviyede olduğu görülmüştür. Test setinde OCR çıktısı için ortalama L1/MAE değeri yaklaşık 0.0684, PSNR değeri yaklaşık 17.93 dB olarak ölçülmüştür. Bu değerler, modelin giriş görüntüsündeki yazı ve arka plan yapısını hedef OCR görüntüsüne yaklaştırabildiğini göstermektedir.

Restored çıkışı için test setinde ortalama L1/MAE değeri yaklaşık 0.0659 ve PSNR değeri yaklaşık 18.10 dB olarak ölçülmüştür. Görsel incelemelerde restored çıktısının genel yapıyı koruduğu ancak bazı örneklerde renk kayması, yeşilimsi ton, doğal olmayan yüzey görünümü veya gölge temizleme eksikliği gösterebildiği görülmüştür. Bu nedenle restored başlığı geliştirmeye açık alan olarak değerlendirilmiş ve GAN tabanlı fine-tune planı bu ihtiyaca göre tasarlanmıştır.

Mask başlığı için genel değerlendirmede test setinde ortalama IoU yaklaşık 0.5827, Dice/F1 değeri yaklaşık 0.7196, precision yaklaşık 0.6145 ve recall yaklaşık 0.8769 olarak ölçülmüştür. Bu sonuçlar mask head'in yazıları yüksek oranda yakaladığını, ancak default threshold değerinde bazı arka plan bölgelerini de yazı olarak algılayabildiğini göstermektedir. Bu nedenle mask başlığı ayrıca threshold sweep yöntemiyle test edilmiştir.

Metrik	Test Ortalama Değeri	Yorum
rest_mae	0.0659	Restored çıktısının hedef restore görüntüsüne ortalama yakınlığını gösterir.
rest_psnr	18.10 dB	Restore görüntüsünde orta düzeyde iyileştirme olduğunu göstermektedir.
ocr_mae	0.0684	OCR'ye uygun çıktı hedefe yakın ve kullanılabilir seviyededir.
ocr_psnr	17.93 dB	OCR çıktısında yazı/arka plan dönüşümü tutarlı ilerlemiştir.
mask_iou	0.5827	Default threshold ile orta-iyi segmentasyon başarısı elde edilmiştir.
mask_dice	0.7196	Yazı maskesinin genel örtüşme başarısı kullanılabilir düzeydedir.
mask_recall	0.8769	Model yazı bölgelerinin büyük kısmını yakalayabilmektedir.
pred_ocr_contrast	0.3989	Yazı ve arka plan ayrımı belirginleşmiştir.

Tablo 5.3. YGM Metrikleri

5.1.4 Mask Head İçin Threshold Testi

YGM'nin üçüncü çıkışı olan mask_logits başlığı ayrıca test edilmiştir. Bu testte yalnızca default threshold değeri kullanılmamış, 0.10 ile 0.90 aralığında farklı eşik değerleri denenerek IoU, Dice/F1, precision ve recall değerleri ölçülmüştür. Bu işlem, modelin ürettiği olasılık haritasının hangi eşikte en iyi binary maskeye dönüştüğünü belirlemek amacıyla yapılmıştır.

Default threshold 0.50 kullanıldığında test setinde IoU yaklaşık 0.5614, Dice/F1 yaklaşık 0.7191, precision yaklaşık 0.6086 ve recall yaklaşık 0.8788 olarak ölçülmüştür. Bu sonuç, modelin yazı bölgelerini kaçırmama eğiliminin yüksek olduğunu ancak bazı gereksiz bölgeleri de yazı olarak işaretleyebildiğini göstermektedir.

Threshold optimizasyonu yapıldığında test setinde en iyi IoU değerinin 0.85 threshold civarında elde edildiği görülmüştür. Bu durumda IoU yaklaşık 0.6075, Dice/F1 yaklaşık

0.7558, precision yaklaşık 0.7260 ve recall yaklaşık 0.7883 olmuştur. Validation setinde ise en iyi sonuç 0.90 threshold civarında elde edilmiş; IoU yaklaşık 0.6382 ve Dice/F1 yaklaşık 0.7791 seviyesine çıkmıştır.

Split	Threshold	IoU	Dice/F1	Precision	Recall	Yorum
Test	0.50	0.5614	0.7191	0.6086	0.8788	Yazıyı kaçırmama başarısı yüksek; fakat fazla pozitif alanlar mevcut.
Test	0.85	0.6075	0.7558	0.7260	0.7883	Daha dengeli ve temiz maske için en uygun test eşiği.
Validation	0.50	0.5827	0.7363	0.6197	0.9070	Validation tarafında recall çok yüksek.
Validation	0.90	0.6382	0.7791	0.7702	0.7883	En iyi validation dengesi; precision belirgin şekilde artmıştır.

Tablo 5.4. YGM Mask Head İçin Yapılan Treshold Deneme Sonuçları

Mask head için AP ve ROC-AUC değerleri de ayrıca incelenmiştir. Test setinde AP yaklaşık 0.9779 ve ROC-AUC yaklaşık 0.9998 olarak ölçülmüştür. Bu değerler, modelin yazı pikselleri ile arka plan piksellerini olasılık düzeyinde oldukça güçlü ayırdığını göstermektedir. Dolayısıyla mask başarısında temel sorun modelin ayırt edememesi değil, binary maskeye dönüştürme aşamasında doğru threshold değerinin seçilmesidir.

Bu değerlendirme sonucunda ürün tarafında 0.50 threshold yerine 0.85–0.90 aralığında bir eşik kullanılmasının daha temiz maske üreteceği sonucuna varılmıştır.

5.1.5 Görsel Çıktı ve Manuel Kalite Kontrolleri

Sayısal metriklerin yanında model çıktıları düzenli olarak görsel önizleme dosyalarıyla kontrol edilmiştir. TTM için tahta maskesinin sınıf ortamındaki gerçek tahta alanını kapsayıp kapsamadığı; YGM için ise input, pred_rest, target_rest, pred_ocr, target_ocr ve pred_mask çıktıları aynı grid üzerinde karşılaştırılmıştır.

Görsel incelemelerde YGM'nin OCR output başlığının özellikle yazıları koyulaştırma ve arka planı sadeleştirme açısından başarılı olduğu gözlemlenmiştir. Pred_mask çıktısı ise gölge, düşük kontrast ve soluk yazı durumlarında dahi yazı bölgelerini büyük ölçüde yakalayabilmiştir.

Manuel testler, modelin yalnızca sayısal metriklerde değil, gerçek kullanım açısından da değerlendirilmesini sağlamıştır. Board2Note projesinde nihai hedef okunabilir not üretimi olduğu için pred_ocr ve pred_mask çıktıları daha yüksek öncelikli kabul edilmiştir.

5.2 Manuel Testler Sonucu Alınan Bazı Hatalar

Model geliştirme sürecinde yalnızca nihai başarı metrikleri değil, karşılaşılan hatalar ve bu hatalara karşı uygulanan çözüm stratejileri de kayıt altına alınmıştır. Bu yaklaşım, sistemin hangi teknik darboğazlardan geçtiğini, hangi kararların neden alındığını ve sonraki geliştirme aşamalarında hangi noktalara dikkat edilmesi gerektiğini göstermesi açısından önemlidir.

- **Roboflow Veri Seti İndirme ve Paket Uyumsuzlukları**

Tanımlanan Sorun: Roboflow veri setlerinin indirilmesi sırasında paket sürümü ve pillow_heif bağımlılığı kaynaklı hatalarla karşılaşılmıştır. Özellikle register_avif_opener fonksiyonunun bulunmaması nedeniyle roboflow import aşamasında çalışma kesintiye uğramıştır. Ayrıca public veri setlerinin workspace/project/version bilgilerinde değişiklikler olduğu için bazı indirme blokları doğrudan çalışmamıştır.

Uygulanan Çözüm: Sorun, Roboflow dataset bilgileri doğru workspace, project ve version değerleriyle güncellenerek ve paket kurulum sırası yeniden düzenlenerek çözülmüştür. Gerekli durumlarda public veri setleri kullanıcı workspace'ine fork edilip yeni version olarak alınmıştır. Böylece veri setlerinin sabit ve tekrar indirilebilir bir yapıya kavuşması sağlanmıştır.

- **COCO Formatı, Sınıf Adı ve Annotation Parser Sorunları**

Tanımlanan Sorun: TTM eğitiminde farklı Roboflow veri setleri birleştirildiği için kategori adları, annotation dosyaları ve mask üretim biçimleri arasında uyumsuzluklar görülmüştür. Bazı veri setlerinde segmentasyon polygon bilgisi varken bazılarında yalnızca bbox bilgisi bulunmuştur. Ayrıca sınıf adlarının whiteboard, board veya farklı varyasyonlarda verilmesi parser tarafında ek kontrol gerektirmiştir.

Uygulanan Çözüm: COCO parser bloğu kategori anahtar kelimelerini destekleyecek şekilde düzenlenmiştir. Polygon segmentation varsa fillPoly ile maske üretilmiş, RLE varsa

pycocotools üzerinden decode edilmiş, segmentasyon bulunmadığında bbox fallback yöntemi kullanılmıştır. Böylece farklı kaynaklardan gelen veri setleri tek bir ortak sample listesine dönüştürülmüştür.

- **Notebook Hücrelerinde SyntaxError ve F-String Hataları**

Tanımlanan Sorun: Colab hücrelerine kod aktarımı sırasında print ifadelerinin satır ortasında kırılması veya f-string ifadelerinin yanlış bölünmesi nedeniyle unterminated string literal ve unterminated f-string literal hataları alınmıştır. Bu hatalar eğitimden bağımsız olsa da eğitim pipeline'ının ilerlemesini engellemiştir.

Uygulanan Çözüm: Hatalı hücreler yeniden yazılmış, print ifadeleri tek satırda veya escape karakterleriyle güvenli hale getirilmiştir. Kritik bloklar daha sonra yeniden düzenlenerek doğrudan kopyalanabilir tam hücreler şeklinde hazırlanmıştır. Bu sayede parser, training loop ve checkpoint devam kodları çalışır hale getirilmiştir.

- **Colab Drive, Local Disk ve RAM Cache Darboğazları**

Tanımlanan Sorun: Eğitim sırasında veri setinin doğrudan Drive üzerinden okunması GPU kullanımını sınırlamış ve eğitim hızının beklenenden düşük olmasına neden olmuştur. A100 GPU kullanılmasına rağmen GPU belleğinin çok az kullanılması ve batch süresinin yüksek kalması, darboğazın modelden değil veri okuma sürecinden kaynaklandığını göstermiştir.

Uygulanan Çözüm: Veri seti Drive'dan local diske çıkarılmış, ardından uygun durumlarda RAM cache yapısı kullanılmıştır. Batch size artırılmış, num_workers ve pin_memory ayarları düzenlenmiş, preprocessed görüntülerin bellekte tutulması sağlanmıştır. Bu düzenlemelerden sonra eğitim süresi belirgin şekilde kısalmış ve GPU daha verimli kullanılmaya başlanmıştır.

- **DataLoader Worker ve Multiprocessing Hataları**

Tanımlanan Sorun: Devam eğitimlerinde DataLoader worker exited unexpectedly, QueueFeederThread ve semaphore or lock released too many times gibi multiprocessing kaynaklı hatalar oluşmuştur. Bu hatalar genellikle worker sayısı, RAM cache, Colab ortamı ve önceki DataLoader nesnelerinin tam kapanmamasıyla ilişkili olarak görülmüştür.

Uygulanan Çözüm: Devam eğitimlerinde DataLoader daha güvenli ayarlarla yeniden oluşturulmuş, worker sayısı düşürülmüş veya gerekli durumda sıfıra çekilmiştir. Eski loader nesneleri temizlenmiş, gc.collect ve torch.cuda.empty_cache çağrıları uygulanmıştır. Bu sayede

eğitim devam ettirilebilmiş, ancak Colab multiprocessing davranışının kararsız olabileceği not edilmiştir.

- **TTM Devam Eğitimi ve Fonksiyon İmza Uyumsuzlukları**

Tanımlanan Sorun: Stage2 devam eğitimi başlatılırken train_stage fonksiyonunun farklı notebook sürümlerinde farklı argüman sırasına sahip olması nedeniyle got multiple values for argument hataları alınmıştır. Bu durum özellikle mevcut checkpoint'ten devam etmek istenirken fonksiyon çağrısının eğitim kodundaki gerçek imzayla uyuşmamasından kaynaklanmıştır.

Uygulanan Çözüm: Fonksiyon imzası inspect edilerek çağrı biçimi yeniden düzenlenmiştir. Gereksiz positional argümanlar kaldırılmış, epochs, lr ve freeze_backbone parametreleri doğru biçimde verilmiştir. Böylece Stage2 extra ve devam eğitimleri başarılı biçimde başlatılmıştır.

- **GAN Fine-Tune Sürecinde Çıktıların Bozulma Riski**

Tanımlanan Sorun: YGM'nin restored çıktısını iyileştirmek için GAN fine-tune planlanmıştır. Ancak GAN eğitiminin yalnızca bir çıkışı iyileştirirken OCR ve mask başlıklarını bozma riski bulunmaktadır. Özellikle OCR output ve mask head mevcut durumda kullanılabilir seviyede olduğu için agresif GAN eğitimi istenmeyen sonuçlara yol açabilir.

Uygulanan Çözüm: GAN fine-tune tasarımı teacher-student yapısıyla kurulmuştur. Mevcut model teacher olarak dondurulmuş, student model restore branch üzerinde geliştirilirken OCR ve mask çıktıları teacher distillation ve target loss ile korunmuştur. Böylece 1. çıktıyı iyileştirme hedefi, 2. ve 3. çıktıları bozmadan ilerletilmeye çalışılmıştır.

5.3 Genel Değerlendirme

Test ve doğrulama süreci, Board2Note projesinin yalnızca iki yapay zeka modelinden ibaret olmadığını; veri hazırlama, eğitim takibi, model çıktısı doğrulama, mobil entegrasyon ve hata ayıklama adımlarından oluşan bütüncül bir sistem olduğunu göstermiştir. Karşılaşılan hatalar, proje sürecinde model performansını artırmanın yanında sistemin çalıştırılabilirliğini ve sürdürülebilirliğini de iyileştirmiştir.

TTM tarafında yapılan testler, tahta tespiti için seçilen **MobileNetV3-Large + LR-ASPP** yapısının doğru bir tercih olduğunu göstermiştir. Model hafif, mobil tarafa uygun ve yüksek segmentasyon başarısı üretmeye elverişli bir yapı sunmuştur. Eğitim sırasında yapılan

devam eğitimleri ve threshold kontrollü testler, tahta maskesinin daha kararlı hale gelmesini sağlamıştır.

YGM tarafında yapılan testler, **NAFNet tabanlı multi-head** yapının özellikle kullanıma uygun çıktı ve yazı maskesi üretiminde güçlü olduğunu göstermiştir. Mask head yüksek recall ve çok yüksek AP/ROC-AUC değerleriyle yazı bölgelerini gölge ve düşük kontrasta rağmen ayırabildiğini göstermiştir.

Buna karşılık restored output başlığı, görsel kalite açısından hâlâ geliştirmeye açık bulunmuştur. Bu nedenle GAN fine-tune süreci restore çıktısını iyileştirmek için planlanmış, ancak OCR ve mask çıktılarının korunması için teacher distillation tabanlı koruma stratejisi tercih edilmiştir. Bu yaklaşım, mevcut güçlü çıktıları kaybetmeden zayıf başlığı geliştirmeyi amaçlamaktadır.

Genel olarak test ve hata ayıklama süreci sonucunda sistem daha kararlı, ölçülebilir ve geliştirilebilir hale gelmiştir. Nihai ürün tarafında TTM'nin tahta alanını ayırması, YGM'nin kullanıma uygun çıktı ve yazı maskesi üretmesi, sonrasında not üretim modüllerinin devreye girmesi başarılı bir şekilde gerçekleştirilmiştir.

6. SONUÇ

Board2Note projesi kapsamında yürütülen çalışma, sınıf ve amfi ortamlarında çekilen tahta görüntülerini yalnızca saklanan bir fotoğraf olmaktan çıkarıp okunabilir, işlenebilir ve düzenlenebilir dijital ders notlarına dönüştürmeyi amaçlayan bütünleşik bir yapay zekâ uygulamasına dönüştürmüştür. Proje sürecinde mobil uygulama, görüntü işleme, tahta alanı tespiti, yazı güçlendirme ve not yönetimi bileşenleri birlikte ele alınmış; bu bileşenlerin tek bir kullanıcı akışı içerisinde çalışması hedeflenmiştir.

Sonuç bölümünde, proje kapsamında geliştirilen sistemin genel başarımı değerlendirilmiştir. Bu kapsamda **TTM-V1**, **TTM-V2**, **YGM-V1**, **YGM-V2** ve **YGM-V3** modelleri; eğitim yaklaşımı, veri yapısı, üretilen çıktılar, nicel başarı değerleri ve sistemdeki kullanım amacı bakımından karşılaştırılmıştır.

Projede iki temel yapay zekâ bileşeni bulunmaktadır. **Birinci bileşen TTM, yani Tahta Tespit Modeli**'dir. TTM'nin görevi, görüntü içerisindeki tahta alanını ayırarak sonraki kırpma ve perspektif düzeltme adımlarına daha sağlıklı bir başlangıç sağlamaktır. **İkinci bileşen YGM, yani Yazı Güçlendirme Modeli**'dir. YGM'nin görevi ise tespit edilen veya kullanıcı tarafından seçilen tahta görüntüsünde yazıları daha belirgin hale getirmek, gölge ve kontrast problemlerini azaltmak, kullanıma uygun çıktı üretmek ve gerektiğinde yazı maskesi oluşturmaktır.

Elde edilen sonuçlar, Board2Note'un kapsamlı bir işlem hattı sunduğunu göstermektedir. Board2Note'ta görüntü önce tahta alanı tespiti, kırpma, perspektif düzeltme ve yazı güçlendirme adımlarından geçirilmekte; ardından not düzenleme sürecine aktarılmaktadır. Bu yaklaşım özellikle düşük ışık, gölge, parlama, silik yazı ve açılı çekim gibi gerçek sınıf ortamı problemlerinde daha kontrollü bir çözüm sunmaktadır.

6.1 Genel Sistem Değerlendirmesi

Board2Note sisteminin genel başarısı, yalnızca bir modelin doğruluk değerine bağlı değildir. Sistem, kullanıcıdan gelen ham görüntünün adım adım işlenmesi ve sonunda düzenlenebilir bir dijital nota dönüştürülmesi üzerine kuruludur. Bu nedenle sonuç değerlendirmesi yapılırken mobil uygulama akışı, tahta alanı belirleme, görüntü iyileştirme, metin düzenleme ve yerel not saklama adımlarının birlikte çalışması dikkate alınmıştır.

Mobil uygulama tarafında kullanıcı; kamera veya galeri üzerinden görüntü seçmekte, önizleme ekranında görseli kontrol etmekte, tahta alanını belirlemekte ve ardından not editörü ekranında not sonucunu düzenleyebilmektedir. Bu akış, karmaşık yapay zekâ ve görüntü işleme

adımlarını kullanıcı açısından sadeleştirmiştir. Kullanıcı teknik ayrıntılarla uğraşmadan, tek bir uygulama üzerinden tahta fotoğrafından not oluşturma sürecini tamamlayabilmektedir.

Model tarafında ise iki aşamalı bir yapı geliştirilmiştir. **TTM modelleri tahta alanını bulmaya odaklanırken, YGM modelleri görüntünün kalitesini artırmaya ve yazı bölgelerini belirginleştirmeye** odaklanmıştır. Bu ayrım, projenin teknik olarak daha yönetilebilir olmasını sağlamıştır. Çünkü tahta alanını bulma problemi ile yazıları temizleme ve güçlendirme problemi birbirinden farklı veri yapıları, kayıp fonksiyonları ve değerlendirme metrikleri gerektirmektedir.

Dosya tabanlı not saklama yaklaşımı da sistemin uygulanabilirliğini artırmıştır. Notların yerel olarak tutulması, proje kapsamında hızlı geliştirme, kolay test ve çevrimdışı kullanım açısından avantaj sağlamıştır.

Bileşen	Temel Görev	Geliştirilen Modeller / Çıktılar	Sonuçtaki Katkı
TTM	Tahta alanını tespit etmek	TTM-V1 LR-ASPP + MobileNetV3, TTM-V2 LR-ASPP + MobileNetV3 640 px	Kırpma, maskeleme ve perspektif düzeltme için daha doğru giriş sağlar.
YGM	Yazıları belirginleştirmek ve görüntüyü hazırlamak	YGM-V1 NAFNet-Small, YGM-V2 NAFNet-Base Multi-Head, YGM-V3 Multi-Head + GAN	Restored output, OCR output, text mask ve white canvas çıktıları üretir.
Not Editörü	Görüntüdeki yazıyı düzenlenebilir metne dönüştürmek	model çıktısı + kullanıcı düzenleme ekranı	Dijital not çıktısının ders notu formatında düzenlenmesine imkân verir.
Mobil Uygulama	Tüm süreci kullanıcıya sunmak	Kotlin, Jetpack Compose, Material 3, dosya tabanlı not yönetimi	Fotoğraf seçme, düzenleme, not oluşturma ve saklama akışını birleştirir.

Tablo 6.1. Board2Note sistem bileşenlerinin sonuç değerlendirmesindeki rolü

6.2 TTM ve YGM Test Çıktıları

6.2.1 TTM-V1: LR-ASPP + MobileNetV3-Large Tahta Tespit Modeli

TTM-V1 modeli, tahta alanının semantic segmentation yaklaşımıyla bulunması için geliştirilmiştir. Model mimarisi olarak torchvision tabanlı LR-ASPP + MobileNetV3-Large yapısı kullanılmıştır. Eğitim sürecinde A100 GPU ve full-RAM cache yaklaşımı tercih edilerek veri yükleme maliyeti azaltılmış, eğitim daha hızlı ve kararlı hale getirilmiştir.

Bu modelde Roboflow tabanlı iki farklı COCO formatlı veri seti birlikte kullanılmıştır. Veri dönüştürme aşamasında anotasyonlar maske formatına çevrilmiş ve eğitim/validasyon/test ayrımı korunmuştur. Eğitim setinde 6259, validasyon setinde 645 ve test setinde 500 örnek kullanılmıştır. Görüntüler 640 x 640 boyutuna getirilmiş, eğitimde batch size 48 olarak ayarlanmıştır.

TTM-V1'in en önemli sonucu, tahta alanını oldukça yüksek doğrulukla ayırabilmesidir. 40 epoch sonunda validasyon IoU değeri 0.9762, validasyon Dice değeri 0.9879 olarak ölçülmüştür. En iyi checkpoint test setinde değerlendirildiğinde IoU 0.9759, Dice 0.9878, precision 0.9870, recall 0.9887 ve pixel accuracy 0.9798 değerlerine ulaşılmıştır. Bu değerler, modelin tahta alanını hem eksik bırakmadan hem de fazla arka plan almadan belirleme konusunda başarılı olduğunu göstermektedir.

6.2.2 TTM-V2: Temizlenmiş Veri ve Dağıtımına Uygun TTM Sürümü

TTM-V2 modeli, TTM-V1 sonrasında daha temiz ve dağıtımına daha uygun bir model paketi oluşturmak amacıyla geliştirilmiştir. Bu sürümde yine MobileNetV3 tabanlı LR-ASPP mimarisi kullanılmış, giriş boyutu 640 piksel olarak korunmuştur. Model, üç farklı veri kaynağından oluşturulan bir veri havuzu ile eğitilmiştir.

TTM-V2'de eğitim tek aşamada bırakılmamış, Stage2 extra, Stage2 extra2 ve Stage3 polish gibi kademeli fine-tuning adımları uygulanmıştır. Bu yaklaşım sayesinde modelin maske sınırları ve genel segmentasyon kararlılığı iyileştirilmiştir. Son Stage3 polish aşamasında model loss değerini 0.0702'ye, IoU değerini 0.9633'e, Dice değerini 0.9798'e, precision değerini 0.9780'e ve recall değerini 0.9847'ye taşımıştır.

Final model paketi 12.47 MB alan kaplamaktadır. Bu durum, modelin mobil veya backend entegrasyonu açısından daha uygulanabilir olduğunu göstermektedir.

Model	Veri / Eğitim Yapısı	Temel Başarı Değerleri	Değerlendirme
TTM-V1	6259 train, 645 val, 500 test; 640 px; 40 epoch; A100 full-RAM cache	Test IoU: 0.9759; Dice: 0.9878; Precision: 0.9870; Recall: 0.9887; Pixel Acc: 0.9798	En yüksek segmentasyon başarımını veren TTM sürümüdür.
TTM-V2	2226 train, 278 val, 279 test; Stage2/Stage3 fine-tune; 640 px	IoU: 0.9633; Dice: 0.9798; Precision: 0.9780; Recall: 0.9847; Loss: 0.0702	Dağıtıma uygun final paketi üretmesi açısından entegrasyon yönü güçlüdür.

Tablo 6.2. TTM modellerinin eğitim ve test sonuçlarının karşılaştırılması



Şekil 6.1. TTM-V2 için örnek tahta tespit çıktısı: girdi görüntüsü, olasılık haritası, ikili maske ve görsel bindirme


6.2.3 YGM-V1: NAFNet-Small ile İlk Yazı Güçlendirme Yaklaşımı

YGM-V1 modeli, Board2Note'un yazı güçlendirme tarafındaki ilk kapsamlı derin öğrenme denemesidir. Model mimarisi olarak NAFNet-Small kullanılmıştır. Bu sürümde amaç, bozulmuş veya kalitesi düşük tahta görüntüsünü daha temiz bir hedef görüntüye dönüştürmektir. Eğitim **supervised restoration** mantığıyla yürütülmüş; L1, SSIM ve edge kayıpları birlikte kullanılmıştır.

YGM-V1 eğitiminde 5506 eğitim, 647 validasyon ve 325 test çifti kullanılmıştır. Model 40 epoch boyunca eğitilmiş ve her 5 epoch'ta bir validasyon çıktıları kaydedilmiştir. Eğitim sürecinde val_score değerinin 1. epoch'ta 0.49899 iken 40. epoch sonunda 0.04288'e gerilediği; val_psnr değerinin 13.34 dB'den 33.47 dB'ye yükseldiği görülmüştür. Bu durum modelin restorasyon görevini giderek daha başarılı şekilde öğrendiğini göstermektedir.

Test setinde modelin L1 değeri 0.0272, SSIM değeri 0.9877, PSNR değeri ise 33.46 dB olarak ölçülmüştür. Bu değerler YGM-V1'in piksel tabanlı restorasyon açısından oldukça başarılı olduğunu göstermektedir. Ancak bu sürüm yalnızca tek çıktı üreten bir restoration modeli olarak kalmış; OCR'ye özel çıktı, text mask veya white canvas üretimi gibi daha ileri

ürün ihtiyaçlarını doğrudan karşılamamıştır. Bu nedenle sonraki sürümlerde çok başlı model yapısına geçilmiştir.



Şekil 6.2. YGM-V1 modelinin 40. epoch validasyon çıktısı: giriş, hedef ve model çıktısı karşılaştırmaları

6.2.4 YGM-V2: NAFNet-Base Multi-Head Model


YGM-V2 modeli, YGM-V1'den farklı olarak yalnızca temiz görüntü üretmek için değil, Board2Note ürün akışında kullanılabilecek çok başlı çıktılar üretmek için geliştirilmiştir. Bu sürümde NAFNet-Base/64 tabanlı yaklaşık 116 milyon parametrelilik bir model kullanılmıştır. Modelin üç ana çıktısı bulunmaktadır: restored output, OCR'ye uygun enhanced output ve text mask output.

Veri seti olarak generated_multihead_dataset_v2.zip kullanılmıştır. Bu veri setinde her örnek için input, target_restored, target_ocr ve text_mask klasörleri bulunmaktadır. Eğitim bölmesinde 3920, validasyon bölmesinde 144 ve test bölmesinde 156 örnek yer almaktadır. Bu yapı sayesinde model aynı anda hem görüntü restorasyonu hem OCR hazırlığı hem de yazı maskesi üretimi görevlerini öğrenebilmiştir.


YGM-V2 eğitiminde Stage1 ve Stage2 olmak üzere denetimli iki aşamalı bir süreç uygulanmıştır. Stage1 sonunda model mask_iou değerini yaklaşık 0.59 seviyesine çıkarmış, Stage2 sonunda ise test değerlendirmesinde restored L1 0.0659, OCR L1 0.0684, restored PSNR 18.09 dB, OCR PSNR 17.92 dB ve mask IoU 0.5828 değerleri elde edilmiştir. Test seti

üzerinde OCR SSIM 0.1365, restored SSIM 0.1272, mask Dice 0.7196 ve composite score 0.7406 değerleri görülmüştür.

YGM-V2'nin en önemli katkısı, projenin ürün hedeflerine daha uygun bir çıktı yapısı sağlamasıdır. YGM-V1 metrik olarak yüksek restorasyon değerleri üretse de yalnızca tek çıkışıdır. YGM-V2 ise OCR'ye yönelik görüntü, yazı maskesi ve restore edilmiş görüntüyü birlikte üretebildiği için Board2Note'un not üretme hattına daha yakın bir model haline gelmiştir.



Şekil 6.3. YGM-V2 gerçek test görüntüsü üzerinde çok başlı model çıktısı



Şekil 6.4. YGM-V2 multi-head final test preview çıktısı: restored output, OCR output ve text mask çıktılarının birlikte gösterimi

6.2.5 YGM-V3: Denetimli + Denetimsiz GAN Destekli Final Modeli

YGM-V3 modeli, YGM-V2'nin çok başlı yapısını koruyarak yazı güçlendirme kalitesini artırmak için geliştirilmiştir. Bu sürümde yine yaklaşık 116 milyon parametrelili NAFNet multi-head üretici kullanılmış; buna ek olarak denetimsiz adversarial fine-tune aşamasında PatchGAN discriminator eklenmiştir. Eğitim süreci Stage1, Stage2 ve Stage3-GAN olmak üzere üç ana aşamada yürütülmüştür.

YGM-V3'ün amacı yalnızca piksel hatasını azaltmak değildir. Modelin özellikle OCR'ye verilecek görüntüde yazıların daha keskin, kontrastlı ve okunabilir hale gelmesi hedeflenmiştir. Bu nedenle GAN aşamasında LSGAN adversarial kaybı, feature matching, hafif denetimli çapa ve spectral normalization kullanılmıştır. Üretici tarafta EMA uygulanarak daha kararlı ağırlıklar tutulmuştur.


Final test sonuçları YGM-V3'ün özellikle OCR output tarafında belirgin bir sıçrama sağladığını göstermektedir. YGM-V2 ile karşılaştırıldığında OCR PSNR değeri 17.92 dB'den 24.81 dB'ye, OCR SSIM değeri 0.1537'den 0.5082'ye, OCR MS-SSIM değeri 0.4457'den 0.7888'e yükselmiştir. Restored PSNR değeri de 18.09 dB'den 20.97 dB'ye çıkmıştır. Text mask tarafında Dice/F1 değeri 0.7159, Boundary-F1 değeri 0.9712 ve mask accuracy değeri 0.9914 olarak ölçülmüştür.

Bu sonuçlar, YGM-V3'ün final yazı güçlendirme modeli olarak seçilmesini teknik açıdan desteklemektedir. Çünkü Board2Note için asıl hedef yalnızca görsel olarak temiz bir tahta üretmek değil, kullanıma daha uygun ve yazıları daha belirgin bir çıktı oluşturmaktır. YGM-V3, denetimli aşamanın öğrenmiş olduğu yapısal temeli GAN aşamasıyla rafine ederek OCR output kalitesinde büyük iyileşme sağlamıştır.


YGM Modeli	Model Yapısı	Veri / Çıktı Yapısı	Öne Çıkan Sonuçlar	Genel Değerlendirme
YGM-V1	NAFNet-Small, tek çıkışlı supervised restoration	5506 train, 647 val, 325 test; input-target çiftleri	Test PSNR: 33.46 dB; SSIM: 0.9877; L1: 0.0272	Restorasyon metrikleri çok güçlüdür; ancak OCR output ve text mask üretmez.
YGM-V2	NAFNet-Base Multi-Head, 116M parametre	3920 train, 144 val, 156 test; restored + OCR + mask	OCR PSNR: 17.92 dB; mask IoU: 0.5828; mask Dice: 0.7196	Ürün akışına uygun çok başlı çıktı yapısı sağlamıştır.

YGM-V3	NAFNet Multi-Head + Stage3 GAN	Aynı multi-head veri seti; denetimli + denetimsiz aşama	OCR PSNR: 24.81 dB; OCR SSIM: 0.5082; mask Dice: 0.7159; canvas SSIM: 0.9767	OCR'ye uygun çıktı kalitesi belirgin biçimde arttığı için final YGM adayıdır.
--------	--------------------------------	---	--	---

Tablo 6.3. YGM modellerinin sonuçlarının karşılaştırılması



Şekil 6.5. YGM-V3 eğitim eğrileri: score, OCR PSNR, OCR SSIM ve mask IoU değerlerinin aşamalara göre değişimi




Şekil 6.6. YGM-V3 stage karşılaştırması: baseline, Stage1, Stage2 ve Stage3-GAN metriklerinin karşılaştırmalı görünümü

Metrik	YGM-V2	YGM-V3	Değişim
OCR PSNR	17.9198 dB	24.8143 dB	+6.8946 dB
OCR SSIM	0.1537	0.5082	+0.3545
OCR MS-SSIM	0.4457	0.7888	+0.3432
Restored PSNR	18.0867 dB	20.9711 dB	+2.8844 dB
Mask Dice/F1	0.7196	0.7159	-0.0037
Boundary-F1	0.9709	0.9712	+0.0003
White Canvas PSNR	30.7433 dB	30.8369 dB	+0.0936 dB
White Canvas SSIM	0.9767	0.9767	Yaklaşık aynı


Tablo 6.4. YGM-V2 ve YGM-V3 modellerinin test seti üzerindeki karşılaştırması



Şekil 6.7. YGM-V3 gerçek görüntü üzerinde inference çıktısı



Şekil 6.8. YGM-V3 için ikinci gerçek görüntü inference çıktısı



Şekil 6.9. YGM-V3 nitel test grid çıktısı: input, restored, OCR enhanced, text mask ve white canvas karşılaştırması

6.2.6 Modellerin Genel Sonuç Yorumu ve Final Kullanım Değerlendirmesi

TTM tarafında iki model de tahta alanı tespiti için kullanılabilir sonuçlar üretmiştir. TTM-V1, test IoU ve Dice değerleri bakımından en yüksek segmentasyon başarımını göstermiştir. Buna karşılık TTM-V2, final model paketi dağıtım ve entegrasyon tarafında daha pratik bir sürüm olarak öne çıkmıştır. Bu nedenle TTM tarafında nihai seçim yapılırken yalnızca en yüksek metrik değil, modelin mobil/backend çalışma zamanına aktarılabilirliği de dikkate alınmıştır.

YGM tarafında ise model seçimi daha açıktır. YGM-V1, klasik restorasyon metriklerinde çok güçlü görünmektedir; ancak Board2Note'un ihtiyaç duyduğu çok başlı çıktı

yapısını sunmamaktadır. YGM-V2 bu eksikliği gidererek restored output, OCR output ve text mask üretmiştir. YGM-V3 ise bu çok başlı yapıyı koruyarak GAN destekli ince ayar sayesinde OCR output kalitesini önemli ölçüde artırmıştır. Bu nedenle final yazı güçlendirme modeli için YGM-V3 daha uygun görünmektedir.

Özellikle OCR PSNR ve OCR SSIM değerlerindeki artış, YGM-V3'ün Board2Note'un ana hedefiyle doğrudan uyumlu olduğunu göstermektedir. Çünkü kullanıcı için nihai değer, görüntünün yalnızca temiz görünmesi değil; yazıların insan okuması açısından daha belirgin hale gelmesidir. YGM-V3, bu ihtiyaca en yakın sonucu veren model olarak değerlendirilmiştir.

6.3 Mobil Uygulama ve Not Çıktısı Örnekleri


Board2Note'un kullanıcıya sunduğu temel çıktı, işlenmiş tahta görüntüsünden üretilen düzenlenebilir dijital nottur. Kullanıcı mobil uygulama üzerinden görüntüyü seçtikten sonra sistem, tahta alanı seçimi, görüntü işleme, model tabanlı iyileştirme ve not editörü adımlarını takip etmektedir. Bu akış sonucunda kullanıcı yalnızca bir görüntü dosyası değil, düzenlenebilen ve saklanabilen bir ders notu elde etmektedir.

Mobil uygulama tarafında geliştirilen ekranlar, model çıktılarının kullanıcı tarafından anlaşılabilir bir deneyime dönüşmesini sağlamaktadır. Görsel önizleme ekranı kullanıcıya seçilen fotoğrafı kontrol etme imkânı verirken, tahta alanı seçim ekranı hatalı kırpma ihtimalini azaltmaktadır. Not editörü ekranı ise model işlemleri sonucundaki olası hataların kullanıcı tarafından düzeltilmesine olanak tanımaktadır.


Notların ders adına göre gruplanması, uygulamanın yalnızca tek seferlik bir dönüştürme aracı olmasını engellemiştir. Kullanıcı oluşturduğu notları daha sonra tekrar görüntüleyebilmekte, silebilmekte veya düzenleyebilmektedir. Bu yapı, Board2Note'u bir görüntü işleme demosu olmaktan çıkarıp gerçek öğrenci kullanım senaryosuna yaklaşan bir mobil not yönetim sistemine dönüştürmektedir.

Tahta Fotoğrafı Eklendiğinde Canvas Ekranına Yansıyan Dijital Not Örneği

Şekil 6.10'da test amacıyla kullanılan orijinal tahta görüntüsü gösterilmektedir. Bu görüntü gerçek sınıf ortamında çekilmiş olup; geniş tahta alanı, ortam ışığı, yansıma, uzak mesafe, arka plan nesneleri ve tahta üzerindeki dağınık yazılar gibi gerçek kullanım koşullarını içermektedir. Bu nedenle görsel, Board2Note'un yalnızca ideal koşullarda değil, gerçek derslik ortamlarında çekilen görüntüler üzerinde de çalışabilirliğini göstermek amacıyla kullanılmıştır.



Şekil 6.10. Orijinal Tahta Görüntüsü



Şekil 6.11. Canvas Editör Ekranına Tahta Görüntüsünün Eklenmiş Hali

6.4 Genel Kazanımlar ve Geliştirme Alanları

Proje sürecinde elde edilen en önemli kazanım, tahta görüntüsünden dijital not üretimine kadar uzanan uçtan uca bir sistemin tasarlanması ve çalışan bileşenler halinde geliştirilmesidir. Bu süreçte yalnızca mobil arayüz değil; veri seti hazırlama, model eğitimi, model karşılaştırması, çıktı analizi, OCR hazırlığı ve not yönetimi birlikte ele alınmıştır.

- Tahta alanını tespit etmek için TTM-V1 ve TTM-V2 modelleri geliştirilmiş ve yüksek segmentasyon başarımı elde edilmiştir.
- Yazı güçlendirme tarafında YGM-V1 ile güçlü bir supervised restoration temeli oluşturulmuştur.
- YGM-V2 ile restored output, OCR output ve text mask üreten çok başlı model yapısına geçilmiştir.
- YGM-V3 ile denetimli + denetimsiz GAN yaklaşımı uygulanmış ve OCR output kalitesi belirgin biçimde artırılmıştır.
- YGM-V3 karşılaştırmasında OCR PSNR değeri YGM-V2'ye göre yaklaşık 6.9 dB artmış, OCR SSIM değeri ise 0.1537'den 0.5082'ye yükselmiştir.
- Text mask çıktısı sayesinde ileride yazıları beyaz sayfa üzerine taşıyan görsel not üretimi için teknik temel oluşturulmuştur.
- Mobil uygulama tarafında kullanıcıyı adım adım yönlendiren görsel seçimi, önizleme, tahta alanı seçimi, not editörü ve not yönetimi ekranları geliştirilmiştir.
- Dosya tabanlı yerel depolama ile notların derslere göre saklanması ve yönetilmesi sağlanmıştır.

Bununla birlikte proje geliştirmeye açık bir yapıya sahiptir. Özellikle gerçek sınıf görüntülerinin sayısının artırılması, sentetik veri ile gerçek veri arasındaki farkın azaltılması ve model çıktılarının mobil cihaz üzerinde daha hızlı çalışacak şekilde optimize edilmesi sonraki aşamalar için önemlidir.

- TTM ve YGM modelleri daha fazla gerçek sınıf, amfi ve farklı tahta türü içeren veri setleriyle yeniden eğitilebilir.
- YGM-V3 modeli gerçek tahta görüntüleriyle fine-tune edilerek sentetik veri kaynaklı olası genelleme problemleri azaltılabilir ve modelin gerçek sınıf ortamlarındaki başarımı artırılabilir.
- TTM-V2 ve YGM-V3 modelleri ONNX, TensorRT veya TFLite gibi formatlara dönüştürülerek mobil ve backend çalışma zamanlarında hızlandırılabilir.

6.5 Genel Sonuç

Sonuç olarak Board2Note projesi, tahta görüntülerini yalnızca fotoğraf olarak saklamak yerine bu görüntüleri işleyerek okunabilir ve düzenlenebilir dijital notlara dönüştüren yapay zekâ destekli bir mobil sistem ortaya koymuştur. Projede geliştirilen TTM modelleri, tahta alanının belirlenmesi probleminde yüksek başarı sağlamış; YGM modelleri ise görüntü iyileştirme ve yazı güçlendirme probleminde kademeli olarak daha gelişmiş çözümler sunmuştur.

Model geliştirme süreci incelendiğinde, TTM-V1'in çok yüksek segmentasyon metrikleriyle güçlü bir başlangıç oluşturduğu, TTM-V2'nin ise dağıtım ve inference paketlemeye daha uygun bir sürüm sağladığı görülmektedir. YGM tarafında YGM-V1 restorasyon kalitesini kanıtlamış, YGM-V2 ürün akışına uygun çok başlı yapıyı kurmuş, YGM-V3 ise GAN destekli denetimsiz aşama ile OCR output kalitesinde en belirgin iyileşmeyi sağlamıştır.

Bu nedenle projenin ulaştığı nokta, yalnızca akademik bir model eğitimi denemesi değildir. Board2Note; veri hazırlama, model eğitimi, model çıktıların karşılaştırılması, mobil uygulama entegrasyonu ve not yönetimi bileşenlerini bir araya getiren uygulanabilir bir eğitim teknolojisi prototipidir.

Genel değerlendirme olarak Board2Note, öğrencilerin ders sırasında çektiği düşük kaliteli tahta fotoğraflarını daha düzenli, okunabilir ve yönetilebilir ders notlarına dönüştürme hedefi doğrultusunda başarılı bir temel ortaya koymuştur. TTM, YGM ve mobil not editörü bileşenlerinin birlikte çalışması, projenin klasik belge tarama uygulamalarının ötesine geçen bütünsel bir çözüm olduğunu göstermektedir.

6.6 Projemizin Github ve Drive Linkleri

Github dosya boyutu kuralları sebebiyle modeller ve ek proje parçaları Google Drive'a yüklenmiştir.

- Github Linki:
<https://github.com/SametUnv/B2n>
- Google Drive Linki:
<https://drive.google.com/drive/folders/19kvYnjinWFHGO4WquNeajakTeKwiAR3QL?usp=sharing>

7. KAYNAKLAR

Roboflow Annotate: <https://roboflow.com/annotate> [Eriřim Tarihi: 23.04.2025]

B2N_1 Roboflow Dataset: https://app.roboflow.com/samets-workspace-4soa9/b2n_1-nktgm/train [Eriřim Tarihi: 25.04.2025]

B2N_2 Roboflow Dataset: https://app.roboflow.com/samets-workspace-4soa9/b2n_2/train [Eriřim Tarihi: 27.04.2025]

WB_Seg-2 Whiteboard Segmentation Dataset: https://universe.roboflow.com/ai-t9wnl/wb_seg-2 [Eriřim Tarihi: 29.04.2025]

Whiteboard Dataset: <https://universe.roboflow.com/piyushs-workspace-l3qcp/whiteboard-52kh3> [Eriřim Tarihi: 02.05.2025]

Whiteboards Detection Dataset: <https://universe.roboflow.com/project1-yhtxz/whiteboards-detection-utuuv> [Eriřim Tarihi: 05.05.2025]

Google Colaboratory: <https://developers.google.com/colab> [Eriřim Tarihi: 08.05.2025]

IAM Handwriting Word Database: <https://www.kaggle.com/datasets/nibinv23/iam-handwriting-word-database> [Eriřim Tarihi: 11.05.2025]

MobileNetV3 PyTorch Implementation: <https://github.com/d-li14/mobilenetv3.pytorch> [Eriřim Tarihi: 14.05.2025]

NAFNet: <https://github.com/megvii-research/NAFNet> [Eriřim Tarihi: 17.05.2025]

Patch-Based Image Inpainting with Generative Adversarial Networks: <https://arxiv.org/abs/1803.07422> [Eriřim Tarihi: 20.05.2025]

Generative Adversarial Networks GANs Türkçe: <https://medium.com/teknopar-akademi/generative-adversarial-networks-gans-t%C3%BCrk%C3%A7e-8eedeee7e2ae> [Eriřim Tarihi: 23.05.2025]

Qwen2.5-VL Technical Report: <https://arxiv.org/abs/2502.13923> [Eriřim Tarihi: 26.05.2025]

Compose Multiplatform: <https://kotlinlang.org/compose-multiplatform/> [Eriřim Tarihi: 30.05.2025]

FastAPI: <https://github.com/fastapi> [Eriřim Tarihi: 01.06.2025]