

Beyaz Tahtadan Yazı Tespiti Board2Note

Ekip Bilgileri

1221602035 – Samet Ünver
1221602013– Hilal Kaynar
1221602038 – Batuhan Güneysu
1221602040 – Taha Demir
1231602808– Halit Eren Deniz

Danışman

Dr. Öğr. Üyesi Turgut Doğan

Sunum Başlıkları

1

PROJENİN GİRİŞİ VE TANITIMI

2

PROJENİN AMACI

3

TAHTA TESPİTİ PROBLEMİ TANIMI VE ÇÖZÜMÜ

4

YAZI TESPİTİ PROBLEMİ TANIMI VE ÇÖZÜMÜ

5

EĞİTİM STRATEJİLERİ VE VERİ SETLERİ

6

MODELLERİMİZ VE SONUÇLAR

7

AKILLI NOT UYGULAMASI: BOARD2NOTE

PROJENİN GİRİŞİ VE TANITIMI

Beyaz Tahtadan Yazı Tespiti



- Projemizdeki temel amacımız eğitim hayatında sıkça karşılaştığımız ve çözüm olarak birçok farklı yöntem ve yol izlediğimiz tahtadan not alma problemine çözüm aranmaktadır.
- Hedefimiz öğrencilerin eğitim ve ders süreçlerinde öğretmenlerin tahtaya yazdıklarını kolay bir biçimde not olarak elde edebilmeleri ve bunu tek bir çaba ile gerçekleştirmeleridir.
- Amacımız derslerde öğretmenin not aldığı beyaz tahtayı birebir olarak öğrencilerin notlarına/defterlerine taşımaktır.


Projenin Temel Amacı

Veri Yapıları ve Algoritmalar 20.05.2024

1) Yığın (Stack)

- Son Giren İlk Çıkar (LIFO)
- Dinamik bir veri yapısıdır.
- Ekleme ve çıkarma işlemleri yığının tepesinden (top) yapılır.
- Temel işlemler: push, pop, peek, isEmpty


Örnek:
Parantez kontrolü, geri alma (undo) işlemleri, fonksiyon çağrıları

top → 

2) Karmaşıklık (Big-O)

- Algoritmanın giriş boyutuna (n) göre çalışma süresinin üst sınırını ifade eder.
- Yaygın gösterimler:
 $O(1) < O(\log n) < O(n) < O(n \log n) < O(n^2) < O(2^n) < O(n!)$
Daha iyi → Daha kötü
- Örnekler:
 $T(n) = 3n^2 + 2n + 1 \Rightarrow O(n^2)$
 $T(n) = 5 \log n + 20 \Rightarrow O(\log n)$

Not: Bir algoritmayı değerlendirirken sadece doğruluğu değil, zaman ve bellek karmaşıklığını da göz önünde bulundurmalıyız.




Veri Yapıları ve Algoritmalar 20.05.2024

1 Yığın (Stack)

- Son Giren İlk Çıkar (LIFO)
- Dinamik bir veri yapısıdır.
- Ekleme ve çıkarma işlemleri yığının tepesinden (top) yapılır.
- Temel işlemler: push, pop, peek, isEmpty

Örnek:
Parantez kontrolü, geri alma (undo) işlemleri, fonksiyon çağrıları

top → 

2 Karmaşıklık (Big-O)

- Algoritmanın giriş boyutuna (n) göre çalışma süresinin üst sınırını ifade eder.
- Yaygın gösterimler:
 $O(1) < O(\log n) < O(n) < O(n \log n) < O(n^2) < O(2^n) < O(n!)$
Daha iyi → Daha kötü
- Örnekler:
 $T(n) = 3n^2 + 2n + 1 \Rightarrow O(n^2)$
 $T(n) = 5 \log n + 20 \Rightarrow O(\log n)$


Tahtaya Yazılan Ders Notu

Tahtadan Elde Edilen Ders Notu


- Projemizin temel amacı, tahta üzerindeki yazıların tespit edilip kullanıcıların(öğrencilerin) ilgili ders notunu kolaylıkla dijital hale getirmelerini sağlamaktır.
- Projemiz; CamScanner gibi geleneksel tarama uygulamalarının ötesine geçerek tahtadaki yazıları doğrudan kullanıcının notuna entegre etmeyi amaçlar. Bu sayede çekim sonrası düzenleme veya aktarma gibi manuel işlem süreçlerini tamamen ortadan kaldırır.

Tahtadan Dijital Not Sürecinin Zorlukları


Tahtadaki yazıların tamamen dijital hale getirilmesi sürecinde birçok farklı zorluk ve problem karşımıza çıkmaktadır;




Tahta Parlamaları: Tahtanın ufak açılı farklılıkları sebebiyle belirli bir alanının parlak ve görünmez hale gelmesi durumu.



Değişken Işık ve Gölgeler: Homojen olmayan ışık dağılımı sebebiyle algoritmaların tamamen işlevsiz kalması.




Tahta Dışı Arka Planlar: Öğrenci tarafından çekilen amatör tahta görüntüsünün birçok farklı alan ve eşya içeriyor olması.




Sonsuz Sayıda Tahta: Görüntülerdeki tahtaların içeriğinde yazı, çizim ve şema gibi alanların bile sorunsuz tespit edilebilmesi.

Projemizde Kullandığımız Teknolojiler ve Araçlar



Geliştirme Dili: Python; Hızlı prototipleme ve Kotlin tarafına arkauç (backend) olarak tercih edilmiştir.



Yapay Zeka Mimarisi: MobileNet-Lars PP ve NAFNet modelleri eğitim sürecinde kullanılmıştır.



Görüntü İşleme Motoru: OpenCV; Endüstri standardı, gürültü azaltma, perspektif düzeltme gibi işlemleri milisaniyeler içinde gerçekleştirme yeteneği.



Arayüz: Kotlin; Modern, güncel ve kullanıcı dostu aynı zamanda native not alma deneyimi sunması amacıyla tercih edilmiştir.



Yapay Zeka Çatısı: PyTorch & TensorFlow; Araştırma ve eğitim sürecinde tüm freameworkler kullanılmıştır.



Eğitim Platformu: Google Colab; Yüksek performanslı GPU'lara (Tesla T4/A100) erişimle model eğitimi yapılmıştır.


PROBLEM-1

TAHTANIN TESPİTİ

Görüntü Üzerinden Tahtanın Tespit Edilmesi

Kullanıcıların amatör ve dikkat etmeden çektikleri beyaz tahta içerikli görsellerin içinden öncelikle tahtanın tespiti gerçekleştirilmelidir.

Tahta tespitindeki zorluklar:




Karmaşık Arka Planlar: Belgeler nadiren temiz bir yüzeyde bulunur, bu da **sınır tespitini zorlaştırır**.



Değişken Işık ve Gölgeler: Dengesiz aydınlatma, yerel **kontrast kaybına** ve **veri kaybına** yol açar.




Performans ve Erişilebilirlik: Çözümlerin özellikle mobil kullanıcılar için **hafif** ve **verimli** çalışması kritik önem taşır.



Farklı Açı ve Boyutlar: Görüntünün **farklı** boyutlardaki **sınıflarda** ve **sınıfın farklı konumlarından** elde edilmesi sebebiyle oluşan **açı**, **yön** ve **boyut** farklılıkları.




Görüntü Üzerinden Tahtanın Tespit Edilmesi




Model, giriş görüntüsü içerisinde yer alan tahta veya projeksiyon yüzeyini piksel seviyesinde tespit etmektedir. Model, görüntünün tamamını değerlendirerek hangi bölgelerin tahta alanına ait olduğunu belirleyen bir segmentasyon maskesi üretir.

Modelin çıktısı doğrudan bir sınıflandırma sonucu değildir; yani “bu görüntüde tahta var/yok” demek yerine, görüntü üzerinde tahtanın hangi piksellerden oluştuğunu gösteren bir maske üretir. Bu maske daha sonra crop alma, perspektif düzeltme ve ikinci modele uygun giriş görüntüsü hazırlama amacıyla kullanılmaktadır.



Kullanılan Model: MobileNetV3 + LR-ASPP

Tahta tespiti için MobileNetV3-Large omurgasına sahip LR-ASPP tabanlı bir semantik segmentasyon modeli tercih edilmiştir. Bu yapı, özellikle mobil ve gerçek zamanlı sistemlerde verimli çalışabilmesi nedeniyle projeye uygun görülmüştür.



MobileNetV3-Large, görüntüden anlamlı özellikleri çıkaran hafif ve optimize edilmiş bir backbone görevi görür. LR-ASPP yapısı ise bu özellikleri kullanarak tahta bölgesine ait segmentasyon maskesini üretir.




Gerçek Zamanlı
Düşük gecikme,
yüksek hız



Hafif
Düşük parametre,
yüksek verimlilik

Model Mimarisi


MobileNetV3 Omurgası (Backbone)



Encoder (Kodlayıcı) Bölümü:

Hızlı ve hafif: Mobil cihazlar ve CPU üzerinde optimum performans sağlamaktadır.


LARS-PP (Head)



Decoder (Kod Çözücü) Bölümü:


Piksel düzeyinde hassasiyet: Açı ve boyut farklarına rağmen yüksek başarılı sonuçlar elde edilir.

Semantic Segmentation VS Instance Segmentation



Semantic Segmentation

- Bir görüntüdeki her piksele bir sınıf etiketi verir. Örneğin: piksel ya "document" ya da "background" olur.
- Aynı sınıftan birden fazla nesne varsa (iki farklı kağıt gibi) semantic segmentation bunları tek sınıf olarak boyar, "kaç tane" olduğunu ayırmak zorunda değildir.




Instance Segmentation

- Yine her pikseli segmentler ama ek olarak aynı sınıfa ait nesneleri tek tek ayırır (instance id verir).
Örneğin iki kağıt varsa:
"document_1" maskesi ayrı,
"document_2" maskesi ayrı çıkar.

Neden Semantic Segmentation

Tahtanın tespitindeki amaç ilgili görüntü üzerinden sadece beyaz tahtayı segmente edip sonrasında harici tüm sınıfları(tahta harici alanlar) arka plan olarak işleme almaktır.




- Bu hedeflere uygun olarak **semantic segmentation**'un ilgili görüntü üzerinde tek bir belgeyi segmentasyon ile ortaya çıkarması ve **maskelemesi** amacımıza uygun bulunmuştur.
- Buna ek olarak Semantic Segmentation yapan modeller hedef platform olan **mobil cihazlara** daha uygun bir çalışma sergilemekle beraber çok daha hızlı sonuç vermektedir.

- Semantic Segmentation'da ilgili görüntüde **tek sınıf kullanılarak** yani ilgili piksel beyaz tahtadır ya da arka plandır şeklinde bir çalışma olduğundan yine temel seçim nedenlerindendir.

1. Model Eğitimi: Veri Setleri

Tahta segmentasyonunu yapacak olan MobileNetV3 modelimizin ilk test eğitimi için ciddi büyüklükteki hazır veri setine başvurulmuştur. Bu veri seti ile beraber modelin yapılacak olan eğitime uyumluluğu tespit edilmeye çalışılmıştır.



Yaklaşık 7000 görüntü içeren hazır bir veri seti kullanılmış olup aynı zamanda kendi elde ettiğimiz küçük bir veri seti eğitimde kullanılmıştır.

Veri setinin ciddi kısmının hazır alınması ile beraber aynı zamanda kendi veri setimizinde dahil edilmesi ile veri setimizin eğitime uygun olup olmadığının kontrol edilmesi amaçlanmıştır.

Kullanılan Veri Setleri

new-dataset-xjgtk (new_dataset_xjgtk_v12_coco)

- Sınıf ve derslik ortamlarında yer alan beyaz tahta ve el yazısı alanlarını içeren, modelin yazı tahtası segmentasyonu performansını ve genelleştirme yeteneğini en üst düzeye çıkarmak için kullanılan büyük ölçekli ana veri seti

Semantic Segmentation

Train: 6061 | Valid: 589 | Test: 472




b2n_1-nktgm (Kendi Veri Setimiz)

- Sınıf ve amfi fotoğraflarındaki yazı tahtası/projeksiyon alanlarını içeren, projeye özel olarak hazırlanmış ve ana eğitimi desteklemek amacıyla entegre edilen yerel/özel yardımcı veri seti

Semantic Segmentation

Train: 198 | Valid: 56 | Test: 28


Hazır Veri Seti İçeriği




B2N Tahta Tespit Modeli - TTM-v1

B2N TTM-v1

Girdi Boyutu:	640x640
Batch-BE/Epoch:	48 / 48 / 40
Optimizer:	AdamW (Fused, A100)
Loss Fonksiyonu:	Cross Entropy + Dice Loss + Focal Loss
Çıktı Aktivasyonu:	Softmax (Threshold: 0.50)
Augmentation:	Yatay çevirme, rastgele scale-crop, parlaklık/kontrast, hafif blur, noise



image



Pred green

Performans: Bu model 40 epoch'luk eğitim sürecinin son epoch'unda en iyi sonucu vermiştir.

Val IoU: 0.9762 | Val Dice: 0.9879 | Val Loss: 0.0906

Test IoU: 0.9759 | Test Dice: 0.9878


Precision: 0.9870 | Recall: 0.9887

Loss: 0.1048



Sonuçlar:

Bu model, MobileNetV3-Large tabanlı LR-ASPP mimarisi ile tahta/projeksiyon alanını segmente etmek için eğitilmiştir. Projemizin ilk aşamalarında hazır veri setleri ile beraber eğitim sonuçlarının incelenmesi ve ilk ürün seviyesi model olarak eğitilmiştir. Özellikle büyük veri seti, 640x640 giriş boyutu ve birleşik loss fonksiyonu sayesinde tahta sınırlarını başarılı bir şekilde öğrenmiştir. Ancak veri setinin problemimize uygun olmayan görüntüler içermesi sebebiyle 2. modele uygun bulunmamıştır.

Hazır Veri Seti Problemleri



Tahtanın önüne geçmiş
insan




Projeksiyonun kapladığı
beyaz tahta




Kendi Veri Setimizin Oluřturulması

Modelimizin eęitimin ok daha gereki ve aynı zamanda daha farklı kořullara adapte(robust) bir model olabilmesi iin kk, orta ve byk birok farklı sınıfta; saę-sol, yakın-uzak gibi elde edilmiř tahta grntlerinde bile doęru tespit yapabilmesi amalanmıřtır.

Bu amaca uygun bir biimde okulumuz iinde birok farklı sınıf, amfi ve yksek lisans sınıfı ierisinden dolu-boř tahta grnts toplanmıřtır.






Elde edilen grntler veri seti n iřleme ve Label iřlemleri iin RoboFlow Annotate uygulaması ile beraber Semantic Segmentation amacıyla 1. modeliniz olan MobileNet modelinin eęitimi iin uygun hale getirilmiřtir.



Veri Setimizin İşlenmemiş Görüntüleri



Derslik



Veri Setimizin İşlenmemiş Görüntüleri







Yüksek Lisans Dersliği



Veri Setimizin İşlenmemiş Görüntüleri





Amfi



Veri Setimizin İşlenmemiş Görüntüleri





Amfi



Veri Setimiz: B2N_1

Veri setimiz RoboFlow üzerinde B2N_1 adı ile WhiteBoard sınıfı Semantic Segmantation türünde orta ölçekte bir veri seti olarak konumlanmıştır.



B2N_1 Veri Seti:
Tür: Semantic Segmentation
Sınıf: WhiteBoard
Toplam Boyut: 493 Görüntü
Çözünürlük: 640x640

TRAIN SET

78%

385 Images

VALID SET

15%

75 Images

TEST SET

7%

33 Images

Eğitimde Kullanılan Veri Setleri

Birinci modelin eğitimi için hem kendi hazırladığımız veri seti hem de ek açık kaynak whiteboard veri setleri kullanılmıştır. Kendi veri setimizde sınıf ve tahta görüntüleri etiketlenerek tahta alanlarının segmentasyon maskeleri oluşturulmuştur. Bu veri seti yaklaşık 500 görüntüye ulaştırılmıştır.

Ek olarak farklı ortam, açı, ışık ve tahta tiplerini modele gösterebilmek için Roboflow üzerinde yer alan public whiteboard veri setlerinden de yararlanılmıştır.

Eğittiğimiz modelin yalnızca bizim veri setimize ezber gitmesi yerine farklı sınıf ortamlarına ve farklı tahta görünümüne karşı daha dayanıklı hale getirilmeye çalışılmıştır.



Kullanılan Veri Setleri

b2n_1-nktgm (KENDİ ÜRETTİĞİMİZ VERİ SETİ)

- Sınıf ve amfi fotoğraflarındaki yazı tahtası/projeksiyon alanlarını içeren, projede en yüksek ağırlığa sahip zorunlu ana veri seti

Semantic Segmentation

Train: 385 | Valid: 75 | Test: 33

whiteboard1-isweb (whiteboard1_isweb_v3_public)

- Modelin genel tahta tespiti performansını ve genelleştirme yeteneğini artırmak amacıyla kullanılan açık kaynaklı kamu veri seti

Semantic Segmentation

Train: 818 | Valid: 234 | Test: 116

whiteboard-52kh3-6yn2d (whiteboard_52kh3_v1_forked)

- Veri çeşitliliğini artırmak ve eğitimi desteklemek amacıyla Roboflow üzerinden çatallanarak projeye dahil edilen yardımcı veri seti

Semantic Segmentation

Train: 785 | Valid: 224 | Test: 113

B2N Tahta Tespit Modeli - TTM-v2

B2N TTM-v2

Girdi Boyutu:	640x640
Batch-BE/Epoch:	64 / 128 / 75
Optimizer:	AdamW
Loss Fonksiyonu:	BCE with Logits Loss + Dice Loss + Edge Loss
Çıktı Aktivasyonu:	Sigmoid (Threshold: 0.50)
Augmentation:	Yatay çevirme, affine, perspective, parlaklık/kontrast, HSV, golge, blur, noise, JPEG artifact



Performans: Final model, 75 epoch'luk kademeli eğitim sürecinin sonunda en iyi sonucu vermiştir.

Val IoU: 0.9633 | Val Dice: 0.9798



Precision: 0.9780 | Recall: 0.9847

Loss: 0.0702



Sonuçlar:

Bu model, önceki modele göre gerçek dünya verilerinde daha iyi sonuçlar elde etmiştir. MobileNetV3-Large + LR-ASPP mimarisiyle tahta/projeksiyon alanını daha net ayırabilmiş ve yüksek başarılı maske üretmiştir. Özellikle kenar bölgelerinde daha başarılı sonuçlar alınmıştır. Veri seti arasına gerçek dünya yani kendi veri setimizin eklenmesi sebebiyle sayısal başarı metriklerinde ufak bir düşüş gözlemlenmiştir.



B2N Tahta Tespit Modeli - TTM-v2



B2N Tahta Tespit Modeli - TTM-v2



B2N Tahta Tespit Modeli - TTM-v2




PROBLEM-2


TAHTADAKİ YAZILARIN TESPİTİ

Tahtadaki Yazıların Belirginleştirilmesi ve Tespit Edilmesindeki Zorluklar


Kullanıcıların amatör ve dikkat etmeden çektikleri beyaz tahta içerikli görsellerin içinden öncelikle tahtanın tespiti gerçekleştirilmelidir.




Yazı Tespitindeki Zorluklar



Sonsuz Yazı ihtimali : Tahtada yazan şeyler çok farklı yazılar,şekiller ve yapılar olabilir.



Değişken Işık ve Gölgeler: Dengesiz aydınlatma, yerel **kontrast kaybına** ve **veri kaybına** yol açar.



Homojen Olmayan Işık: Kırpılmış tahta görüntüsünde parlama ve yansıma sebebiyle kaybolmuş rengi değişmiş yazılar.





Temiz Olmayan Tahta: Tahtada önceki yazıların silinmesinden kalan ciddi silgi izleri.

Tahtadaki Yazıların Belirginleştirilmesi ve Tespit Edilmesi

Eğittiğimiz 1. modelimiz olan TTM v2 modelimize giren tahta içerikli görüntüler öncelikle tahta segmente edilerek kural tabanlı kırpma ve düzleştirme işlemlerine tabi tutulur. Ardından oluşan görüntü direkt olarak segmente edilmiş tahtayı içerir.

Elde edilen 1. model çıktısındaki tahtadan yazılar şekiller ve yapıların not haline getirilmesi için görüntüdeki içeriklerin kalınlaştırılması, maskelenmesi ve aynı zamanda tahta içindeki gölge, yansıma ve kirli gözüken alanlara rağmen bu işlemin başarılı bir şekilde gerçekleştirilmesi amaçlanmaktadır.



Buna uygun olarak yapacağımız kompleks, zorlu ve karmaşık işlem için uygun model olan NAFnet modeli tercih edilmiştir.

2. Model için İlk Eğitim


Tahta görüntülerindeki gölge, aydınlık, karanlık, yansımali ve kirli alanların temizlenerek daha düzgün halde gösterilmesi için SD7K hazır eğitim veri seti ile beraber test eğitimi gerçekleştirilmiştir.

SD7K

Sınıf ve amfi ortamlarında çekilen yazı tahtası fotoğraflarını netleştirmek, üzerindeki gölgeleri/bozulmaları gidermek ve metin okunabilirliğini optimize etmek amacıyla kullanılan ikili (paired input/target) ana veri seti

Image Restoration / Board Enhancement

Train: 5506 | Valid: 647 | Test: 325



B2N Yazı Güçlendirme Modeli YGM-v1 NAFNet

YGM-v1 NAFNet DEV

Girdi Boyutu:	512x512
Batch-BE/Epoch:	16 / 16 / 40
Optimizer:	AdamW (LR: 2e-4, WD: 1e-4)
Loss Fonksiyonu:	L1 Loss + SSIM Loss + Edge Loss
Çıktı Aktivasyonu:	Yok / Lineer RGB çıktı
Augmentation:	Paired random crop, center resize (val/test)

Performans: Bu model 40 epoch'luk eğitimin son epoch'unda en iyi sonucu vermiştir.


Val SSIM: 0.9870 | Val PSNR: 33.47 | Val L1: 0.02745

Test SSIM: 0.9877 | Test PSNR: 33.46

Test L1: 0.02723 | Test Edge: 0.02376

Sonuçlar:

Bu model projemizin ilk aşamalarında görüntü iyileştirme/restorasyon işlemlerinin seçilen modelin mimarisinin uygun olup olmadığını test ettiğimiz modelidir. Amaç tahta görüntüsündeki gölge, bulanıklık ve kontrast problemlerini azaltarak daha temiz ve okunabilir bir çıktı üretmektir. NAFNet-Small mimarisi sayesinde giriş görüntüsündeki bozulmalar azaltılmış, hedef temiz görüntüye daha yakın sonuçlar elde edilmiştir.



B2N Yazı Güçlendirme Modeli YGM-v1 NAFNet

LATENT DIRICHLET ALLOCATION

Num. topics (k)	Perplexity (Mult. Mixt.)	Perplexity (pLSI)
2	22,266	7,052
5	2.20×10^4	17,588
10	1.93×10^{17}	63,800
20	1.20×10^{17}	2.52×10^5
50	4.19×10^{106}	5.04×10^6
100	2.39×10^{510}	1.72×10^7
200	3.51×10^{264}	1.31×10^7

Table 1: Overfitting in the mixture of unigrams and pLSI models for the AP corpus. Similar behavior is observed in the nematode corpus (not reported).

we removed a standard list of 50 stop words from each corpus. From the AP data, we further removed words that occurred only once.

We compared LDA with the unigram, mixture of unigrams, and pLSI models described in Section 4. We trained all the hidden variable models using EM with exactly the same stopping criteria, that the average change in expected log likelihood is less than 0.001%.

Both the pLSI model and the mixture of unigrams suffer from serious overfitting issues, though for different reasons. This phenomenon is illustrated in Table 1. In the mixture of unigrams model, overfitting is a result of peaked posteriors in the training set; a phenomenon familiar in the supervised setting, where this model is known as the naive Bayes model (Rennie, 2001). This leads to a nearly deterministic clustering of the training documents (in the E-step) which is used to determine the word probabilities in each mixture component (in the M-step). A previously unseen document may best fit one of the resulting mixture components, but will probably contain at least one word which did not occur in the training documents that were assigned to that component. Such words will have a very small probability, which causes the perplexity of the new document to explode. As k increases, the documents of the training corpus are partitioned into finer collections and thus induce more words with small probabilities.

In the mixture of unigrams, we can alleviate overfitting through the variational Bayesian smoothing scheme presented in Section 5.4. This ensures that all words will have some probability under every mixture component.

In the pLSI case, the hard clustering problem is alleviated by the fact that each document is allowed to exhibit a different proportion of topics. However, pLSI only refers to the training documents and a different overfitting problem arises that is due to the dimensionality of the $p(z|d)$ parameter. One reasonable approach to assigning probability to a previously unseen document is by marginalizing over d :

$$p(\mathbf{w}) = \sum_d \prod_{n=1}^N \sum_z p(w_n | z) p(z | d) p(d).$$

Essentially, we are integrating over the empirical distribution on the topic simplex (see Figure 4). This method of inference, though theoretically sound, causes the model to overfit. The document-specific topic distribution has some components which are close to zero for those topics that do not appear in the document. Thus, certain words will have very small probability in the estimates of

LATENT DIRICHLET ALLOCATION

Num. topics (k)	Perplexity (Mult. Mixt.)	Perplexity (pLSI)
2	22,266	7,052
5	2.20×10^4	17,588
10	1.93×10^{17}	63,800
20	1.20×10^{17}	2.52×10^5
50	4.19×10^{106}	5.04×10^6
100	2.39×10^{510}	1.72×10^7
200	3.51×10^{264}	1.31×10^7

Table 1: Overfitting in the mixture of unigrams and pLSI models for the AP corpus. Similar behavior is observed in the nematode corpus (not reported).

we removed a standard list of 50 stop words from each corpus. From the AP data, we further removed words that occurred only once.

We compared LDA with the unigram, mixture of unigrams, and pLSI models described in Section 4. We trained all the hidden variable models using EM with exactly the same stopping criteria, that the average change in expected log likelihood is less than 0.001%.

Both the pLSI model and the mixture of unigrams suffer from serious overfitting issues, though for different reasons. This phenomenon is illustrated in Table 1. In the mixture of unigrams model, overfitting is a result of peaked posteriors in the training set; a phenomenon familiar in the supervised setting, where this model is known as the naive Bayes model (Rennie, 2001). This leads to a nearly deterministic clustering of the training documents (in the E-step) which is used to determine the word probabilities in each mixture component (in the M-step). A previously unseen document may best fit one of the resulting mixture components, but will probably contain at least one word which did not occur in the training documents that were assigned to that component. Such words will have a very small probability, which causes the perplexity of the new document to explode. As k increases, the documents of the training corpus are partitioned into finer collections and thus induce more words with small probabilities.

In the mixture of unigrams, we can alleviate overfitting through the variational Bayesian smoothing scheme presented in Section 5.4. This ensures that all words will have some probability under every mixture component.

In the pLSI case, the hard clustering problem is alleviated by the fact that each document is allowed to exhibit a different proportion of topics. However, pLSI only refers to the training documents and a different overfitting problem arises that is due to the dimensionality of the $p(z|d)$ parameter. One reasonable approach to assigning probability to a previously unseen document is by marginalizing over d :

$$p(\mathbf{w}) = \sum_d \prod_{n=1}^N \sum_z p(w_n | z) p(z | d) p(d).$$

Essentially, we are integrating over the empirical distribution on the topic simplex (see Figure 4). This method of inference, though theoretically sound, causes the model to overfit. The document-specific topic distribution has some components which are close to zero for those topics that do not appear in the document. Thus, certain words will have very small probability in the estimates of

LATENT DIRICHLET ALLOCATION

Num. topics (k)	Perplexity (Mult. Mixt.)	Perplexity (pLSI)
2	22,266	7,052
5	2.20×10^4	17,588
10	1.93×10^{17}	63,800
20	1.20×10^{17}	2.52×10^5
50	4.19×10^{106}	5.04×10^6
100	2.39×10^{510}	1.72×10^7
200	3.51×10^{264}	1.31×10^7

Table 1: Overfitting in the mixture of unigrams and pLSI models for the AP corpus. Similar behavior is observed in the nematode corpus (not reported).

we removed a standard list of 50 stop words from each corpus. From the AP data, we further removed words that occurred only once.

We compared LDA with the unigram, mixture of unigrams, and pLSI models described in Section 4. We trained all the hidden variable models using EM with exactly the same stopping criteria, that the average change in expected log likelihood is less than 0.001%.

Both the pLSI model and the mixture of unigrams suffer from serious overfitting issues, though for different reasons. This phenomenon is illustrated in Table 1. In the mixture of unigrams model, overfitting is a result of peaked posteriors in the training set; a phenomenon familiar in the supervised setting, where this model is known as the naive Bayes model (Rennie, 2001). This leads to a nearly deterministic clustering of the training documents (in the E-step) which is used to determine the word probabilities in each mixture component (in the M-step). A previously unseen document may best fit one of the resulting mixture components, but will probably contain at least one word which did not occur in the training documents that were assigned to that component. Such words will have a very small probability, which causes the perplexity of the new document to explode. As k increases, the documents of the training corpus are partitioned into finer collections and thus induce more words with small probabilities.

In the mixture of unigrams, we can alleviate overfitting through the variational Bayesian smoothing scheme presented in Section 5.4. This ensures that all words will have some probability under every mixture component.

In the pLSI case, the hard clustering problem is alleviated by the fact that each document is allowed to exhibit a different proportion of topics. However, pLSI only refers to the training documents and a different overfitting problem arises that is due to the dimensionality of the $p(z|d)$ parameter. One reasonable approach to assigning probability to a previously unseen document is by marginalizing over d :

$$p(\mathbf{w}) = \sum_d \prod_{n=1}^N \sum_z p(w_n | z) p(z | d) p(d).$$

Essentially, we are integrating over the empirical distribution on the topic simplex (see Figure 4). This method of inference, though theoretically sound, causes the model to overfit. The document-specific topic distribution has some components which are close to zero for those topics that do not appear in the document. Thus, certain words will have very small probability in the estimates of

Gölgeli Ve Bozuk Görüntü

Düzgün Görüntü

Model Çıktısı

B2N Yazı Güçlendirme Modeli YGM-v1 NAFNet



Gölge ve Bozuk Görüntü



Düzenli Görüntü



Model Çıktısı

B2N Yazı Güçlendirme Modeli YGM-v1 NAFNet



Gölge ve Bozuk Görüntü

Düzgün Görüntü

Model Çıktısı

Yazı Tespit Modeli İçin Geliştirmeler

Projemizde 2. modelimizin yapmasını amaçladığımız tahta görüntündeki gölge, parlama, kirlilik ve yansıma gibi durumları temizlemesi ve tahta içeriğini kalınlaştırması. Bu isteklerimiz tek bir model için oldukça karmaşık ve zorlu olmakla birlikte aynı zamanda farklı amaçlar ve farklı durumlar içinde tek bir fonksiyonunun kullanılması gerekebilmektedir.



Bu duruma çözüm olarak modelimizi çok başlı olacak şekilde eğitmenin mantıklı olacağına karar verdik.

YGM: 2. Modelimizin Mimari Değişimi

- Modelimiz çok başlı bir yapıda çıktı verecek hale getirildi.
- 3 farklı çıktı için özel ürettiğimiz bir veri seti üretilmesi kararlaştırıldı.

Modele Özel Veri Seti


2. Modelimizin eğitimi için şu an halihazırda bulunan hazır veri setlerinin hiçbirisi uygun olmamakla birlikte yakın bir amaca hizmet eden bir veri seti de bulunamamıştır.

Bu sebepten dolayı 2. modelimiz; tahta üzerindeki yazıları tespit edecek olan model eğitimi tamamen sentetik olarak üretilecek bir veri seti ile beraber yapılması kararlaştırılmıştır.



Mr. Gaitskell from
MPs tomorrow.
nominating any more
Labour life Peers
MOVE to stop Mr.

Üretilen Veri Seti



Boş Tahta Veri Seti: B2N_2 Veri Seti

El Yazısı Veri Seti(Satır el yazısı): IAM-line

Dataset: Generated Multihead Dataset

Train: input: 3920 | target_restored: 3920 |
target_ocr: 3920 | text_mask: 3920

Val: input: 144 | target_restored: 144 | target_ocr:
144 | text_mask: 144


Test: input: 156 | target_restored: 156 | target_ocr:
156 | text_mask: 156

Veri Seti Boyutu: 8,32 GB


Bu veri seti 1. modelimiz olan TTM-V2 için topladığımız veri setinin içerdiği boş tahta görüntüleri ile beraber **IAM Handwriting** Database veri seti kullanılarak **boş tahta görsellerinin** üstüne el yazısı veri setinden alınan **el yazıları** yerleştirilerek oluşturulmuştur. Bu veri seti Colab ortamında Drive'da saklanarak elde edilmiş özel bir veri setidir.

Üretilen Veri Seti Örnekleri


input




target_restored



target_ocr




text_mask



Kullanılan Model: NAFNet Tabanlı Multi-Head Yapı

İkinci modelde NAFNet tabanlı çok çıkışlı bir görüntü iyileştirme mimarisi kullanılmıştır. Model, tek bir giriş görüntüsünden üç farklı çıktı üretmektedir:

1. **Restored Output:** Tahta görüntüsünün genel olarak temizlenmiş ve restore edilmiş hali
 2. **OCR Output:** Beyaz arka plan üzerinde daha koyu ve belirgin yazı çıktısı
 3. **Mask Output:** Yazı bölgelerini gösteren text mask / mask_logits çıktısı
- 3 başlı model yapısı ile beraber farklı senaryolar için modelimiz ürün seviyesine hazır halde doğdu.




Bu çok başlı yapı sayesinde model yalnızca tek bir görüntü çıktısı üretmek yerine, farklı kullanım amaçlarına yönelik tamamlayıcı çıktılar üretmektedir.

Kullanılan Model: NAFNet Tabanlı Multi-Head Yapı




Modelin Üç Çıkışının Görevleri

Pred Restored




```
STA SUM /Tutarı kaydet/skle
HLT
ADS, HEX 100 /Adres ilahatı
PTR, HEX 0 /İşareti bir ayarla
NBR, DEC -100 /Bir sayı
CTR, HEX 0 /Sıra içi ayarla
SUM, HEX 0 /Sıra kısıya eklensin
ORG 100 /Yukarı 100 ile ilahatı saklanı
DEC 38 /1. sıra
DEC 37 /2. sıra
DEC 1
END //Sembolik programın sonu
```

Pred OCR



```
STA SUM /Tutarı kaydet/skle
HLT
ADS, HEX 100 /Adres ilahatı
PTR, HEX 0 /İşareti bir ayarla
NBR, DEC -100 /Bir sayı
CTR, HEX 0 /Sıra içi ayarla
SUM, HEX 0 /Sıra kısıya eklensin
ORG 100 /Yukarı 100 ile ilahatı saklanı
DEC 38 /1. sıra
DEC 37 /2. sıra
DEC 1
END //Sembolik programın sonu
```

Pred Mask



```
STA SUM /Tutarı kaydet/skle
HLT
ADS, HEX 100 /Adres ilahatı
PTR, HEX 0 /İşareti bir ayarla
NBR, DEC -100 /Bir sayı
CTR, HEX 0 /Sıra içi ayarla
SUM, HEX 0 /Sıra kısıya eklensin
ORG 100 /Yukarı 100 ile ilahatı saklanı
DEC 38 /1. sıra
DEC 37 /2. sıra
DEC 1
END //Sembolik programın sonu
```

Modelin **birinci çıkışı** olan restored output, tahta görüntüsündeki genel bozulmaları azaltmayı hedefler. Bu çıktı, görüntünün daha doğal ve temiz bir tahta görünümüne yaklaşmasını sağlar.


İkinci çıkış olan OCR output, yazıların daha koyu, arka planın ise daha sade ve beyaz görüldüğü OCR ve nota uygun görüntü üretir. Bu çıktı, not üretme ve metin tanıma aşamasında temel çıktı olarak kullanılmaktadır.

Üçüncü çıkış olan mask output, görüntüdeki yazı bölgelerini piksel seviyesinde ayırır. Bu maske sayesinde yazılar arka plandan ayrıştırılabilir, yazı katmanı çıkarılabilir. Ürün çıktısı.


B2N Yazı Güçlendirme Modeli YGM-v2 NAFNet-Base Multi-Head

YGM-v2 NAFNet Multi-Head

Girdi Boyutu:	512x512
Batch-BE/Epoch:	8 / 4 / 20
Optimizer:	AdamW (LR: 1e-4 / 4e-5, WD: 1e-4)
Loss Fonksiyonu:	Multi-Head: L1 + SSIM + Edge + BCE + Dice
Çıktı Aktivasyonu:	Lineer RGB (restore/OCR) + Sigmoid (mask)
Augmentation:	Paired random crop (yatay çevirme kapalı)



Girdi



Maskelenmiş Tahta

Performans: Bu model 20 epoch'luk iki aşamalı eğitimin sonunda en iyi sonucu vermiştir.


Val Score: 0.22819 | Val Restore L1: 0.07284
Val OCR L1: 0.07440 | Val Mask IoU: 0.5952

Test Score: 0.21773 | Test Mask IoU: 0.58279
Test Restore PSNR: 18.09 | Test OCR PSNR: 17.92


Sonuçlar: Bu model, önceki NAFNet modelinden farklı olarak çok başlı bir yapı ile eğitilmiştir. Sadece görüntüyü temizlemek yerine aynı anda restore edilmiş görüntü, OCR'ye uygun görüntü ve yazı maskesi üretmesi hedeflenmiştir. Model A100 GPU üzerinde BF16 precision ile eğitilmiştir.

B2N YGM-v2 NAFNet-Base Multi-Head


input




pred_rest




target_rest



pred_ocr




target_ocr




B2N YGM-v2 NAFNet-Base Multi-Head


input




pred_rest




target_rest



pred_ocr




target_ocr




B2N YGM-v2 NAFNet-Base Multi-Head


input




pred_rest




target_rest



pred_ocr





target_ocr



B2N YGM-v2 NAFNet-Base Multi-Head

pred_mask

input



Denetimsiz Öğrenme Eklenerek Başarı Arttırılabilir mi?

V2 Modelinin Sınırı: Neden Yeterli Degil?


V2 modeli yalnızca denetimli kayıplarla (L1, SSIM, Edge, Mask) eğitilmiştir. Bu kayıplar modeli piksel bazında hedefe yaklaştırır da çıktıların ortalamaya çekilmesine neden olur. Sonuç olarak bulanık, düşük kontrastlı ve dijital not için yetersiz görüntüler üretilmektedir. Peki bu sınır nasıl aşılabılır?

Neden Denetimsiz Öğrenme Eklenmesi Düşünüldü?

- 1. Denetimli kayıplar tek bir ortalama çözüme yakınsarken, adversarial öğrenme gerçek görüntü dağılımını öğrenir.**
→ Çıktılar ortalama değil, gerçekçi olur.
- 2. GAN'in Discriminator'u bulanık/yapay çıktıları cezalandırır.**
→ Model keskin kenarlar ve yüksek kontrast üretmeye zorlanır.
- 3. Feature Matching Loss, yalnızca piksel değil yapı ve doku benzerliğini de öğretir.**
→ OCR ve insan okuması için kritik olan yazı kenarı detayları korunur.
- 4. Literatürde super-resolution ve image restoration alanlarında GAN eklenmesinin algısal kaliteyi belirgin şekilde arttırdığı gösterilmiştir.** (SRGAN, ESRGAN, Real-ESRGAN)

Beklenen Etki


Denetimli öğrenmenin üstüne adversarial fine-tune eklenmesiyle OCR çıktısında **keskinlik**, **kontrast** ve **okunabilirlik** artışı beklenmektedir.




Denetimsiz Öğrenme Eklenerek Başarı Arttırılabilir mi?

1 V2 Modelinin Sınırı

Yalnızca Denetimli Kayıplar




2 Neden Denetimsiz / Adversarial Öğrenme?



3 Beklenen Etki

Adversarial Fine-tune Sonrası



2 Note

B2N Yazı Güçlendirme Modeli YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

Girdi Boyutu:	512x512
Batch-BE/Epoch:	10 / 4 / 32
Optimizer:	AdamW (LR: 1e-4/4e-5/2e-5, WD: 1e-4)
Loss Fonksiyonu:	Charb + MS-SSIM + Edge + VGG + BCE + Dice + Focal + LSGAN
Çıktı Aktivasyonu:	Lineer RGB (restore/OCR) + Sigmoid (mask)
Augmentation:	Paired random crop (yatay çevirme kapalı)

2 Note

Performans: En iyi model Stage-3 GAN aşamasında elde edilmiştir.

Best Val Score: 0.29822

OCR PSNR: 24.81 | OCR SSIM: 0.5082

OCR MS-SSIM: 0.7888

Mask IoU: 0.5778 | Mask Dice: 0.7159

White Canvas PSNR: 30.8369 | SSIM:

0.9767

Mask Precision: 0.6077 | Recall: 0.8808

Rest PSNR: 20.97 | OCR Edge-F1:

0.9597

Sonuçlar:

Bu model, önceki Multi-Head NAFNet modelinin daha gelişmiş versiyonudur. Denetimli öğrenme + GAN tabanlı adversarial fine-tune ile eğitilmiştir. White Canvas = OCR Enhanced x Text Mask formülü ile ürün çıktısı üretilmiştir.

2 Note

2x

Daha Yüksek
OCR SSIM

İnsan gözüne daha
uygun çıktılar

%38

Daha Temiz Tahta
OCR PSNR

Piksel bazlı görüntü
benzerliği

%77


Daha Temiz Görüntü
OCR SSIM

İnce ve büyük
detaylar

White Canvas PSNR: 30.84 ve SSIM: 0.9767 değerleri, nihai ürün çıktısının yüksek kalitede olduğunu kanıtlamaktadır. Bu model YGM-V2 modelinden metrik değerler olarak çok daha başarılı olmakla beraber GAN denetimsiz öğrenme ile gerçekleştirilen Stage-3 aşamasının göstergesi olarak çok daha güçlü bir model ortaya çıkmıştır.

Başarının Sırrı: Adım Adım Eğitim İstatistikleri

2Note




Stage 1: 14 epoch (tüm başlıklar birlikte) **DENETİMLİ**
Stage 2: 12 epoch (OCR + mask ağırlıklı) **DENETİMLİ**
Stage 3 GAN: 6 epoch (PatchGAN adversarial fine-tune) **DENETİMSİZ**
GAN batch size: 8

Grafiklerde görüldüğü gibi OCR-PSNR ve Canvas-PSNR başarılarında adımlara bağlı başarı gösterilmiştir.

Stage-3 yani GAN tabanlı denetimsiz eğitim aşamasında OCR-PSNR değerinde ciddi bir artış gözlemlenmiştir.

Başarının Sırrı: Adım Adım Eğitim İstatistikleri

2 Note



Daha detaylı görünümde net bir şekilde OCR-PSNR başarısının 1. Stage'de plato noktasına ulaştığı ve sonrasında gerçekleştirilen Stage-2 denetimli eğitiminde de aynı şekilde başarının hafif artarak yeniden platoya girdiği gözükmemektedir.

Stage-3 GAN tabanlı denetimsiz öğrenim aşamasında ise denetimli yapılan eğitim aşamalarının takıldığı bu sınır tamamen kaldırılmış ve model ciddi şekilde gelişmiştir.

Başarının Sırrı: Adım Adım Eğitim İstatistikleri



2 Note

Az önce gösterilen OCR-PSNR sonucu gibi OCR-SSIM yani insan gözüne daha uygun sonuçların üretilmesinde ölçümlerin yapıldığı başarı değeri GAN denetimsiz eğitim adımında ciddi oranda artış sağlayarak önceki denetimli eğitimde oluşan plato ve sınırı tamamen kırmıştır.

2 Note

YGM-v3 NAFNet-Base Multi-Head + SUP-GAN - Detaylı Bilgiler

Veri Seti Boyutu:	Toplam 4220 paired goruntu Train: 3920 Val: 144 Test: 156
Egitim Aşamaları:	Stage 1: 14 epoch (tüm başlıklar birlikte) Stage 2: 12 epoch (OCR + mask ağırlıklı) Stage 3 GAN: 6 epoch (PatchGAN adversarial fine-tune) GAN batch size: 8
Loss Detayları:	Denetimli: Charbonnier + MS-SSIM + Edge + VGG Perceptual + BCE + Dice + Focal GAN: LSGAN Loss + Feature Matching Loss Model 3 çıktı üretir: Restore OCR Yazı Maskesi White Canvas = OCR Enhanced x Text Mask
Detaylı Test Sonuçları:	Rest PSNR: 20.9712 Rest SSIM: 0.2305 Rest MAE: 0.0569 OCR PSNR: 24.8144 OCR SSIM: 0.5082 OCR MS-SSIM: 0.7888 OCR MAE: 0.0471 OCR Edge-F1: 0.9597 Mask IoU: 0.5778 Mask Dice: 0.7159 Mask Precision: 0.6077 Mask Recall: 0.8808 Mask F1: 0.7159 Mask Boundary-F1: 0.9712 Mask Accuracy: 0.9914 White Canvas PSNR: 30.8369 White Canvas SSIM: 0.9767
Kısa Yorum:	White Canvas PSNR: 30.84 ve SSIM: 0.9767 değerleri, nihai ürün çıktısının yüksek kalitede olduğunu kanıtlamaktadır. Bu model YGM-V2 modelinden metrik değerler olarak çok daha başarılı olmakla beraber GAN denetimsiz öğrenme ile gerçekleştirilen Stage-3 aşamasının göstergesi olarak çok daha güçlü bir model ortaya çıkmıştır.

V3 Modeli: GAN Tabanlı Adversarial Fine-Tune

V3 modelinde, V2 modelinin denetimli eğitiminden sonra GAN tabanlı adversarial fine-tune uygulanmıştır. Bu aşamada NAFNet modeli Generator, PatchGAN yapısı ise Discriminator olarak kullanılmıştır.


Generator, bozuk/gölgeli tahta görüntüsünden OCR'ye uygun temiz görüntü üretmeye çalışırken; Discriminator, üretilen OCR görüntüsü ile gerçek hedef OCR görüntüsünü ayırt etmeye çalışmıştır.

Discriminator'a yalnızca çıktı görüntüsü değil, input + OCR görüntüsü birlikte verilmiştir. Böylece Discriminator, üretilen görüntünün giriş görüntüsüyle tutarlı olup olmadığını da öğrenmiştir.

GAN Aşamasında Kullanılan Kayıp Yapısı:

$$\text{Generator Loss} = \text{Supervised Loss} + 0.02 \times \text{Adversarial Loss} + 5.0 \times \text{Feature Matching Loss}$$

Bu yapı sayesinde model yalnızca piksel bazlı hatayı azaltmamış; yazı kenarı, kontrast, keskinlik ve gerçekçi temiz görüntü dağılımını da öğrenmiştir.



Neden OCR Başarısını Artırdı?

Denetimli eğitimde model çoğunlukla L1, SSIM, Edge ve Mask loss değerlerini düşürmeye çalışır. Bu durum bazen ortalama, yumuşak ve bulanık çıktılar üretir. OCR için ise yazının net, koyu, keskin ve arka plandan ayrılmış olması gerekir.

GAN aşamasında Discriminator, yumuşak veya yapay görünen OCR çıktılarını cezalandırmıştır. Generator ise daha gerçekçi, daha keskin ve daha yüksek kontrastlı yazılar üretmeye zorlanmıştır.

OCR PSNR: 18.64 dB → 24.81 dB **OCR SSIM:** 0.1765 → 0.5082


Sonuç

V3 modelinin başarısı, denetimli öğrenme ile öğrenilen temel restorasyon bilgisinin GAN destekli adversarial öğrenme ile güçlendirilmesinden kaynaklanmaktadır. GAN aşaması, modelin yalnızca hedef görüntüye yaklaşmasını değil, gerçek temiz OCR görüntülerine benzeyen daha okunabilir ve daha keskin çıktılar üretmesini sağlamıştır.

Bu nedenle V3 modeli, OCR öncesi görüntü iyileştirme ve beyaz canvas üretimi açısından V2 modeline göre daha başarılı olmuştur.




Denetimsiz Öğrenmenin Model Başarısına Etkisi




YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

input



pred_ocr



pred_mask




white_canvas (ÜRÜN)




YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

input



pred_ocr



pred_mask




white_canvas(ÜRÜN)




YGM-v3 NAFNet-Base Multi-Head + SUP-GAN


input



pred_ocr



pred_mask



white_canvas(ÜRÜN)



Projemizde Geliştirilen En Güçlü Modeller

B2N Tahta Tespit Modeli - TTM-v2

B2N TTM-v2

Girdi Boyutu:	640x640
Batch-BE/Epoch:	64 / 128 / 75
Optimizer:	AdamW
Loss Fonksiyonu:	BCE with Logits Loss + Dice Loss + Edge Loss
Çıktı Aktivasyonu:	Sigmoid (Threshold: 0.50)
Augmentation:	Yatay çevirme, affine, perspective, parlaklık/kontrast, HSV, gölge, blur, noise, JPEG artifact



B2N Yazı Güçlendirme Modeli YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

YGM-v3 NAFNet-Base Multi-Head + SUP-GAN

Girdi Boyutu:	512x512
Batch-BE/Epoch:	10 / 4 / 32
Optimizer:	AdamW (LR: 1e-4/4e-5/2e-5, WD: 1e-4)
Loss Fonksiyonu:	Charb + MS-SSIM + Edge + VGG + BCE + Dice + Focal + LSGAN
Çıktı Aktivasyonu:	Lineer RGB (restore/OCR) + Sigmoid (mask)
Augmentation:	Paired random crop (yatay çevirme kapali)



Performans: Final model, 75 epoch'luk kademeli eğitim sürecinin sonunda en iyi sonucu vermiştir.
Val IoU: 0.9633 | Val Dice: 0.9798
Precision: 0.9780 | Recall: 0.9847
Loss: 0.0702

Sonuçlar: Bu model, önceki modele göre gerçek dünya verilerinde daha iyi sonuçlar elde etmiştir. MobileNetV3-Large + LR-ASPP mimarisıyla tahta/projeksiyon alanını daha net ayırabilmiş ve yüksek başarılı maske üretmiştir. Özellikle kenar bölgelerinde daha başarılı sonuçlar alınmıştır. Veri seti arasına gerçek dünya yani kendi veri setimizin eklenmesi sebebiyle sayısal başarı metriklerinde ufak bir düşüş gözlemlenmiştir.


Performans: En iyi model Stage 3 GAN aşamasında elde edilmistir.
Best Val Score: 0.29822
OCR PSNR: 24.81 | OCR SSIM: 0.5082
OCR MS-SSIM: 0.7888
Mask IoU: 0.5778 | Mask Dice: 0.7159

White Canvas PSNR: 30.8369 | SSIM: 0.9767
Mask Precision: 0.6077 | Recall: 0.8808
Rest PSNR: 20.97 | OCR Edge-F1: 0.9597

Sonuçlar: Bu model, önceki Multi-Head NAFNet modelinin daha gelişmiş versiyonudur. Denetimli öğrenme + GAN tabanlı adversarial fine-tune ile eğitilmiştir. White Canvas = OCR Enhanced x Text Mask formülü ile ürün çıktısı üretilmiştir.

B2N Tahta Tespit Modeli V2

B2N Yazı Güçlendirme Modeli V3



2 Note


2 Note



Projeden Ürüne: Board2Note

Sonuçlar: TTM-Tahta Tespit Modeli

Birinci Modellerimiz: İlk geliştirilen TTM(Tahta Tespit Modeli) ve YGM(Yazı Güçlendirme Modeli) modelleri geliştirme için hazır veri setleri ve amacın bir kısmına uygun çıktı verecek şekilde geliştirilmiştir. Alınan sonuçlara bakılarak modellerin amacımıza uygun olduğu saptanarak MobileNetV3 ve NAFNet modelleri ürün seviyesinde geliştirme için tercih edilmiştir.



B2N Tahta Tespit Modeli - TTM-v2

B2N TTM-v2

Girdi Boyutu:	640x640
Batch-BE/Epoch:	64 / 128 / 75
Optimizer:	AdamW
Loss Fonksiyonu:	BCE with Logits Loss + Dice Loss + Edge Loss
Çıktı Aktivasyonu:	Sigmoid (Threshold: 0.50)
Augmentation:	Yatay çevirme, affine, perspective, parlaklık/kontrast, HSV, gölge, blur, noise, JPEG artifact



Performans: Final model, 75 epoch'luk kademeli eğitim sürecinin sonunda en iyi sonucu vermiştir.

Val IoU: 0.9633 | Val Dice: 0.9798

Precision: 0.9780 | Recall: 0.9847

Loss: 0.0702

Sonuçlar: Bu model, önceki modele göre gerçek dünya verilerinde daha iyi sonuçlar elde etmiştir. MobileNetV3-Large + LR-ASPP mimarisiyle tahta/projeksiyon alanını daha net ayırabilmiş ve yüksek başarılı maske üretmiştir. Özellikle kenar bölgelerinde daha başarılı sonuçlar alınmıştır. Veri seti arasına gerçek dünya yani kendi veri setimizin eklenmesi sebebiyle sayısal başarı metriklerinde ufak bir düşüş gözlemlenmiştir.

Model-1 TTM-V2: Mevcut hazır veri setlerindeki bazı görsellerin, projenin ikinci modeline girdi (input) olmaya uygun olmaması nedeniyle yeni bir veri hazırlığı sürecine gidilmiştir. Bu doğrultuda, amaca daha uygun hazır veri setleri seçilmiş ve kendi topladığımız veriler etiketlenerek karma bir veri setiyle modelin eğitimi gerçekleştirilmiştir. Gerçek dünya koşullarına çok daha uygun ve amacımıza yönelik çıktılar vermekle beraber test sonuçlarında oldukça yüksek skorlar elde etmiştir.

Sonuçlar: YGM- Yazı Güçlendirme Modeli

Birinci YGM Modelimiz: Geliştiridğimiz ilk YGM modelimiz amacımızın bir kısmını karşılayan görüntü iyileştirme (Enchanced/Restore) işlemlerini gerçekleştirecek şekilde eğitime sokulmuştur. Bu eğitimde S7DK bozuk ve düzgün görüntüleri içeren veri seti kullanılmış olup eğitim sonrasında modelin görüntü iyileştirme konusunda başarısı gözlemlenmiştir.

B2N Yazı Güçlendirme Modeli YGM-v2 NAFNet-Base Multi-Head

YGM-v2 NAFNet Multi-Head	
Girdi Boyutu:	512x512
Batch-BE/Epoch:	8 / 4 / 20
Optimizer:	AdamW (LR: 1e-4 / 4e-5, WD: 1e-4)
Loss Fonksiyonu:	Multi-Head: L1 + SSIM + Edge + BCE + Dice
Çıktı Aktivasyonu:	Lineer RGB (restore/OCR) + Sigmoid (mask)
Augmentation:	Paired random crop (yatay çevirme kapalı)

Performans: Bu model 20 epoch'luk iki aşamalı eğitimin sonunda en iyi sonucu vermiştir.
Val Score: 0.22819 | Val Restore L1: 0.07284 | Test Score: 0.21773 | Test Mask IoU: 0.58279
Val OCR L1: 0.07440 | Val Mask IoU: 0.5952 | Test Restore PSNR: 18.09 | Test OCR PSNR: 17.92

Sonuçlar: Bu model, önceki NAFNet modelinden farklı olarak çok başlı bir yapı ile eğitilmiştir. Sadece görüntüyü temizlemek yerine aynı anda restore edilmiş görüntü, OCR'ye uygun görüntü ve yazı maskesi üretmesi hedeflenmiştir. Model A100 GPU üzerinde BF16 precision ile eğitilmiştir.

LATENT DIRECTIONAL ALLOCATION		
Num. topics (k)	Perplexity (Mult. Mix.)	Perplexity (pLSI)
2	22,266	7,052
5	2.20×10^5	17,588
10	1.93×10^{17}	63,800
20	1.20×10^{19}	2.52×10^8
50	4.18×10^{19}	5.04×10^8
100	2.39×10^{20}	1.72×10^7
200	3.51×10^{24}	1.31×10^7

Table 1: Overfitting in the mixture of unigrams and pLSI models for the AP corpus. Similar behavior is observed in the semantide corpus (not reported).

we removed a standard list of 50 stop words from each corpus. From the AP data, we further removed words that occurred only once.

We compared LDA with the unigram, mixture of unigrams, and pLSI models described in Section 4. We trained all the hidden variable models using EM with exactly the same stopping criteria, that the average change in expected log likelihood is less than 0.001%.

Both the pLSI model and the mixture of unigrams suffer from serious overfitting issues, though for different reasons. This phenomenon is illustrated in Table 1. In the mixture of unigrams model, overfitting is a result of peaked posteriors in the training set, a phenomenon familiar in the supervised setting, where this model is known as the naive Bayes model (Bennie, 2001). This leads to a nearly deterministic clustering of the training documents (in the E-step) which is used to determine the word probabilities in each mixture component (in the M-step). A previously unseen document may best fit one of the resulting mixture components, but will probably contain at least one word which did not occur in the training documents that were assigned to that component. Such words will have a very small probability, which causes the perplexity of the new document to explode. As k increases, the documents of the training corpus are partitioned into finer collections and thus induce more words with small probabilities.

In the mixture of unigrams, we can alleviate overfitting through the variational Bayesian smoothing scheme presented in Section 5.4. This ensures that all words will have some probability under every mixture component.

In the pLSI case, the hard clustering problem is alleviated by the fact that each document is allowed to exhibit a different proportion of topics. However, pLSI only refers to the training documents and a different overfitting problem arises that is due to the dimensionality of the $p(z|d)$ parameter. One reasonable approach to assigning probability to a previously unseen document is to marginalize over d .

$$p(\mathbf{w}) = \sum_{\mathbf{z}} \prod_{n=1}^N \sum_{d=1}^D p(w_n | z) p(z | d) p(d).$$

Essentially, we are integrating over the empirical distribution on the topic simplex (see Figure 4). This method of inference, though theoretically sound, causes the model to overfit. The document-specific topic distribution has some components which are close to zero for those topics that do not appear in the document. Thus, certain words will have very small probability in the estimates of

LATENT DIRECTIONAL ALLOCATION		
Num. topics (k)	Perplexity (Mult. Mix.)	Perplexity (pLSI)
2	22,266	7,052
5	2.20×10^5	17,588
10	1.93×10^{17}	63,800
20	1.20×10^{19}	2.52×10^8
50	4.18×10^{19}	5.04×10^8
100	2.39×10^{20}	1.72×10^7
200	3.51×10^{24}	1.31×10^7

Table 1: Overfitting in the mixture of unigrams and pLSI models for the AP corpus. Similar behavior is observed in the semantide corpus (not reported).

we removed a standard list of 50 stop words from each corpus. From the AP data, we further removed words that occurred only once.

We compared LDA with the unigram, mixture of unigrams, and pLSI models described in Section 4. We trained all the hidden variable models using EM with exactly the same stopping criteria, that the average change in expected log likelihood is less than 0.001%.

Both the pLSI model and the mixture of unigrams suffer from serious overfitting issues, though for different reasons. This phenomenon is illustrated in Table 1. In the mixture of unigrams model, overfitting is a result of peaked posteriors in the training set, a phenomenon familiar in the supervised setting, where this model is known as the naive Bayes model (Bennie, 2001). This leads to a nearly deterministic clustering of the training documents (in the E-step) which is used to determine the word probabilities in each mixture component (in the M-step). A previously unseen document may best fit one of the resulting mixture components, but will probably contain at least one word which did not occur in the training documents that were assigned to that component. Such words will have a very small probability, which causes the perplexity of the new document to explode. As k increases, the documents of the training corpus are partitioned into finer collections and thus induce more words with small probabilities.

In the mixture of unigrams, we can alleviate overfitting through the variational Bayesian smoothing scheme presented in Section 5.4. This ensures that all words will have some probability under every mixture component.


In the pLSI case, the hard clustering problem is alleviated by the fact that each document is allowed to exhibit a different proportion of topics. However, pLSI only refers to the training documents and a different overfitting problem arises that is due to the dimensionality of the $p(z|d)$ parameter. One reasonable approach to assigning probability to a previously unseen document is to marginalize over d .

$$p(\mathbf{w}) = \sum_{\mathbf{z}} \prod_{n=1}^N \sum_{d=1}^D p(w_n | z) p(z | d) p(d).$$


Essentially, we are integrating over the empirical distribution on the topic simplex (see Figure 4). This method of inference, though theoretically sound, causes the model to overfit. The document-specific topic distribution has some components which are close to zero for those topics that do not appear in the document. Thus, certain words will have very small probability in the estimates of

Model-2 YGM-V2: Geliştirien YGM-v1 modelinin sonuçları amacımıza uygun ve başarı metrikleri yüksek sonuç verdiğiinden NAFNet modeli 2. model olarak kararlaştırılmıştır. Bu karar sonrasında kendi elde ettiğimiz veri集中的 boş tahta görüntüleri ile oluşturduğumuz B2n-2 veri seti ve IAM Handwirte satır düzeninde yazılar içeren veri seti ile model sıfırdan eğitime sokulmuş ve ürün seviyesine yakın bir sonuç alınmıştır.

Sonuçlar

Model	Veri / Eğitim Yapısı	Temel Başarı Değerleri	Değerlendirme
TTM-V1	6259 train, 645 val, 500 test; 640 px; 40 epoch; A100 full- RAM cache	Test IoU: 0.9759; Dice: 0.9878; Precision: 0.9870; Recall: 0.9887; Pixel Acc: 0.9798	İlk yüksek segmentasyon başarımını veren TTM sürümüdür.
TTM-V2 	2226 train, 278 val, 279 test; Stage2/Stage3 fine-tune; 640 px: Kendi Topladığımız Veri Seti Dahil	IoU: 0.9633; Dice: 0.9798; Precision: 0.9780; Recall: 0.9847; Loss: 0.0702	Amacımıza uygun final paketi üretmesi ve 2. model girdisi açısından güçlüdür.

Sonuçlar: YGM- Yazı Güçlendirme Modeli



Projeden ürüne: Bu model denetimli eğitimde ortaya çıkan L1, SSIM, Edge ve Mask gibi denetimli kayıplara takılı kalan başarımızı bir üst seviyeye çıkarmak amacıyla denetimli eğitilmiş YGM-V2 modelimize ek olarak denetimsiz GAN tabanlı adversarial fine-tune eğitimi gerçekleştirilmiştir.

Ürün Seviyesi Modelimiz: YGM V3 Ultra: Denetimli ile beraber modelimizin amacına uygun yani insanların rahatça yazıları okuyabilecekleri ve notlarına ekledikleri durumda kesiklik, bozukluk ya da benzer problemlerin insana uygun şekilde çözülmesi gerekliliğinden dolayı; denetimsiz GAN tabanlı fine-tune eğitime eklenmiştir.


Sonuçlar

Model	Temel Amaç	Veri/Eğitim	Öne Çıkan Sonuç
YGM-V1	Tek çıktılı görüntü restorasyonu; bozulmuş tahta görüntüsünden temiz hedef üretimi.	5506 train / 647 val / 325 test; 40 epoch; H100 80 GB; NAFNet tabanlı eğitim.	Test PSNR 33.46 dB; Test SSIM 0.9877; fakat OCR output ve text mask üretmemektedir.
YGM-V2	Çok başlı yapı: restored output, OCR output ve text mask output üretimi.	3920 train / 144 val / 156 test; NAFNet-Base multi-head; denetimli eğitim.	OCR PSNR yaklaşık 17.92 dB; mask IoU 0.5828; mask Dice 0.7196; canvas SSIM 0.9767.
YGM-V3 <i>2 Note</i>	YGM-V2 üzerine denetimli + denetimsiz GAN refine eğitimi.	3920 train / 144 val / 156 test; SENTETİK VERİ SETİ Aşamalı Eğitim : 14+12+6 epoch; A100 80 GB; 116M parametre.	OCR PSNR 24.81 dB; OCR SSIM 0.5082 ; MS-SSIM 0.7888; canvas PSNR 30.84 dB ; Boundary-F1 0.9712.

Sonuçlar


Metrik	YGM-V2	YGM-V3	Değişim	Yorum
OCR PSNR	17.9198 dB	24.8143 dB	+6.8946 dB / +38.5%	OCR için en güçlü artışlardan biridir.
OCR SSIM	1.537	5.082	+0.3545 / +230.7%	Yazı yapısının ve görsel benzerliğin belirgin iyileştiğini gösterir.
OCR MS-SSIM	4.457	7.888	+0.3432 / +77.0%	Çok ölçekli yapısal benzerlik artmıştır.
Mask IoU	5.827	5.778	-0.0049 / -0.8%	Maske başarımları korunmuş, çok küçük bir düşüş olmuştur.
Mask Dice/F1	7.196	7.159	-0.0037 / -0.5%	Maske çıktısı kararlı kalmıştır.
Canvas PSNR	30.7433 dB	30.8369 dB	+0.0936 dB / +0.3%	Ürün çıktısı kalitesi korunmuş ve hafif artmıştır.
Restored PSNR	18.0867 dB	20.9711 dB	+2.8844 dB / +15.9%	Genel restorasyon çıktısı da iyileşmiştir.

Modellerimizin Gelişimi



Proje hedeflerine ulaşmak için geliştirilen modeller iki ana aşamada ilerlemiştir. İlk aşamada tahta alanını doğru şekilde tespit edebilmek için MobileNetV3 tabanlı TTM modeli geliştirilmiş, ikinci aşamada ise tespit edilen tahta üzerindeki yazıların okunabilirliğini artırmak için NAFNet tabanlı YGM model ailesi oluşturulmuştur. Geliştirme sürecinde ilk modeller daha çok mimari uygunluğu test etmek amacıyla eğitilmiş, sonraki modellerde ise veri seti kalitesi, çok başlı çıktı yapısı ve GAN tabanlı iyileştirme yöntemleriyle ürün seviyesine yaklaşılmıştır.


Uygulanan Temel Stratejiler



Gerçek Dünya Verisi: İlk eğitimlerde hazır veri setleri kullanılmış, ancak proje hedeflerine daha uygun sonuçlar almak için sınıf, amfi ve farklı tahta ortamlarından oluşan özel veri setleri hazırlanmıştır. Bu sayede modelin gerçek kullanım senaryolarına daha dayanıklı hale gelmesi sağlanmıştır.




Çok Başlı Model Yapısı: YGM-v2 ile birlikte model yalnızca temiz görüntü üretmek yerine restored output, OCR output ve text mask olmak üzere üç farklı çıktı üretecek şekilde geliştirilmiştir. Bu yapı, OCR öncesi görüntü hazırlama sürecini daha kontrollü ve ürün odaklı hale getirmiştir.



Denetimli ve Denetimsiz Öğrenme: YGM-v2'de L1, SSIM, Edge, BCE ve Dice gibi denetimli kayıplar kullanılmıştır. Ancak çıktıların zaman zaman yumuşak ve düşük kontrastlı kalması sebebiyle YGM-v3 modelinde GAN tabanlı adversarial fine-tune uygulanmıştır. Bu geliştirme sonucunda OCR çıktılarında keskinlik, kontrast ve okunabilirlik belirgin şekilde artmıştır.


Sonuçlar

Sınıfında en başarılı modellerimizin birleşmesi ile oraya çıkan; Board2Note akıllı not uygulaması



2Note


TTM V2



YGM V3


2Note

Sonuçlar




2 Note

Sonuçlar



Orijinal Görüntü



1. Model Sonucu Segmente Edilmiş Tahta

Sonuçlar

örn α ilkel eleman ve $P(x) = x^3 + 2x + 1 \in \mathbb{F}_3(x)$ üzerinde tanımlı indirgenemez polinomdur. Buna göre $\mathbb{F}_{3^3}(x) = \mathbb{F}(27)$ cismini oluşturunuz.

α ilk el emansa.

$$|H_{27}^*| = 27 - 1 = 26$$

$$\alpha^{2^b} = 1 \pmod{2^7}$$

$0 \leq m \leq 1$.

$$P(\alpha) = \alpha^3 + 2\alpha + 1 = 0$$

$$\alpha^3 = -2\alpha - 1 = \alpha + 2$$

$$\alpha^4 = \alpha \cdot \alpha^3 = \alpha(\alpha+2) = \alpha^2 + 2\alpha$$

$$x^5 - x^3 + 2x^2 = x + 2 + 2x^2 = 2x^2 + x + 2 \quad (212)$$

$$\begin{aligned} a^6 &= 2a^3 + a^2 + 2a = 2(a+2) + a^2 + 2a \\ &= 2a + 4 + a^2 + 2a \\ &= a^2 + 4a + 4 = a^2 + \end{aligned}$$

$$\alpha^0 = 1$$

$$\alpha^1 = \alpha$$

$$\alpha^2 = \alpha^2$$

$$\alpha^3 = \alpha + 2$$

$$-2\alpha \quad \begin{pmatrix} 1 & 2 & 0 \\ \alpha^2 & \alpha^1 & \alpha^0 \end{pmatrix} = 12 //$$

Sonuçlar

örn

α ilkel eleman ve $P(x) = x^3 + 2x + 1 \in \mathbb{F}_3(x)$ üzerinde

tanımlı indirgenemez polinomdur. Buna göre $\mathbb{F}_3(x) \cong \mathbb{F}(27)$ cismini oluştururuz.

α ilkel eleman ise.

$$|\mathbb{F}_{27}^*| = 27 - 1 = 26$$

$$\alpha^{26} = 1 \pmod{27}$$

olmalı.

$$P(\alpha) = \alpha^3 + 2\alpha + 1 = 0$$

$$\alpha^3 = -2\alpha - 1 = \alpha + 2$$

$$\alpha^4 = \alpha \cdot \alpha^3 = \alpha(\alpha + 2) = \alpha^2 + 2\alpha$$

$$\alpha^5 = \alpha^3 + 2\alpha^2 = \alpha + 2 + 2\alpha^2 = 2\alpha^2 + \alpha + 2 \quad (2 \ 1 \ 2)$$

$$\alpha^6 = 2\alpha^3 + \alpha^2 + 2\alpha = 2(\alpha + 2) + \alpha^2 + 2\alpha$$

$$= 2\alpha + 4 + \alpha^2 + 2\alpha$$

$$= \alpha^2 + 4\alpha + 4 = \alpha^2 + \alpha + 1$$

$$\alpha^0 = 1$$

$$\alpha^1 = \alpha$$


$$\alpha^2 = \alpha^2$$

$$\alpha^3 = \alpha + 2$$


$$\begin{pmatrix} 1 & 2 & 0 \\ \alpha^2 & \alpha^1 & \alpha^0 \end{pmatrix} = 12 //$$

Ürün Seviyesi Son Çıktı

Sonuçlar



Orijinal Görüntü



1. Model Sonucu Kırpılmış Tahta

Sonuçlar

Örnek

$\mathbb{F}_5$ -tanımlı $\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 2 & 3 & 4 & 0 & 0 \\ 1 & 4 & 4 & 1 & 0 & 1 \end{bmatrix}$ Standart formda
gösteren matrisi bulunuz.

$\begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 0 & 0 & 1 & 3 & 1 & 3 \end{bmatrix} \rightarrow 4x$

$\begin{bmatrix} 2 & 0 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 1 & 4 & 4 & 1 & 0 & 1 \end{bmatrix}$

$3x \rightarrow \begin{bmatrix} 2 & 0 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 0 & 1 & 1 & 0 & 3 & 2 \end{bmatrix} \rightarrow 4x$

2.Model Sonucu Yazıları Belirginleştirilmiş Çıktı

Sonuçlar

ör
 $\mathbb{F}_5$ -denimli $\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 2 & 3 & 4 & 0 & 0 \\ 1 & 4 & 4 & 1 & 0 & 1 \end{bmatrix}$
 $\underbrace{\hspace{10em}}_I$ $\underbrace{\hspace{10em}}_A$

Student formula
fjreter matrisc danielm,


$$\begin{array}{l} \left[\begin{array}{ccccc|c} 1 & 0 & 0 & 1 & 3 & 0 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 0 & 0 & 4 & 2 & 4 & 2 \end{array} \right] \rightarrow 4x \end{array}$$

$$4x \rightarrow \begin{bmatrix} 2 & 0 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 1 & 4 & 4 & 1 & 0 & 1 \end{bmatrix}$$


$$3R \rightarrow \begin{bmatrix} 2 & 0 & 0 & 2 & 1 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \xrightarrow{3R \rightarrow R - R} \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \xrightarrow{4R \rightarrow R - 4R} \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 0 & 1 & 1 & 0 & 3 & 2 \end{bmatrix}$$

Ürün Seviyesi Son Çıktı

Sonuçlar




Orijinal Görüntü



1. Model Segmentasyon Sonucu

Sonuçlar



2. Model Sonucu Yazıları Belirginleştirilmiş Çıktı

Sonuçlar

$V_{14} = -2.1$	$W_{48} = 1$
$V_{24} = 3.7$	$W_{58} = 2$
$V_{34} = 0.9$	$W_{68} = 3$
$V_{45} = 1.5$	$W_{78} = 4$
$V_{25} = -4.8$	$W_{49} = -1$
$V_{35} = 2.6$	$W_{59} = -1.5$
$V_{46} = -4.2$	$W_{69} = -2$
$V_{26} = -2.3$	$W_{79} = -2.5$
$V_{36} = 1.8$	$b_8 = 1.6$
$V_{17} = 0.7$	$b_9 = -0.09$
$V_{27} = 4.3$	
$V_{37} = -5.4$	
$b_4 = 5$	
$b_5 = -15$	
$b_6 = -7$	
$b_7 = 26$	

$$e_1 = \frac{1}{2} (t_1 - y_1)^2$$

$$= \frac{1}{2} (1 - 0.5)^2 = 0.125$$

$$e_2 = \frac{1}{2} (t_2 - y_2)^2$$

$$= \frac{1}{2} (-1 - 0.73)^2 = 1.496$$

$$e_T = e_1 + e_2 = 1.621$$


$$E_T = \frac{1}{2} (t_1 - y_1)^2 + \frac{1}{2} (t_2 - y_2)^2$$

$$W_{36}^{yeni} = W_{34} = E_4 \cdot X_3$$

$$W_{79} = E_9 \cdot X_7$$

$$b_8 = E_8$$

$$b_9 = E_9$$



$$E_8 = \frac{\partial E}{\partial x_8} = \frac{\partial E}{\partial y_1} \cdot \frac{\partial y_1}{\partial x_8}$$

$$= -(t_1 - y_1) y_1 (1 - y_1) = -0.125$$

$$E_6 = [E_8 \cdot W_{68} + E_9 \cdot W_{69}] [1 - x_6]^2 = -0.98$$

$$E_9 = \frac{\partial E}{\partial x_9} = \frac{\partial E}{\partial y_2} \cdot \frac{\partial y_2}{\partial x_9} = \frac{1}{2} (t_2 - y_2) y_2 (1 - y_2) = 0.34$$

$$W_{36}^{yeni} = W_{36}^{eski} - \eta \cdot \frac{\partial E}{\partial W_{36}}$$

$$= 1.8 - \left[\frac{(-0.7)(-0.09)(2.5)}{(1.0)(-0.09)(2.5)} \right] = 2.085$$

$$b_9^{yeni} = b_9^{eski} - \eta \cdot \frac{\partial E}{\partial b_9} = -0.09 - (-0.7) = 0.61$$

$$b_8 = b_8^{eski} - [0.7] E_8$$

$$1.6 - [0.7] (-0.125) = 1.51$$


Ürün Seviyesi Son Çıktı



2 Note

**Mobil Uygulamamız:
Board2Note**

Akıllı Not Uygulaması: Board2Note



Projemiz kapsamında geliştirdiğimiz TTM-V2 ve YGM-V3 modellerimizi gündelik hayatta, eğitim sürecinde ya da eğitimci olarak not alan tüm kullanıcıların kullanıcı dostu, modern ve hızlı bir ara yüz üzerinden not almasını aynı zamanda beyaz tahta görüntülerini anında notlarına ekleyebilecekleri mobil uygulamamız;

Board2Note

- Gündelik hayatta dijital not tutma sürecinde etkin olarak rol alması ve aynı zamanda kameralı cihaz gereksinimi sebebiyle mobil platform için geliştirilen uygulamamızın frontend tarafında Kotlin tercih edilmiştir.
- Modellere istek atılması ve aynı zamanda diğer kural tabanlı işlemlerin gerçekleştirilmesi süreci için Python FastAPI backend tercih edilmiştir. (Hızlı yanıt alınabilmesi için tercih edildi.)

$$\begin{array}{l|l}
 u_{14} = -2.1 & w_{48} = 1 \\
 u_{24} = 3.7 & w_{58} = 2 \\
 u_{34} = 0.9 & w_{68} = 3 \\
 & w_{78} = 4 \\
 u_{15} = 1.5 & 0 \\
 u_{25} = -4.8 & w_{49} = -1 \\
 u_{35} = 2.6 & w_{59} = -1.5 \\
 & w_{69} = -2 \\
 & w_{79} = -2.5 \\
 u_{16} = -4.2 & b_8 = 1.6 \\
 u_{26} = -2.3 & b_9 = -0.09 \\
 u_{36} = 1.8 & \\
 u_{17} = 0.7 & \\
 u_{27} = 4.3 & 0 \\
 u_{37} = -5.4 & \\
 b_4 = 5 & \\
 b_5 = -15 & \\
 b_6 = -7 & \\
 b_7 = 26 &
 \end{array}$$

$$\begin{aligned}
 e_1 &= \frac{1}{2} (t_1 - y_1)^2 \\
 &= \frac{1}{2} (1 - 0.5)^2 = 0.125
 \end{aligned}$$

$$\begin{aligned}
 e_2 &= \frac{1}{2} (t_2 - y_2)^2 \\
 &= \frac{1}{2} (-1 - 0.73)^2 = 1.496
 \end{aligned}$$

$$e_T = e_1 + e_2 = 1.621$$

$$E_T = \frac{1}{2} (t_1 - y_1)^2 + \frac{1}{2} (t_2 - y_2)^2$$

$$\begin{aligned}
 w_{36}^{yen} &= w_{34} = E_4 \cdot x_3 \\
 &\downarrow E_6 \cdot x_3 \\
 b_8 &= E_6
 \end{aligned}$$

$$\begin{aligned}
 w_{34} &= E_4 \cdot x_3 \\
 w_{79} &= E_9 \cdot x_7
 \end{aligned}$$



Board2Note

$$\begin{aligned}
 3x \rightarrow & \begin{bmatrix} 2 & 0 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 2 & 1 & 2 & 0 & 0 & 1 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 4 & 1 & 1 & 4 & 0 & 4 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 1 & 3 & 3 \\ 0 & 1 & 2 & 3 & 4 & 0 \\ 0 & 1 & 0 & 3 & 2 & 4 \end{bmatrix}
 \end{aligned}$$

ölkü

α ilkel eleman ve $P(x) = x^3 + 2x + 1 \in \mathbb{F}_3(x)$ irrasyonel polinomdur. Buna göre

el elemanına


$$|\mathbb{F}_{27}^*| = 27 - 1 = 26$$

$$P(\alpha) = \alpha^3 + 2\alpha + 1 = 0$$

$$\alpha^3 = -2\alpha - 1 = \alpha + 2$$

$$\alpha^4 = \alpha \cdot \alpha^3 = \alpha(\alpha + 2) = \alpha^2 + 2\alpha$$

$$\begin{aligned}
 \alpha^0 &= 1 \\
 \alpha &= \alpha \\
 \alpha^2 &= \alpha^2 \\
 \alpha^3 &= \alpha + 2
 \end{aligned}$$



$$\frac{\partial E}{\partial x_8} = \frac{\partial E}{\partial y_1} \cdot \frac{\partial y_1}{\partial x_8}$$


$$= -(t_1 - y_1) y_1 (1 - y_1) = -0.125$$

$$E_9 = \frac{\partial E}{\partial x_9} = \frac{\partial E}{\partial y_2} \cdot \frac{\partial y_2}{\partial x_9} = \frac{1}{2} (t_2 - y_2)$$

$$[E_4 w_{68} + E_9 w_{69}] [1 - (x_6)^2] = -0.98$$

$$w_{14}^{yen} = w_{14}^{old}$$

Board2Note



2Note



Board2Note uygulamasının amacı kullanıcıların kendilerine özel tamamen bağımsız bir not alma uygulaması kullanırken aynı zamanda eğitim süreçlerinde tahta görüntülerini kolayca notlarına ekleyebilmelerini sağlamaktır.


Uygulama içinden galeri ya da anlık kamera ile beraber tahta görüntüsü çekilerek kolayca ders notuna eklenebilir şekilde hazır halde elde edilmektedir.

Uygulamada not favorileme, arşivleme ve silme gibi temel işlevlerin yanı sıra kategori/ders oluşturup notları kategorize etme gibi öğrenci dostu özelliklerde sunulmuştur.

Tahta üzerinden alınan not anında not defterine eklenerek üstünde çok işlevli araçlar ile canvas yapısı sayesinde not alma imkanı sunulmaktadır.

Kullanıcıya tahtadan eklediği notları kolayca yapay zeka servisleri ile beraber anlatım alabileceği akıllı AI özellikleri sunulmuştur


2Note



Modern arayüz yapısı
ile tüm notları ve
kategorileri tek
ekrandan yönetebilme
özellği sunulmuştur.



Favoriye alınan notları
ekran üzerinden görme
ve çıkarma




Profesyonel kanvas
yapısı ile not alma
deneyimini arttıran not
ekranı

2 Note




Galeri ya da kamera ile
tahta görüntüsünü
anında dijital nota
çevirme imkanı




Dijitale dönüştürülen
tahta notu üstünde
dilediğinde not alma ve
not oluşturma

2Note



Geniş tablet ekranlarına uygun yapıda
ölçeklenebilir ana ekran

2 Note



**Tabletlere özel
geliştirilmiş
basınca duyarlı ve
kolay yönetilebilir
işlevsel kanvas not
alma ekranı**

Konumu değiştirebilir çok işlevli not araç çubuğu

2 Note

Başlık
değiştirme

Renk paleti

Kalem
boyutu

Sayfa
temizleyici

Sayfa değiştirici ile istediğiniz
kadar not alın

“+” butonu ile
tahta görüntüsü
ya da ham
görüntü ekleme
özellliği

00:29 2 Haz Sal

← Yapay Sinir Ağları

1/3

Geri yayılım

Hata

$$e_1 = \frac{1}{2} (t_1 - y_1)^2 = \frac{1}{2} (1 - 0,5)^2 = 0,125$$
$$e_2 = \frac{1}{2} (t_2 - y_2)^2 = \frac{1}{2} (-1 - 0,73)^2 = 1,436$$
$$E_T = e_1 + e_2 = 1,621$$
$$E_T = \frac{1}{2} (t_1 - y_1)^2 + \frac{1}{2} (t_2 - y_2)^2$$
$$W_{36}^{yeni} = W_{34} \cdot x_3$$
$$W_{39} = E_9 \cdot x_3$$
$$b_8 = E_8$$
$$b_9 = E_9$$
$$E_8 = \frac{\partial E}{\partial x_8} = \frac{\partial E}{\partial y_1} \cdot \frac{\partial y_1}{\partial x_8} = -(t_1 - y_1) \cdot y_1 (1 - y_1) = -0,125$$
$$E_9 = \frac{\partial E}{\partial x_9} = \frac{\partial E}{\partial y_2} \cdot \frac{\partial y_2}{\partial x_9} = \frac{1}{2} (t_2 - y_2) \cdot y_2 (1 - y_2) = 0,34$$
$$E_6 = [E_8 \cdot W_{68} + E_9 \cdot W_{69}] [1 - K_1^2] = -0,98$$
$$W_{11}^{yeni} = W_{11}^{eski} - \eta \cdot \frac{\partial E}{\partial W_{11}} = 1,8 - \left[\frac{(-0,73)(-0,09)(2,5)}{(1,8)(-0,09)(2,5)} \right] = 2,083$$
$$b_{y1}^{yeni} = b_{y1}^{eski} - \eta \cdot \frac{\partial E}{\partial b_{y1}} = -0,09 - (-0,1) = 0,01$$

$b_8 = b_{y1}^{eski} - [0,73] E_T$
 $1,6 - [0,73](-0,125) = 1,51$

$b_9 = b_{y2}^{eski} - [0,73] E_T$
 $1,6 - [0,73](-0,125) = 1,51$

Sayfa 1 / 3

2 Note

Anlatım için metne dönüştürme



Yalnızca tahtadan not eklemek ve not editörü değil aynı zamanda ilgili notu anlatan bir yardımcı

Yeni Canvas Notu

$W_{14} = -2.1$	$W_{68} = 1$
$W_{24} = 2.7$	$W_{58} = 2$
$W_{34} = 0.9$	$W_{48} = 3$
$W_{45} = 1.5$	$W_{38} = 4$
$W_{25} = -4.8$	$W_{49} = -1$
$W_{35} = 2.6$	$W_{59} = -1.5$
$W_{46} = -4.2$	$W_{69} = -2$
$W_{26} = -2.3$	$W_{39} = -2.5$
$W_{36} = 1.8$	$b_8 = 1.6$
$W_{17} = 0.7$	$b_9 = -0.09$
$W_{27} = 4.3$	
$W_{37} = -5.4$	
$b_4 = 5$	
$b_5 = -15$	
$b_6 = -7$	
$b_7 = 26$	

$E_1 = \frac{1}{2} (t_1 - y_1)^2 = \frac{1}{2} (1 - 0.5)^2 = 0.125$

$E_2 = \frac{1}{2} (t_2 - y_2)^2 = \frac{1}{2} (-1 - 0.73)^2 = 1.476$

$E_T = E_1 + E_2 = 1.621$

$E_T = \frac{1}{2} (t_1 - y_1)^2 + \frac{1}{2} (t_2 - y_2)^2$

$W_{36} y_{6i} = W_{34} x_4$

$W_{35} x_5$

$b_8 = E_8$

$E_8 = \frac{\partial E}{\partial x_8} = \frac{\partial E}{\partial y_1} \frac{\partial y_1}{\partial x_8} = -(t_1 - y_1) y_1 (1 - y_1) = -0.125$

$E_9 = \frac{\partial E}{\partial x_9} = \frac{\partial E}{\partial y_2} \frac{\partial y_2}{\partial x_9} = -(t_2 - y_2) y_2 (1 - y_2) = 0.34$

$E_6 = [E_8 \cdot W_{68} + E_9 \cdot W_{69}] [1 - y_6^2] = -0.98$

$b_8 = b_{geli} - \eta \cdot \frac{\partial E}{\partial y_8} = 1.6 - (0.7)(-0.125) = 1.51$

$b_9 = b_{geli} - \eta \cdot \frac{\partial E}{\partial y_9} = -0.09 - (0.7)(0.34) = -0.238$

Sayfa 1 / 1

Yapay zeka servisleri ile ilgili ders notunu açıklama özelliği

2 Note ✨

2 Note

Yeni Canvas Notu

Sil Metni guncelle

AI Açıklama

Adim Adim Anlatim

1. Hata Hesaplama: İlk olarak her bir cikis birimi icin hata hesaplanır. Notlarda e1 ve e2 olarak verilen bu degerler, tahmin edilen deger (x) ile gercek deger (y) arasindaki farkin karesinin yarisi alinarak bulunur.

2. Toplam Hataya Ulasma: Bireysel hatalar toplandiginda ($E_t = e1 + e2$), agin genel performansini gosteren toplam hata elde edilir.

3. Hatanin Yayilimi: Agin ogrenmesi icin, bu toplam hatanin hangi agirliklardan kaynaklandigini bulmamiz gerekir. Bunun icin kısmi turevler kullanilir.

4. Zincir Kuralinin Uygulanmasi: Bir girdinin (örneğin X8) toplam hata üzerindeki etkisini bulmak icin, hatanin önce cikis degerine, sonra cikis degerinin girdiye göre turevi alinir ve bu iki deger carpilir.

Sayfa 1 / 1

AI Açıklama

Adim Adim Anlatim

1. Hata Hesaplama: İlk olarak her bir cikis birimi icin hata hesaplanır. Notlarda e1 ve e2 olarak verilen bu degerler, tahmin edilen deger (x) ile gercek deger (y) arasindaki farkin karesinin yarisi alinarak bulunur.
2. Toplam Hataya Ulasma: Bireysel hatalar toplandiginda ($E_t = e1 + e2$), agin genel performansini gosteren toplam hata elde edilir.
3. Hatanin Yayilimi: Agin ogrenmesi icin, bu toplam hatanin hangi agirliklardan kaynaklandigini bulmamiz gerekir. Bunun icin kısmi turevler kullanilir.
4. Zincir Kuralinin Uygulanmasi: Bir girdinin (örneğin X8) toplam hata üzerindeki etkisini bulmak icin, hatanin önce cikis degerine, sonra cikis degerinin girdiye göre turevi alinir ve bu iki deger carpilir.

Nota ait detaylı yapay zeka anlatımı

2Note

**Beyaz Tahtadan Yazı Tepiti
Board2Note**

Bizi dinlediğiniz için teşekkürler

Ekip Bilgileri

1221602035 – Samet Ünver
1221602013– Hilal Kaynar
1221602038 – Batuhan Güneysu
1221602040 – Taha Demir
1231602808– Halit Eren Deniz

Danşman

Dr. Öğr. Üyesi Turgut Doğan



2 Note

bir nottan fazlası